

Аннотация

В работе проводится анализ алгоритмов адаптивной компенсации нелинейных паразитных искажений, возникающих в приеме-передающих устройствах телекоммуникаций.

Нелинейные искажения образуются в передатчиках базовых станций, а также мобильных устройств при прохождении сигнала через нелинейные цепи передающего тракта, усилитель мощности и дуплексер. Вследствие компактности расположения компонент в RF-чипсете мобильного устройства, паразитная помеха распространяется из передатчика в приёмную часть уменьшая чувствительность приёмника.

Нелинейные искажения в передатчике базовых станций и мобильных устройств значительно влияют на качество радиочастотных сигналов, создавая помехи в канале связи. Такие нелинейные искажения приводят к увеличению битовой ошибки (Bit Error Rate - BER) на приемнике, генерируют внутриполосные и внеполосные помеховые сигналы и ухудшают качество передачи сигналов соседних полос. Для предотвращения искажений в современных базовых станциях и сотовых устройствах широко используются методы цифрового предискажения, основанные на методе адаптивной компенсации нелинейных искажений в передатчике.

В работе рассматриваются задачи адаптивной нелинейной компенсации искажений в задаче цифрового предискажения сигнала передатчика и адаптивной компенсации паразитных помех в приёмном тракте мобильного терминала системы связи стандарта 4G/5G. Приводится математическое описание модели нелинейной помехи, а также используемых в исследовании алгоритмов.

На примере компенсации искажений в приёмнике предложен алгоритм адаптации второго порядка — смешанный метод Ньютона для обучения многослойных комплекснозначных моделей. Алгоритм характеризуется высокой скоростью сходимости, а теоретически обоснованной динамикой, способствующей отталкиванию от седловых точек. С целью обеспечения практической реализуемости в аппаратуре разработана его модификация на основе метода сопряжённых градиентов, позволяющее существенно снизить вычислительную сложность без значительной потери эффективности.

В рамках задачи цифрового предискажения сигнала в передатчике предложен подход к проектированию модели, основанный на учёте динамических режимов работы усилителя мощности посредством адаптации многомерной модели с дополни-

тельными входными признаками. Такой способ позволяет адаптивно предсказывать изменения характеристик нелинейного устройства без необходимости переключения между отдельными моделями. Для снижения вычислительных и аппаратных затрат разработана структура модели на основе малорангового разложения многомерной функции, что позволяет избежать экспоненциального роста сложности при увеличении числа динамических параметров.

Отдельное внимание уделено вопросам аппаратной оптимизации цифровой реализации адаптивных нелинейных корректоров. Предложены методы сокращения ресурсов, основанные на уменьшении вычислительной сложности цифровых фильтров, входящих в состав моделей, включая квантование коэффициентов и структурные преобразования, направленные на сокращение числа операций умножения.

Таким образом, в работе предложен комплекс методов, направленных на повышение эффективности адаптивной компенсации нелинейных искажений при одновременном снижении вычислительных и аппаратных затрат, что обеспечивает практическую применимость разработанных решений в современных системах связи.

Содержание

Аннотация	i
Введение	iv
I.. Методы адаптивной компенсации нелинейных искажений сигнала в приеме-передающих устройствах систем связи	1
1. Постановка задачи адаптивной компенсации нелинейных искажений в устройствах связи	1
1.1. Проблема возникновения паразитных помех в приёмном тракте приема-передающего устройства	1
1.2. Схема компенсации паразитных нелинейных помех в приёмном тракте мобильного терминала	3
1.3. Проблема возникновения нелинейных искажений сигнала передающего тракта	4
1.4. Схема компенсации нелинейных искажений в передатчике приема-передающего устройства	5
1.5. Критерии компенсации нелинейных искажений в устройствах связи	6
2. Методы первого порядка для адаптации моделей нелинейных искажений	8
2.1. Метод градиентного спуска	8
2.2. Модификации метода градиентного спуска	11
3. Методы второго порядка для адаптации моделей нелинейных искажений	12
3.1. Метод Ньютона	12
3.2. Модификации метода Ньютона	17
3.3. Смешанный метод Ньютона	18
3.4. Метод LS	20
4. Методы адаптации моделей нелинейных искажений не требующие явного обращения матрицы Гессе	21
4.1. Метод сопряженных градиентов	21
4.2. Метод DCD	25
4.3. Квазиньютоновские методы	28
4.4. Метод Barzilai-Borwein	30
4.5. Метод DFP	30
4.6. Метод BFGS	31

4.7.	Квазиньютоновские методы для моделей с вещественными параметрами	32
5.	Математические модели линейных и нелинейных искажений в системах связи	33
5.1.	Линейная модель искажений сигнала в системах связи	33
5.2.	Полиномиальная модель нелинейных искажений в системах связи	35
5.3.	Модель нелинейных искажений в системах связи на основе сплайновых полиномов	38
5.4.	Модель Вольтерра нелинейных искажений в системах связи . .	40
5.5.	Модель Гаммерштейна нелинейных искажений в системах связи	41
5.6.	Модель Винера нелинейных искажений в системах связи	43
5.7.	Модель Винера-Гаммерштейна нелинейных искажений в системах связи	46
5.8.	Применение нейросетевых структур для аппроксимации нелинейных искажений приемо-передающего тракта	48
5.9.	Применение канонического тензорного разложения для аппроксимации многомерный структур	52

II..Исследование эффективности методов адаптивной компенсации нелинейных искажений в устройствах связи

	нелинейных искажений в устройствах связи	56
1.	Структура тестовой платформы	56
2.	Формирование тестовых наборов данных	57
2.1.	Формирование обучающей выборки для задачи компенсации нелинейной помехи в приёмнике полнодуплексной системы связи . .	57
2.2.	Формирование обучающей выборки для задачи компенсации нелинейных комбинационных искажений второго порядка в приёмнике системы связи	58
2.3.	Формирование обучающей выборки для задачи цифровых предискажений в передатчике двухканальной системы связи	60
2.4.	Формирование обучающей выборки для задачи цифровых предискажений в передатчике одноканальной системы связи в условиях динамически меняющегося режима работы усилителя мощности	63
3.	Исследование алгоритмов и адаптивных моделей компенсации паразитной помехи на приёмнике устройств связи	64
3.1.	Компенсация паразитной помехи на приёмнике полнодуплексной системы связи методом адаптации модели Гаммерштейна . .	64
3.2.	Компенсация паразитных комбинационных помеховых составляющих второго порядка на основе адаптации классических и нейросетевых структур	68

4.	Исследование алгоритмов и адаптивных моделей компенсации нелинейных искажений в передатчике устройств связи	73
4.1.	Компенсация нелинейных искажений в передатчике устройств связи в условиях динамического изменения выходной мощности нелинейного усилителя	73

III. Практическая реализация нелинейных корректоров в системах связи	83
---	-----------

1.	Исследование компенсации нелинейных искажений методами не требующими явного обращения матрицы Гессе	83
2.	Сокращение ресурсов при реализации моделей нелинейных искажений засчет канонического тензорного разложения	86
3.	Методы экономии ресурсов при реализации цифровых фильтров в моделях компенсации нелинейных искажений	89
3.1.	Метод экономии ресурсов при реализации цифровых фильтров засчет квантования параметров	91
3.2.	Метод экономии ресурсов при реализации цифровых передискретизаторов	96
3.3.	Метод экономии ресурсов при реализации цифровых фильтров при помощи алгоритма МСМ	102
3.4.	Сокращение ресурсов при реализации классических моделей нелинейных искажений засчет оптимизации структуры цифровых фильтров	108

Заключение	114
-------------------	------------

Введение

По мере совершенствования телекоммуникационных технологий возникают задачи повышения скорости передачи информации. Так например разработка систем стандарта 5G предполагает решение задач связанных с увеличением скорости передачи информации по сравнению с системами стандарта 4G. Увеличение скорости передачи требует повышения порядков цифровой модуляции. А это в свою очередь требует улучшения характеристик чувствительности приёмника.

Кроме того, важнейшим направлением развития телекоммуникационных технологий является унификация производства аппаратуры. Так основная тенденция это упрощение аналоговых трактов аппаратуры с компенсацией возникающих искажений адаптивными цифровыми корректорами [dig_front_end].

Современным направлением решения перечисленных задач является использование адаптивных систем нелинейной коррекции, которые позволяют существенно повысить коэффициент полезного действия передающих трактов системы при сохранении характеристик линейности системы в соответствии с принятыми международными стандартами связи [3gpp_36_804]. С точки зрения производителя оборудования это означает уменьшение себестоимости устройства. Для оператора связи это гарантирует уменьшение энергопотребления базовых станций. С точки зрения пользователя мобильного терминала это означает увеличение времени автономной работы телефона.

Одной из ключевых задач нелинейной коррекции является задача адаптивной коррекции сигнала в приёмнике приёмо-передающего устройства (SIC – Self-Interference Cancellation) [Shahghasi2025_SICStrategies, Lee2025AOPLMS_TWC, Hu2023AEU_SW]. Ввиду компактного расположения компонент в RF-чипсете мобильного терминала, нелинейные компоненты, возникающие в передающем тракте в результате прохождения через нелинейный усилитель мощности, попадают в приемный тракт мобильного телефона, проходя через дуплексер по различным путям распространения. Кроме того, компоненты второго порядка могут попадать в окрестность нулевой частоты в результате нелинейности смесителей в каналах передатчика и приёмника. В результате уменьшается чувствительность приёмника, а соответственно и пропускную способность нисходящего канала связи.

Одной из задач компенсации помех в приёмнике SIC является проблема проектирования полнодуплексных систем связи (IBFD – In-Band Full Duplex). Полно-

дуплексная система связи подразумевает работу каналов передатчика и приёмника в одной и той же частотной полосе. Поскольку в реальных устройствах существуют проблемы изоляции каналов передатчика и приёмника, сигнал передатчика просачивается в канал приёмника на уровне до $\approx 60\text{--}100$ дБ выше сигнала приёмного устройства [Duarte2012_FDWireless_TWC] и требуют уровня компенсации $\approx 75\text{--}115$ дБ. Компенсация такого уровня помехи осуществляется в несколько этапов: за счет пассивной изоляции [Deo2020_FDdualReceiver_IETMAP, Li2025_SelfDecoupledAntenn] при помощи аналогового корректора [Shilling2023_AnalogSIC_JCM, Hermstein2025_RFC] а также цифровых методов адаптивной коррекции [Duarte2012_FDWireless_TWC, PMC9784726_WidelyLinear_SIC].

Пассивные техники изоляции TX-RX канала включают в себя циркуляторы, направленные антенны, методы кросс-поляризации, экранирование и обеспечивают в среднем $\approx 20\text{--}30$ дБ изоляции [Duarte2012_FDWireless_TWC], отдельных случаях достигают 45 дБ пассивной изоляции [Deo2020_FDdualReceiver_IETMAP]. Методы активной аналоговой коррекции позволяют достичь $\approx 30\text{--}50$ дБ компенсации помехи. Таким образом, компенсация цифровыми методами требуется на уровне $\approx 20\text{--}35$ дБ [Duarte2012_FDWireless_TWC].

Классические методы цифровой компенсации нелинейных помех в приёмные полнодуплексной системы связи представляют собой адаптацию классических моделей [Song2024_S] и нейросетевых моделей [Wang2024_TVT_SimpleNN_NonlinearSIC] моделей при помощи методом первого порядка ввиду их простоты аппаратной реализации. Тем не менее, для корректной работы полнодуплексной системы требуется высокий компенсации, а также высокая скорость сходимости адаптивных моделей.

В связи с этим, в данной работе предложен метод второго порядка – смешанный метод Ньютона для адаптации многослойных комплекснозначных моделей нелинейных помех. Особенностью данного метода является высокая скорость сходимости, а также теоретическое обоснование эффекта отталкивания от седловых точек в случае голоморфности ошибки адаптации [mixed_newton_global_opt]. Кроме того, данный метод не требует явного вычисления вторых производных, что существенно увеличивает скорость вычисления шага адаптации.

Тем не менее, предложенный метод подразумевает обращение матрицы Гёссе для пересчета параметров модели, в результате чего данный подход становится практически трудно реализуемым в реальных устройствах связи. В связи с этим в данной работе предлагается модификация смешанного метода Ньютона на базе метода сопряженных градиентов. Такой подход позволяет оценивать шаг смешанного метода Ньютона, сокращая вычислительную сложность шага адаптации, сохраняя высокую скорость сходимости. В результате метод сопряженных градиентов выступает компромиссом между предложенным методом второго порядка и высокой скоростью сходимости и градиентными методами и низкой вычислительной сложностью.

Как было отмечено ранее, к задачам компенсации помех приёмнике SIC относится

задача компенсации компоненты второго порядка, возникающей за счет нелинейной характеристики аппаратных смесителей в передатчике и приёмнике [sic_imd2_phd, Gebhard2018_IM2RLS_arXiv, Gebhard2019_RLS_IMD2_TMTT]. Комбинационная помеха второго порядка, познкаящая на нулевой частоте имеет невысокий уровень по мощности $\approx$ дБ. Поэтому для решения данной задачи при помощи цифровых методов адаптации не требует аппаратной реализации больших адаптивных моделей. Чаще всего используются классические модели, такие как модель Винера, которые адаптируются методами LMS/RLS [sic_imd2_phd, Gebhard2019_RLS_IMD2].

В данной работе предлагается сравнение классического подхода компенсации комбинационной помехи второго порядка на основе адаптации полиномиальной модели на основе функционального базиса Чебышева, а также модели на основе полносвязного перцептрона. Нейросетевой подход на основе полносвязной модели по сути представляет собой адаптивный функциональный базис, что позволяет дополнительно сократить ресурсы аппаратной реализации адаптивной модели. При этом уровень компенсации помехи увеличивается по сравнению с классическим подходом. Отметим, однако, что скорость сходимости алгоритма обучения полносвязной модели с несколькими слоями ниже, чем у классической ввиду усложнения ландшафта функции потерь.

Кроме того, проводится сравнение скорости сходимости методов адаптации рассмотренных моделей. Предлагается использовать квазиньютоновские методы с ограниченной памятью ввиду их простоты аппаратной реализации, а также высокой скорости сходимости по сравнению с градиентными методами.

С другой стороны в данной работе подробно рассмотрена задача цифрового предсказания сигнала (DPD – Digital Pre-Distortion) в передатчике приёмо-передающего устройства [dpd_models]. Данный подход основан на адаптивной подстройке параметров цифрового корректора с целью формирования характеристики обратной характеристике нелинейного устройства, в частности усилителя мощности. Метод адаптивного предсказания широко используется в современных системах связи и позволяет улучшить спектральную маску, понизить битовую ошибку на приемнике и, как следствие, использовать модуляции более высокого порядка тем самым повышая скорость передачи информации [pa_models].

Корректная работа системы цифрового предсказания основана на предположении стационарности нелинейных искажений усилителя мощности и статистических свойств входного сигнала [dpd_models]. Сходимость алгоритмов адаптации модели (1.4.3) предполагает, что входной и опорный сигналы принадлежат одному и тому же стационарному распределению. При нарушении этого условия ухудшается или утрачивается сходимость алгоритма обучения [widrow1985adaptive].

В реальных системах динамическое распределение ресурсных блоков и регулировка выходной мощности (до 20–30 дБ относительно максимума согласно требованиям 3GPP/ETSI) приводят к изменению режима работы усилителя мощности

и его нелинейных характеристик [Dynamic_DPD_RB_Alloc, etsi_ts_136104]. Переходные процессы при переключении уровней мощности вызывают скачки ошибки адаптации и ухудшают выполнение спектральных требований, вследствие чего модель DPD, обученная для конкретного режима, теряет эффективность и требует адаптивной перенастройки.

Одним из подходов к прогнозированию нелинейных искажений при изменении режима мощности усилителя является пересчёт параметров модели относительно выбранного опорного состояния. В работе [GuoYan_PA_DPD_2015] параметры разделяются на статические и динамические, причём последние переключаются в зависимости от уровня мощности.

Альтернативное направление основано на методах искусственного интеллекта [Dynamic_DPD_CNN]. Так, в [Dynamic_DPD_ANN] нейронная сеть используется для извлечения признаков нелинейности и преобразования параметров обобщённой полиномиальной модели с памятью [dpd_models] под требуемый уровень мощности.

В текущей работе предлагается иной подход, основанный на адаптации многомерной модели, где влияние динамических режимов учитывается посредством введения дополнительных признаков, соответствующих различным состояниям усилителя мощности.

Тем не менее, многомерные модели подвержены проклятию размерности [dpd_models], что влечет за собой экспоненциальный рост ресурсов аппаратной реализации с увеличением числа динамических признаков, учитываемых моделью. В связи с этим в работе предложена модель на основе малорангового разложения многомерной функции. Такой подход позволяет существенно сократить ресурса аппаратной реализации при сохранении высокого уровня компенсации искажений во всем динамическом диапазоне выходной мощности УМ – 11.2 дБ. При этом модель на основе малорангового разложения адаптируется при помощи смешанного метода Ньютона.

Рассматриваемые в работе задачи компенсации искажений в передающем и приёмном трактах преимущественно основаны на адаптации моделей, в более или менее явном виде отражающих физические механизмы формирования нелинейностей [dpd_thesis, pa_models, nn_haykin, adapt_filt_haykin]. Нелинейные элементы радиотракта, в частности усилители мощности, обладают выраженными инерционными свойствами, что обуславливает необходимость учёта эффектов памяти. Для их описания традиционно используются адаптивные фильтры, входящие в состав классических структур, таких как модели Винера и Гаммерштейна.

Кроме того, популярным решением при разработке систем нелинейной обработки сигналов является адаптивная компенсация нелинейных искажений на повышенной частоте дискретизации [resampler_telecom, Wu2024_TimeVsFreq_DPD_MassiveMIMO, Fellmann2025_WLMS_Walsh_DPD_preprint]. Такой подход позволяет избежать эффектов наложения спектральных копий и, в результате, эффективно исполь-

зовать ресурсы нелинейной модели. С другой стороны, аппаратная реализация цифровых передискретизаторов требует дополнительных аппаратных ресурсов, в частности реализации дополнительных цифровых фильтров.

В данной работе предлагаются алгоритмы аппаратной оптимизации цифровых фильтров. Первый подход основан на квантовании коэффициентов, в результате чего часть операций умножения заменяется на операции битового сдвига, что снижает вычислительную сложность реализации.

Второй подход предполагает совместное применение разработанного алгоритма квантования и известного метода Multiple Constant Multiplication (MCM) [Aksoy2010]. На начальном этапе квантование сокращает число аппаратных умножителей, после чего алгоритм MCM формирует вычислительный граф, позволяющий полностью исключить умножители за счёт использования сумматоров и операций сдвига. В совокупности предложенные методы снижают энергопотребления и уменьшают площадь кристалла при реализации цифровых фильтров.

Таким образом, данная работа посвящена адаптивной компенсации нелинейных искажений в приёмном и передающем трактах устройств связи. В рамках исследования предложены эффективные модели и алгоритмы их адаптации. Отдельно рассмотрены методы сокращения ресурсов при аппаратной реализации адаптивных нелинейных корректоров.

Глава I

Методы адаптивной компенсации нелинейных искажений сигнала в приеме-передающих устройствах систем связи

1. Постановка задачи адаптивной компенсации нелинейных искажений в устройствах связи

1.1 Проблема возникновения паразитных помех в приёмном тракте приема-передающего устройства

В данном разделе формулируется задача адаптивной компенсации нелинейных паразитных помех, возникающих на приёмнике приема-передающего устройства. Приводится схема адаптивной компенсации данного рода помех. А также описывается модель формирования паразитных помех на основе качественного представления физических процессов.

В качестве примера возникновения паразитных помех в приёмном тракте рассмотрим приёмно-передающее устройство, состоящее из двух каналов передатчика и приёмника (2T2R), как это показано на рис. 1. При этом передатчик и приёмник разнесены по частоте.

В процессе прохождения сигнала на несущей частоте f_0 через нелинейные цепи передатчика, генерируются компоненты на кратных частотах f_0 , $2f_0$, $3f_0$ и выше. Гармоники порядка выше 3-его, как правило, имеют существенно меньшую мощность по сравнению с гармониками 1-го, 2-го и 3-его порядка.

Среди элементов передающего тракта, представленных на рис. 1, наибольший вклад в формирование нелинейных компонент спектра вносит аналоговый усилитель мощности. В связи с этим будем далее считать, что именно усилитель мощности является источником нелинейности. Согласно стандарту LTE, используемому в системах связи четвёртого поколения 4G, пара передатчик-приёмник может работать на

таких частотах, при которых первая, вторая или третья гармоника сигнала передатчика попадает в полосу приёмного тракта того же устройства [3gpp_36_104]:

- LTE Band 2 (UL 1920–1980 MHz) – LTE Band 2 (DL 1930–1990 MHz)
- LTE Band 8 (UL 880-915 MHz) - LTE Band 3 (DL 1805-1880 MHz)
- LTE Band 17 (UL 704-716 MHz) - LTE Band 4 (DL 2110-2155 MHz)

Кроме того, за счёт малых размеров RF-чипсетов, компоненты внутри чипсета расположены компактно. Вследствие технологических ограничений производства существует сложность обеспечения изоляции отдельных компонентов RF-чипсета. В связи с этим появляются различные пути распространения помехи в приёмнике, как это показано на рис. 1.




Рис. 1. Каналы распространения 1-ой гармоники нелинейных помех в приёмно-передающем устройстве 2T2R

Пример спектра сигнала передатчика на несущей частоте $f_0 = 1.93$ ГГц и помехи, возникающей в приёмнике на несущей частоте передатчика $f_1 = 1.96$ ГГц изображен на рис. 2. Задача модуля компенсации заключается в том, чтобы понизить уровень этой помехи для обеспечения требуемого уровня чувствительности приёмника.

Таким образом, одной из задач данной работы является разработка и исследование модуля адаптивной нелинейной коррекции, который позволит компенсировать




Рис. 2. Спектральная плотность мощности сигнала передатчика на выходе нелинейного УМ на частоте $f_0 = 1.93$ ГГц и полезного сигнала приёмника на частоте $f_1 = 1.96$ ГГц

паразитные помехи в приёмнике. Кроме того, такой подход позволит снизить требования к блокам фильтрации аналогового сигнала: дуплексерам и полосовым фильтрам.

1.2 Схема компенсации паразитных нелинейных помех в приёмном тракте мобильного терминала

Как отмечалось ранее, будем считать, что основным источником нелинейных помех в приёмном тракте является аналоговый усилитель мощности в передающем тракте мобильного терминала [dig_front_end].

Предлагается идентифицировать помехи, попадающих в приёмник путем адаптации нелинейной модели по критерию минимума среднего квадрата ошибки [adapt_filt]. Такая схема компенсации нелинейных помех изображена на рис. 3.

Исходный цифровой сигнал x на несущей частоте f_0 проходит через блок нелинейной модели $f(\cdot)$, в результате чего на её выходе формируется цифровой сигнал $y = f(x)$. Сигнал проходит по передающему тракту: через ЦАП, RF-модуль, аналоговый усилитель мощности, затем вследствие наличие различных путей распространения, паразитные гармоники исходного сигнала на частотах f_0 , $2f_0$, $3f_0$ попадают на приёмную часть.

Проходя по приёмному тракту помеха приобретает вид цифрового сигнала, обозначенного как d . Помимо помехи в приёмную часть терминала поступает полезный




Рис. 3. Схема компенсации нелинейных помех в приёмнике приёмно-передающего устройства

сигнал r . Таким образом, на выходе АЦП – сумма $r + d$.

Блок адаптации АД производит идентификацию, подстраивая коэффициенты z нелинейной модели $f(\cdot)$ посредством измерения отклонения $e = d - y$ принятой приёмным трактом помехи от выхода нелинейной модели. В общем случае можно считать, что коэффициент корреляции отправляемого на передатчике сигнала x и полезного принятого сигнала r равен нулю. Поэтому в результате работы модуля компенсации результирующий сигнал на приёмнике будет стремиться к полезному принятому сигналу $r + e \rightarrow r$. Задачу идентификации паразитной помехи путём адаптации нелинейной модели по критерию минимума среднего квадрата сформулируем следующим образом:

$$\begin{cases} J = e^* e \rightarrow \min_z, \\ e = d - f(x, z) \end{cases} \quad (1.2.1)$$

1.3 Проблема возникновения нелинейных искажений сигнала передающего тракта

Ввиду нелинейности характеристики передающего тракта формируются нелинейные искажения, которые значительно влияют на качество радиочастотных сигналов, создавая помехи в канале связи. Такие нелинейные искажения приводят к увеличению битовой ошибки на приемнике, генерируют внутриполосные и внеполосные помеховые сигналы и ухудшают качество передачи сигналов соседних полос.

Как было отмечено ранее, наибольший вклад в искажения сигнала в передающем тракте вносят нелинейные усилители мощности. В результате прохождения через УМ формируются компоненты спектра внутри полосы передатчика, а также внеполосные искажения. На рис. 4 изображена спектральная плотность мощности сигнала передатчика до и после прохождения через УМ.




Рис. 4. Спектральная плотность мощности сигнала передатчика на входе и выходе усилителя мощности на частоте $f_0 = 1.93$ ГГц

1.4 Схема компенсации нелинейных искажений в передатчике приемо-передающего устройства

Для предотвращения искажений в современных базовых станциях и сотовых устройствах широко используются методы цифровой предискажения DPD [1]-[3].

Устройство DPD представлено блоком с обратной нелинейной характеристикой, изменяющим входной сигнал УМ так, чтобы минимизировать нелинейных искажений на выходе УМ (рис. 5).

Таким образом, DPD предискажает входной сигнал УМ таким образом, чтобы




Рис. 5. Структура системы цифрового предискажения

на выходе сформировался линейно искаженный сигнал. Такой подход позволяет работать в режимах высокой нелинейности УМ и, в результате, повысить КПД УМ. Задача оптимизации цифрового предискажения может быть представлена математическим выражением [4], описывающим минимизацию отклонения входа DPD от выхода УМ:

$$\|g(x - f(x, z)) - x\|_2^2 \rightarrow \min_z, \quad (1.4.1)$$

где x – входной сигнала УМ, $g(\cdot)$ – нелинейная характеристика УМ, $f(\cdot)$ – модель цифрового предискажения с адаптивными параметрами z . Предположим, что нелинейную характеристику УМ $g(x)$ можно аппроксимировать линейной функцией в окрестности рабочей точки:

$$g(x - f(x, z)) \approx g(x) - g'_x(x)f(x, z), \quad (1.4.2)$$

где $g'_x(x)$ – производная нелинейной функции УМ по входу. Поскольку DPD должен работать в таком режиме УМ, чтобы уровень нелинейных искажений оставался значительно ниже уровня передаваемого сигнала, то $g'_x(x) \approx I$ – будет представлять собой единичную матрицу. Подставляя (1.4.2) в (1.4.1), получаем выражение:

$$\|f(x, z) - e\|_2^2 \rightarrow \min_z, \quad (1.4.3)$$

где $e = g(x) - x$ – вектор ошибки.

1.5 Критерии компенсации нелинейных искажений в устройствах связи

Существует несколько способов обработки сигнала [adapt_filt_haykin]. Симуляция алгоритмов как правило проводится на сохраненных блоках данных. В этом случае имеется мощный вычислитель (компьютер) и возможность вести математическую обработку матриц и других объектов алгоритмов. Это блочный режим работы.

При аппаратной реализации блочный режим стараются заменить стохастическим в реальном времени [adapt_filt_haykin], чтобы минимизировать задержки и сократить ресурсы. В этом случае векторы состояния, корреляционные матрицы, шаг алгоритма, а также другие объекты, обновляются каждый отсчет.

При рассмотрении методов компенсации паразитных помех будем считать, что на вход блока адаптации поступает вектор комплексных отсчетов передатчика $\mathbf{x} \in \mathbb{C}^{N \times 1}$ длины N , вектор отсчетов с приёмника $\mathbf{d} \in \mathbb{C}^{N \times 1}$ также длины N .

Задача блока адаптации заключается в том, чтобы так преобразовать исходный вектор $\mathbf{x}$, чтобы как можно лучше приблизить к вектору отсчетов на приёмнике $\mathbf{d}$ путём минимизации нормы вектора ошибки $\mathbf{e} = \mathbf{d} - f(\mathbf{x}, \mathbf{z}) \in \mathbb{C}^{N \times 1}$, где $f(\cdot)$ – оператор преобразования исходного вектора в вектор отсчетов на выходе модели помехи. Оператор $f(\cdot)$ определяется коэффициентами $\mathbf{z} \in \mathbb{C}^{K \times 1}$, K – число адаптивных

параметров модели.

Рассмотрим требования к целевой функции (метрике) алгоритмов компенсации. Метрика величины отклонения выхода модели помехи от вектора отсчетов самой помехи должна быть вещественнозначной и неотрицательной для реализации процедуры поиска минимума данной метрики. Кроме того, желательно задать целевую функцию квадратичной и выпуклой для применения эффективных методов адаптации [**convex_opt**].

Такой вещественной, неотрицательной и квадратичной метрикой является средний квадрат ошибки (MSE - Mean Square Error). Физический смысл среднего квадрата ошибки – энергия отклонения выхода нелинейной модели от помехи, измеренной на приёмнике. При блочной обработке сигнала MSE имеет вид:

$$J = ||\mathbf{e}||_2^2 = \mathbf{e}^H \mathbf{e}. \quad (1.5.1)$$

Помимо MSE на практике применяется метрика - нормированный средний квадрат ошибки (NMSE - Normalized Mean Square Error):

$$J = \frac{||\mathbf{e}||_2^2}{||\mathbf{d}||_2^2} = \frac{\mathbf{e}^H \mathbf{e}}{\mathbf{d}^H \mathbf{d}}. \quad (1.5.2)$$

В данном случае энергия ошибки нормируется к энергии сигнала приёмника для того чтобы оценить уровень ошибки независимо от динамического диапазона сигнала на входе приемника.

Реальные сигналы, используемые в системах связи [**sklyar_dig_telecom**] являются мощностными, то есть обладают бесконечной энергией на бесконечном промежутке времени, однако в уравнениях (1.5.1), (1.5.2) фигурирует энергия ошибки и сигнала помехи, рассчитанная на конечной длине блока.

Отметим, что в задаче цифрового-предыскажения, описанной в разделе 1.3 важнейшим критерием качества компенсации внеполосных искажений является коэффициент утечки в соседнем канале ACLR (Adjacent Channel Leakage Ratio), который представляет собой отношение энергии нелинейных искажений в соседнем канале к энергии сигнала в канале передатчика и вычисляется следующим образом:

$$L = \frac{||\text{conv}_{\mathbf{w}_b}(\mathbf{x} + \mathbf{e})||_2^2}{||\text{conv}_{\mathbf{w}_o}(\mathbf{x} + \mathbf{e})||_2^2}, \quad (1.5.3)$$

где $\mathbf{x} + \mathbf{e}$ – представляет собой сигнал на выходе УМ после компенсации нелинейных искажений, $\text{conv}(\cdot)$ – оператор свертки, $\mathbf{w}_b$ – коэффициенты фильтра нижних частот, настроенного на полосу сигнала передатчика, $\mathbf{w}_o$ – коэффициенты полосового фильтра, настроенного на полосу соседнего канала связи. Частотный разнос между каналом передатчика и соседним каналом связи определяется в соответствие со стандартом [**3gpp_36_804**].

Таким образом, общепринятым критерием оптимизации в задачах компенсации

нелинейных искажений (1.2.1), (1.4.3) является энергия ошибки алгоритма адаптации (1.5.1). При этом ACLR (1.5.3) и NMSE (1.5.2) используются для оценки качества работы адаптивной модели и алгоритма обучения в задаче цифрового предсказания в передатчике и задачи компенсации нелинейных помех в приёмнике соответственно.

2. Методы первого порядка для адаптации моделей нелинейных искажений

Методы первого порядка [**polyak_optimiz**] занимают центральное место в задачах адаптации нелинейных моделей, применяемых для компенсации искажений в трактах телекоммуникационных устройств. Их ключевое преимущество заключается в низкой вычислительной сложности и хорошей масштабируемости, что делает их особенно привлекательными для аппаратной реализации в системах с ограниченными ресурсами.

В отличие от более сложных второпорядковых алгоритмов, методы первого порядка — такие как стохастический градиентный спуск и его модификации — опираются лишь на локальную информацию о градиенте функции ошибки, обеспечивая устойчивую и быструю адаптацию даже при неполном знании статистики сигнала. Благодаря этому они хорошо подходят для работы в реальном времени и могут эффективно функционировать при изменяющихся условиях канала или параметров нелинейности.

Кроме того, градиентные методы допускают реализацию в фиксированной точке, что позволяет использовать простые арифметические блоки и снижает энергопотребление. Такая особенность делает их оптимальным выбором для встроенных и энергоэффективных систем, где важно обеспечить баланс между скоростью сходимости и аппаратной сложностью. В контексте нелинейной компенсации это обеспечивает возможность динамического обновления коэффициентов модели с минимальными затратами ресурсов при сохранении высокой точности восстановления сигнала.

2.1 Метод градиентного спуска

Градиентный спуск для случая нелинейной модели с вещественными параметрами представляет собой следующий итеративный алгоритм:

$$z_{k+1} = z_k - \mu(D_{z_k}J(z_k))^T, z_k \in \mathbb{R}^{K \times 1}, \quad (2.1.1)$$

$$\left\| D_{z^*}J(z_k) - D_{z^*}J(z_{k+1}) \right\|_2 < L \left\| D_{z^*}J(z_k) - D_{z^*}J(z_{k+1}) \right\|_2, \quad \mu \leq L, \quad (2.1.2)$$

где $D_z J \in \mathbb{R}^{1 \times K}$ — оператор вычисления производной функции J по адаптивным параметрам z . Условие Липшица [**polyak_optimiz**] задаёт ограничение на скорость

поиска минимума целевой функции. Для ускорения алгоритма достаточно увеличить шаг μ , однако при слишком больших μ - алгоритм расходится. Критическое значение, при котором наступает стагнация алгоритма – $\mu_{\text{кр}} = \frac{L}{2}$.

Ввиду того, что в устройствах связи работают с комплекснозначными сигналами, параметры моделей нелинейной обработки сигналов также выбирают комплекснозначными. Направление возрастания вещественной функции комплексного переменного определяется производной вещественной функции по комплексно-сопряженным параметрам [wirt_deriv_book]. В связи с этим, метод градиентного спуска для моделей с комплексными параметрами строится следующим образом:

$$\mathbf{z}_{k+1} = \mathbf{z}_k - \mu(D_{\mathbf{z}_k^*}J(\mathbf{z}_k))^T, \mathbf{z}_k \in \mathbb{C}^{K \times 1}, \quad (2.1.3)$$

где $D_{\mathbf{z}_k^*}J \in \mathbb{C}^{1 \times K}$ – оператор вычисления производной вещественной функции J по адаптивным комплексно-сопряженным параметрам $\mathbf{z}^*$.

Получим разностное уравнение метода градиентного спуска оптимизации вещественной скалярной функции потерь, зависящей от комплексных векторов параметров. Для этого разложим функцию потерь J в окрестности нуля в ряд Тейлора до членов первого порядка малости:

$$dJ = D_{\mathbf{z}}Jd\mathbf{z} + D_{\mathbf{z}^*}Jd\mathbf{z}^* \in \mathbb{R}, \quad (2.1.4)$$

где $D_{\mathbf{z}}J \in \mathbb{C}^{1 \times K}$, $D_{\mathbf{z}^*}J \in \mathbb{C}^{1 \times K}$, $d\mathbf{z} \in \mathbb{C}^{K \times 1}$, $d\mathbf{z}^* \in \mathbb{C}^{K \times 1}$. Разложим выход нелинейной модели в Ряд Тейлора в окрестности нуля до членов первого порядка малости [wirt_deriv_book]:

$$d\mathbf{y} = D_{\mathbf{z}}\mathbf{y}d\mathbf{z} + D_{\mathbf{z}^*}\mathbf{y}d\mathbf{z}^* \in \mathbb{C}^{N \times 1}, \quad (2.1.5)$$

где $D_{\mathbf{z}}\mathbf{y}$, $D_{\mathbf{z}^*}\mathbf{y} \in \mathbb{C}^{N \times K}$ – матрицы Якоби, производные выхода модели по прямым и комплексно-сопряженным параметрам модели.

Распишем дифференциал среднего квадрата ошибки, введенного в (1.5.1) и подставим разложение выхода нелинейной модели $\mathbf{y}$ до членов первого порядка малости (2.1.5):

$$\begin{aligned} dJ &= d(e^H e) = de^H e + e^H de = -e^T d\mathbf{y}^* - e^H d\mathbf{y} = \\ &= -e^T D_{\mathbf{z}}\mathbf{y}^* d\mathbf{z} - e^T D_{\mathbf{z}^*}\mathbf{y}^* d\mathbf{z}^* - e^H D_{\mathbf{z}}\mathbf{y} d\mathbf{z} - e^H D_{\mathbf{z}^*}\mathbf{y} d\mathbf{z}^* = \\ &= (-e^T D_{\mathbf{z}}\mathbf{y}^* - e^H D_{\mathbf{z}}\mathbf{y})d\mathbf{z} + (-e^T D_{\mathbf{z}^*}\mathbf{y}^* - e^H D_{\mathbf{z}^*}\mathbf{y})d\mathbf{z}^*. \end{aligned} \quad (2.1.6)$$

Сравнивая выражения перед дифференциалом $\mathbf{z}^*$ в (2.1.4) и (2.1.6), получаем выражение производной функции потерь по комплексно-сопряженным параметрам $\mathbf{z}^*$:

$$(D_{\mathbf{z}^*}J)^T = (-e^T D_{\mathbf{z}^*}\mathbf{y}^* - e^H D_{\mathbf{z}^*}\mathbf{y})^T = -(D_{\mathbf{z}}\mathbf{y})^H e - (D_{\mathbf{z}^*}\mathbf{y})^T e^* \in \mathbb{C}^{K \times 1}. \quad (2.1.7)$$

Таким образом, подставляя (2.1.7) в (2.1.3) получаем разностное уравнение градиентного спуска для функции потерь MSE с вектором ошибки общего вида, то есть зависящим от прямых и сопряженных параметров $\mathbf{e} = \mathbf{e}(\mathbf{x}, \mathbf{z}, \mathbf{z}^*)$:

$$\mathbf{z}_{k+1} = \mathbf{z}_k + \mu(D_{\mathbf{z}}\mathbf{y})^H \mathbf{e} + \mu(D_{\mathbf{z}^*}\mathbf{y})^T \mathbf{e}^* \in \mathbb{C}^{K \times 1} \quad (2.1.8)$$

Пусть вектор отклонения выхода модели от значений помехи $\mathbf{e}(\mathbf{x}, \mathbf{z}) \in \mathbb{C}^{N \times 1}$ — голоморфная функция относительно $\mathbf{z}$, то есть не зависит от вектора комплексно-сопряженных параметров $\mathbf{z}^*$. В этом случае Якобиан выхода модели от сопряженных параметров равен нулю:

$$D_{\mathbf{z}^*}\mathbf{y} = \mathbf{0}. \quad (2.1.9)$$

Тогда из (2.1.8) разностное уравнение метода градиентного спуска может быть представлено как:

$$\mathbf{z}_{k+1} = \mathbf{z}_k + \mu(D_{\mathbf{z}}\mathbf{y})^H \mathbf{e}. \quad (2.1.10)$$

В нелинейной адаптивной обработке сигналов условие (2.1.9) используется при построении нелинейных моделей, поскольку в этом случае снижается вычислительная сложность пересчета параметров адаптивных моделей, снижается требования по памяти, энергопотребление, а также занимаемая площадь на кристалле.

Заметим, что в случае вещественно модели $\mathbf{y} \in \mathbb{R}^{N \times 1}$ с вещественными параметрами $\mathbf{z} \in \mathbb{R}^{K \times 1}$ разностное уравнение градиентного спуска (2.1.8) будет иметь вид:

$$\mathbf{z}_{k+1} = \mathbf{z}_k + \mu 2(D_{\mathbf{z}}\mathbf{y})^T \mathbf{e} = \mathbf{z}_k + \tilde{\mu}(D_{\mathbf{z}}\mathbf{y})^T \mathbf{e} \in \mathbb{R}^{K \times 1}, \quad (2.1.11)$$

где множитель 2 появляется ввиду того, что в выражении (2.1.8) $\mathbf{y} = \mathbf{y}^* \in \mathbb{R}^{N \times 1}$, $\mathbf{e} = \mathbf{e}^* \in \mathbb{R}^{N \times 1}$, $\mathbf{z} = \mathbf{z}^* \in \mathbb{R}^{K \times 1}$.

Заметим, что вопреки схожести разностных уравнений градиентного спуска (2.1.10) и (2.1.11) для параметров комплексной модели с голоморфной ошибкой адаптации и параметров вещественной модели с вещественными параметрами соответственно, модель с вещественными параметрами не является голоморфной ввиду того, что вещественные параметры могут быть представлены как взвешенная сумма прямых и сопряженных параметров модели:

$$\mathbf{z} = \frac{\mathbf{z} + j\mathbf{z} + \mathbf{z} - j\mathbf{z}}{2} = \frac{\hat{\mathbf{z}} + \hat{\mathbf{z}}^*}{2}. \quad (2.1.12)$$

В связи с этим условие голоморфности (2.1.9) не выполняется.

Вычислительная сложность подсчета градиента и матрицы Гёссе оцениваются согласно (2.1.10), (2.1.11), (2.1.8) как $\mathcal{O}(KN)$ комплексных и вещественных операций соответственно:

$$\chi_{grad} = \mathcal{O}(KN). \quad (2.1.13)$$

2.2 Модификации метода градиентного спуска

Классический метод градиентного спуска (2.1.3) является эффективным в случае с гладкими выпуклыми функциями потерь, однако в случае сильно искривлённого ландшафта или шумных градиентов он может сходиться медленно. Для ускорения сходимости и сглаживания колебаний используется метод тяжёлого шара (momentum), предложенный Поляком [polyak1964]. Основная идея заключается во введении вектора скорости, аккумулирующего информацию о предыдущих шагах:

$$\begin{cases} \mathbf{m}_{k+1} = \beta \mathbf{m}_k + \mu (D_{\mathbf{z}^*} J(\mathbf{z}_k))^T, \\ \mathbf{z}_{k+1} = \mathbf{z}_k - \mathbf{m}_{k+1}, \end{cases} \quad (2.2.1)$$

где $0 \leq \beta < 1$ — коэффициент инерции. Такой подход позволяет снизить осцилляции и ускорить движение вдоль пологих направлений, однако градиент вычисляется в текущей точке, что может приводить к избыточным колебаниям.

Для устранения этого недостатка была предложена модификация Нестерова, известная как *ускоренный градиент Нестерова* [nesterov1983method] (Nesterov accelerated gradient, NAG). В этом подходе градиент вычисляется в «прогнозируемом» положении, что стабилизирует алгоритм адаптации:

$$\begin{cases} \mathbf{m}_{k+1} = \beta \mathbf{m}_k + \mu (D_{\mathbf{z}^*} J(\mathbf{z}_k - \beta \mathbf{v}_k))^T, \\ \mathbf{z}_{k+1} = \mathbf{z}_k - \mathbf{m}_{k+1}. \end{cases} \quad (2.2.2)$$

Таким образом, данный метод корректирует направление движения до обновления параметров, что обеспечивает более устойчивую и быструю сходимость для выпуклых задач.

Дальнейшее развитие концепции инерционного градиентного спуска привело к созданию алгоритма *Adam* (Adaptive Moment Estimation) [kingma2014adam], который сочетает механизмы накопления импульса градиента и адаптивной нормализации шага по каждой координате параметров. В отличие от классических схем с фиксированной скоростью обучения, Adam автоматически масштабирует величину шага в зависимости от первой и второй статистических моментов градиента, что обеспечивает баланс между скоростью сходимости и устойчивостью обновлений. Такая адаптивность позволяет алгоритму поддерживать высокую скорость обучения на ранних этапах и эффективно выходить из окрестностей локальных минимумов, что делает его одним из наиболее универсальных и применимых методов стохастической оптимизации:

$$\begin{cases} \mathbf{m}_{k+1} = \beta_1 \mathbf{m}_k + (1 - \beta_1) (D_{\mathbf{z}^*} J(\mathbf{z}_k))^T, \\ \mathbf{v}_{k+1} = \beta_2 \mathbf{v}_k + (1 - \beta_2) |(D_{\mathbf{z}^*} J(\mathbf{z}_k))^T|^2, \\ \hat{\mathbf{m}}_{k+1} = \frac{\mathbf{m}_{k+1}}{1 - \beta_1^{k+1}}, \quad \hat{\mathbf{v}}_{k+1} = \frac{\mathbf{v}_{k+1}}{1 - \beta_2^{k+1}}, \\ \mathbf{z}_{k+1} = \mathbf{z}_k - \mu \frac{\hat{\mathbf{m}}_{k+1}}{\sqrt{\hat{\mathbf{v}}_{k+1}} + \varepsilon}, \end{cases} \quad (2.2.3)$$

где $\beta_1 \approx 0.9$, $\beta_2 \approx 0.999$, $\varepsilon \approx 10^{-8}$. Adam объединяет преимущества момента (инерция) и адаптивных методов (нормализация шага по координатам), что обеспечивает стабильную сходимость даже при шумных или нестационарных градиентах.

Эволюция этих подходов отражает постепенное улучшение базового метода: от простого градиентного шага (2.1.3) к инерционному ускорению (2.2.1), затем к прогнозирующему ускорению Нестерова (2.2.2), и, наконец, к адаптивно-инерционной схеме (2.2.3).

3. Методы второго порядка для адаптации моделей нелинейных искажений

3.1 Метод Ньютона

Несмотря на широкое распространение и простоту реализации методов первого порядка, их эффективность существенно снижается в задачах с жёсткими (плохо обусловленными) функциями, где направление антиградиента может существенно отличаться от направления наискорейшего убывания. Для ускорения сходимости и более точного учёта локальной геометрии целевой функции применяются методы второго порядка, использующие информацию не только о градиенте, но и о кривизне поверхности уровня.

Классическим представителем данного класса является *метод Ньютона*, основанный на аппроксимации функции её локальным квадратичным разложением в окрестности текущей точки. Основная идея заключается в том, что, если функция $J(\mathbf{z}, \mathbf{z}^*)$ близка к квадратичной, то минимум аппроксимации можно найти аналитически, что обеспечивает сверхлинейную сходимость. В отличие от методов первого порядка, метод Ньютона использует матрицу Гессе (матрицу вторых производных) для корректировки направления поиска, что позволяет автоматически масштабировать шаги в зависимости от локальной кривизны поверхности.

Таким образом, метод Ньютона интерпретируется как переход от *направлений убывания* к *направлениям оптимального спуска*, обеспечивающим более точное приближение минимума.

Для формального описания метода Ньютона введем следующие обозначения. Для удобства записи алгоритма метода Ньютона введем вектор комплексных и веществен-

ных параметров удвоенной длины, включающий вектор прямых и сопряженных параметров:

$$\mathbf{c} = \begin{pmatrix} \mathbf{z}^T & \mathbf{z}^{*T} \end{pmatrix}^T \in \mathbb{C}^{2K \times 1}, \quad \mathbf{r} = \begin{pmatrix} \mathbf{x}^T & \mathbf{y}^T \end{pmatrix}^T \in \mathbb{R}^{2K \times 1}, \quad (3.1.1)$$

$$\mathbf{z} = \mathbf{x} + j\mathbf{y} \in \mathbb{C}^{K \times 1}, \quad \mathbf{z}^* = \mathbf{x} - j\mathbf{y} \in \mathbb{C}^{K \times 1}. \quad (3.1.2)$$

Полная матрица вторых роизводных скалярной вещественной функции J по вектору комплексных параметров удвоенной длины $\mathbf{c}$ описывается следующим образом `[complex_deriv]`:

$$H_{\mathbf{c},\mathbf{c}}J = D_{\mathbf{c}}(D_{\mathbf{c}}J)^T = \begin{pmatrix} H_{\mathbf{z},\mathbf{z}}J & H_{\mathbf{z}^*,\mathbf{z}}J \\ H_{\mathbf{z},\mathbf{z}^*}J & H_{\mathbf{z}^*,\mathbf{z}^*}J \end{pmatrix} \in \mathbb{C}^{2K \times 2K}. \quad (3.1.3)$$

При этом матрица вторых производных функции потерь J по вещественным параметрам может быть раписана как:

$$H_{\mathbf{r},\mathbf{r}}J = D_{\mathbf{r}}(D_{\mathbf{r}}J)^T = \begin{pmatrix} H_{\mathbf{x},\mathbf{x}}J & H_{\mathbf{x},\mathbf{y}}J \\ H_{\mathbf{y},\mathbf{x}}J & H_{\mathbf{y},\mathbf{y}}J \end{pmatrix} \in \mathbb{R}^{2K \times 2K}. \quad (3.1.4)$$

Заметим, что матрицы Гессе (3.1.3), (3.1.4) соотносятся как:

$$H_{\mathbf{r},\mathbf{r}} = \mathbf{T}^H H_{\mathbf{c},\mathbf{c}} J \mathbf{T}^* \rightarrow H_{\mathbf{c},\mathbf{c}} = \frac{1}{4} \mathbf{T} H_{\mathbf{r},\mathbf{r}} J \mathbf{T}^T, \quad \text{где} \quad (3.1.5)$$

$$\mathbf{T} = \begin{pmatrix} \mathbf{I}_K & -j\mathbf{I}_K \\ \mathbf{I}_K & j\mathbf{I}_K \end{pmatrix}. \quad (3.1.6)$$

Рассмотрим разложение в ряд Тейлора вещественной функции потерь J комплексного переменного $\mathbf{z} = \mathbf{x} + j\mathbf{y}$ как функции вещественного вектора удвоенной длины $\mathbf{r}^T = \begin{pmatrix} \mathbf{x}^T & \mathbf{y}^T \end{pmatrix}^T$ в окрестности вещественной точки $\mathbf{r}$:

$$M_{\mathbf{r}}^2(\Delta_{\mathbf{r}}) = J(\mathbf{r}) + (D_{\mathbf{r}}J)\Delta_{\mathbf{r}} + \frac{1}{2}\Delta_{\mathbf{r}}^T H_{\mathbf{r},\mathbf{r}} \Delta_{\mathbf{r}} \in \mathbb{R}, \quad \Delta_{\mathbf{r}} = \mathbf{r}_1 - \mathbf{r} \in \mathbb{R}^{2K \times 1}. \quad (3.1.7)$$

Из выражений для комплексного и вещественного векторов параметров (3.1.2), а также (3.1.6) следует преобразование векторов параметров:

$$\mathbf{c} = \mathbf{T}^* \mathbf{r} \rightarrow \Delta_{\mathbf{c}} = \mathbf{T}^* \Delta_{\mathbf{r}} \quad \Delta_{\mathbf{c}} = \mathbf{c}_1 - \mathbf{c} \in \mathbb{C}^{2K \times 1}. \quad (3.1.8)$$

Кроме того, из выражений (3.1.2), а также определений производных Виртинге-ра `[complex_deriv]` следует правило преобразования градиентов:

$$(D_{\mathbf{r}}J)^T = \mathbf{T}^H (D_{\mathbf{c}}J)^T \quad (3.1.9)$$

Подставляем выражения (3.1.8), (3.1.9), (3.1.6) в (3.1.7) и получаем разложение ф-

ции J в окрестности комплексной точки $\mathbf{c}$;

$$\begin{aligned} M_{\mathbf{r}}^2(\Delta_{\mathbf{r}}) &= M_{\mathbf{c}}^2(\Delta_{\mathbf{c}}) = J(\mathbf{c}) + (D_{\mathbf{c}}J)(\mathbf{T}\Delta_{\mathbf{r}})^* + \frac{1}{2}(\mathbf{T}\Delta_{\mathbf{r}})^H H_{\mathbf{c},\mathbf{c}} J(\mathbf{T}\Delta_{\mathbf{r}})^* = \\ &= J(\mathbf{c}) + (D_{\mathbf{c}}J)\Delta_{\mathbf{c}} + \frac{1}{2}(\Delta_{\mathbf{c}})^T H_{\mathbf{c},\mathbf{c}} J(\Delta_{\mathbf{c}}) \end{aligned} \quad (3.1.10)$$

Продифференцируем (3.1.10) по приращению $\Delta_{\mathbf{c}}$:

$$\begin{aligned} dM_{\mathbf{c}}^2(\Delta_{\mathbf{c}}) &= (D_{\mathbf{c}}J)d\Delta_{\mathbf{c}} + \frac{1}{2}(d\Delta_{\mathbf{c}})^T H_{\mathbf{c},\mathbf{c}} J(\Delta_{\mathbf{c}}) + \frac{1}{2}(\Delta_{\mathbf{c}})^T H_{\mathbf{c},\mathbf{c}} J(d\Delta_{\mathbf{c}}) = \\ &= (D_{\mathbf{c}}J)d\Delta_{\mathbf{c}} + (\Delta_{\mathbf{c}})^T H_{\mathbf{c},\mathbf{c}} J(d\Delta_{\mathbf{c}}) = (D_{\mathbf{c}}J + (\Delta_{\mathbf{c}})^T H_{\mathbf{c},\mathbf{c}} J)d\Delta_{\mathbf{c}}. \end{aligned} \quad (3.1.11)$$

Из (3.1.11) следует выражение для производной мажоранты $M_{\mathbf{c}}^2(\Delta_{\mathbf{c}})$ по приращению $\Delta_{\mathbf{c}}$. Приравняем производную к нулю для поиска шага метода Ньютона:

$$D_{\Delta_{\mathbf{c}}}M_{\mathbf{c}}^2(\Delta_{\mathbf{c}}) = (D_{\mathbf{c}}J)^T + H_{\mathbf{c},\mathbf{c}}J\Delta_{\mathbf{c}} = 0 \Rightarrow \Delta_{\mathbf{c}} = (H_{\mathbf{c},\mathbf{c}}J)^{-1}(D_{\mathbf{c}}J)^T \quad (3.1.12)$$

Найдем эквивалентную форму шага метода Ньютона из выражения (3.1.12). Применим операцию комплексного сопряжения к обеим частям уравнения (3.1.12):

$$\begin{aligned} M_{\mathbf{c}^*}^2(\Delta_{\mathbf{c}^*}) &= (D_{\mathbf{c}^*}J)^T + H_{\mathbf{c}^*,\mathbf{c}^*}J\Delta_{\mathbf{c}^*} = 0 \Leftrightarrow \\ &\Leftrightarrow (D_{\mathbf{c}^*}J)^T + H_{\mathbf{c}^*,\mathbf{c}^*}JS\Delta_{\mathbf{c}} = 0 \Leftrightarrow \\ &\Leftrightarrow (D_{\mathbf{c}^*}J)^T + H_{\mathbf{c},\mathbf{c}^*}J\Delta_{\mathbf{c}} = 0 \Rightarrow \Delta_{\mathbf{c}} = (H_{\mathbf{c},\mathbf{c}^*}J)^{-1}(D_{\mathbf{c}^*}J)^T. \end{aligned} \quad (3.1.13)$$

В преобразованиях (3.1.13) использовалось свойство матрицы замены $\mathbf{S} \in \mathbb{C}^{2K \times 2K}$ такой, что:

$$\Delta_{\mathbf{c}^*} = \mathbf{S}\Delta_{\mathbf{c}}, \quad \mathbf{S} = \begin{pmatrix} \mathbf{0} & \mathbf{I}_K \\ \mathbf{I}_K & \mathbf{0} \end{pmatrix}. \quad (3.1.14)$$

При этом произведение гессиана на матрицу замены преобразовано как

$$\begin{aligned} H_{\mathbf{c}^*,\mathbf{c}^*}JS &= D_{\mathbf{c}^*}(D_{\mathbf{c}^*}J)^T \mathbf{S} = \begin{pmatrix} D_{\mathbf{z}^*} & D_{\mathbf{z}} \end{pmatrix} \begin{pmatrix} (D_{\mathbf{z}^*}J)^T \\ (D_{\mathbf{z}}J)^T \end{pmatrix} \mathbf{S} = \\ &= \begin{pmatrix} D_{\mathbf{z}^*}(D_{\mathbf{z}^*}J)^T & D_{\mathbf{z}}(D_{\mathbf{z}^*}J)^T \\ D_{\mathbf{z}^*}(D_{\mathbf{z}}J)^T & D_{\mathbf{z}}(D_{\mathbf{z}}J)^T \end{pmatrix} \begin{pmatrix} \mathbf{0} & \mathbf{I}_K \\ \mathbf{I}_K & \mathbf{0} \end{pmatrix} = \\ &= \begin{pmatrix} D_{\mathbf{z}}(D_{\mathbf{z}^*}J)^T & D_{\mathbf{z}^*}(D_{\mathbf{z}^*}J)^T \\ D_{\mathbf{z}}(D_{\mathbf{z}}J)^T & D_{\mathbf{z}^*}(D_{\mathbf{z}}J)^T \end{pmatrix} = \begin{pmatrix} D_{\mathbf{z}} & D_{\mathbf{z}^*} \end{pmatrix} \begin{pmatrix} (D_{\mathbf{z}^*}J)^T \\ (D_{\mathbf{z}}J)^T \end{pmatrix} = \\ &= D_{\mathbf{c}}(D_{\mathbf{c}^*}J)^T = H_{\mathbf{c},\mathbf{c}^*}J \end{aligned} \quad (3.1.15)$$

Из выражений (3.1.12), (3.1.13) получаем две эквивалентных формы разностного

уравнения метода Ньютона:

$$\mathbf{c}_{k+1} = \mathbf{c}_k - \mu(H_{\mathbf{c},\mathbf{c}}J)^{-1}(D_{\mathbf{c}}J)^T \quad (3.1.16)$$

$$\mathbf{c}_{k+1} = \mathbf{c}_k - \mu(H_{\mathbf{c},\mathbf{c}^*}J)^{-1}(D_{\mathbf{c}^*}J)^T \quad (3.1.17)$$

Получим разностное уравнение метода Ньютона для функции потерь MSE (1.5.1). Градиент функции потерь по вектору параметров удвоенной длины может быть получен из выражения (2.1.7):

$$(D_{\mathbf{c}^*}J)^T = \begin{pmatrix} D_{\mathbf{z}^*}J & D_{\mathbf{z}}J \end{pmatrix}^T = \begin{pmatrix} D_{\mathbf{z}^*}J & (D_{\mathbf{z}^*}J)^* \end{pmatrix}^T, \quad (3.1.18)$$

где использовано свойство $(D_{\mathbf{z}^*}J)^* = D_{\mathbf{z}}J^* = D_{\mathbf{z}}J$ ввиду вещественности функции потерь $J \in \mathbb{R}$.

Заметим также, что ввиду определения матрицы Гёссе (3.1.3), достаточно найти две из четырех составляющих матрицы (3.1.17):

$$H_{\mathbf{z}^*,\mathbf{z}}J = D_{\mathbf{z}^*}(D_{\mathbf{z}}J)^T = (D_{\mathbf{z}}(D_{\mathbf{z}^*}J)^T)^* = (H_{\mathbf{z},\mathbf{z}^*}J)^*, \quad (3.1.19)$$

$$H_{\mathbf{z},\mathbf{z}}J = D_{\mathbf{z}}(D_{\mathbf{z}}J)^T = (D_{\mathbf{z}^*}(D_{\mathbf{z}^*}J)^T)^* = (H_{\mathbf{z}^*,\mathbf{z}^*}J)^* \quad (3.1.20)$$

Найдем теперь матрицы Гессе для MSE из выражения (2.1.7):

$$d(D_{\mathbf{z}^*}J)^T = -d \left[(D_{\mathbf{z}}\mathbf{y})^H \mathbf{e} \right] - d \left[(D_{\mathbf{z}^*}\mathbf{y})^T \mathbf{e}^* \right]. \quad (3.1.21)$$

Найдем первое слагаемое выражения (3.1.21):

$$\begin{aligned} d \left[(D_{\mathbf{z}}\mathbf{y})^H \mathbf{e} \right] &= d \left[\mathbf{I}_K (D_{\mathbf{z}}\mathbf{y})^H \mathbf{e} \right] = d \left[(\mathbf{e}^T \otimes \mathbf{I}_K) \text{vec}(D_{\mathbf{z}}\mathbf{y})^H \right] = \\ &= (-d\mathbf{y}^T \otimes \mathbf{I}_K) \text{vec}(D_{\mathbf{z}}\mathbf{y})^H + (\mathbf{e}^T \otimes \mathbf{I}_K) d\text{vec}(D_{\mathbf{z}}\mathbf{y})^H = \\ &= -(D_{\mathbf{z}}\mathbf{y})^H d\mathbf{y} + (\mathbf{e}^T \otimes \mathbf{I}_K) d\text{vec}(D_{\mathbf{z}}\mathbf{y})^H, \end{aligned} \quad (3.1.22)$$

где $\mathbf{I}_K \in \mathbb{R}^{K \times K}$ – единичная матрица, $\otimes$ – произведение Кронекера, $\text{vec}(\cdot)$ – оператор векторизации матрицы, вытягивает матрицу в единый столбец. Отметим, что в выкладках (3.1.22) использовано свойство $\text{vec}(ABC) = (C^T \otimes A) \text{vec}(B)$ [wirt_deriv_book].

В выражении (3.1.22) разложим вектор в ряд Тейлора до слагаемых первого порядка малости:

$$d\text{vec}(D_{\mathbf{z}}\mathbf{y})^H = D_{\mathbf{z}}\text{vec}(D_{\mathbf{z}}\mathbf{y})^H dz + D_{\mathbf{z}^*}\text{vec}(D_{\mathbf{z}^*}\mathbf{y})^H dz^*. \quad (3.1.23)$$

Подставим (2.1.5), (3.1.23) в (3.1.22):

$$\begin{aligned} d \left[(D_{\mathbf{z}}\mathbf{y})^H \mathbf{e} \right] &= -(D_{\mathbf{z}}\mathbf{y})^H (D_{\mathbf{z}}\mathbf{y}) dz - (D_{\mathbf{z}}\mathbf{y})^H (D_{\mathbf{z}^*}\mathbf{y}) dz^* + \\ &+ (\mathbf{e}^T \otimes \mathbf{I}_K) D_{\mathbf{z}}\text{vec}(D_{\mathbf{z}}\mathbf{y})^H dz + (\mathbf{e}^T \otimes \mathbf{I}_K) D_{\mathbf{z}^*}\text{vec}(D_{\mathbf{z}}\mathbf{y})^H dz^*. \end{aligned} \quad (3.1.24)$$

По аналогии с (3.1.24) получаем выражение для второго слагаемого дифференциала градиента функции потерь MSE:

$$d \left[(D_{\mathbf{z}^*} \mathbf{y})^T \mathbf{e}^* \right] = -(D_{\mathbf{z}^*} \mathbf{y})^T (D_{\mathbf{z}^*} \mathbf{y}^*) d\mathbf{z}^* - (D_{\mathbf{z}^*} \mathbf{y})^T (D_{\mathbf{z}} \mathbf{y}^*) d\mathbf{z} + \\ + (\mathbf{e}^H \otimes \mathbf{I}_K) D_{\mathbf{z}} \text{vec}(D_{\mathbf{z}^*} \mathbf{y})^T d\mathbf{z} + (\mathbf{e}^H \otimes \mathbf{I}_K) D_{\mathbf{z}^*} \text{vec}(D_{\mathbf{z}^*} \mathbf{y})^T d\mathbf{z}^*. \quad (3.1.25)$$

Подставим выражения (3.1.24), (3.1.25) в (3.1.21) и приравняем выражения при дифференциалах $d\mathbf{z}$, $d\mathbf{z}^*$ с выражениями при дифференциалах в (2.1.4), получим иско-
мые Гессианы:

$$H_{\mathbf{z}, \mathbf{z}^*} J = D_{\mathbf{z}} (D_{\mathbf{z}^*} J)^T = (D_{\mathbf{z}} \mathbf{y})^H (D_{\mathbf{z}} \mathbf{y}) - (\mathbf{e}^T \otimes \mathbf{I}_K) D_{\mathbf{z}} \text{vec}(D_{\mathbf{z}} \mathbf{y})^H + \\ + (D_{\mathbf{z}^*} \mathbf{y})^T (D_{\mathbf{z}} \mathbf{y}^*) - (\mathbf{e}^H \otimes \mathbf{I}_K) D_{\mathbf{z}} \text{vec}(D_{\mathbf{z}^*} \mathbf{y})^T, \quad (3.1.26)$$

$$H_{\mathbf{z}^*, \mathbf{z}^*} J = D_{\mathbf{z}^*} (D_{\mathbf{z}^*} J)^T = (D_{\mathbf{z}} \mathbf{y})^H (D_{\mathbf{z}^*} \mathbf{y}) - (\mathbf{e}^T \otimes \mathbf{I}_K) D_{\mathbf{z}^*} \text{vec}(D_{\mathbf{z}} \mathbf{y})^H + \\ + (D_{\mathbf{z}^*} \mathbf{y})^T (D_{\mathbf{z}^*} \mathbf{y}^*) - (\mathbf{e}^H \otimes \mathbf{I}_K) D_{\mathbf{z}^*} \text{vec}(D_{\mathbf{z}^*} \mathbf{y})^T. \quad (3.1.27)$$

Таким образом, выражения (3.1.26), (3.1.27), (3.1.19), (3.1.20) определяют полную матрицу вторых производных, а выражения (3.1.18), (2.1.7) полный градиент функции потерь MSE в разностном уравнении (3.1.17).

Отметим, что разностное уравнение метода Ньютона (3.1.17) для вещественной модели $\mathbf{y} \in \mathbb{R}^{N \times 1}$ с вещественными параметрами $\mathbf{z} \in \mathbb{R}^{K \times 1}$ имеет следующий вид:

$$\mathbf{z}_{k+1} = \mathbf{z}_k - \mu (H_{\mathbf{z}, \mathbf{z}} J)^{-1} (D_{\mathbf{z}} J)^T, \quad (3.1.28)$$

где вследствие (2.1.11) градиент представлен выражением:

$$(D_{\mathbf{z}} J)^T = (D_{\mathbf{z}} \mathbf{y})^T \mathbf{e} \in \mathbb{R}^{K \times 1}, \quad (3.1.29)$$

в то время как гессиан может быть выражен из (3.1.27) как:

$$H_{\mathbf{z}, \mathbf{z}} J = D_{\mathbf{z}} (D_{\mathbf{z}} J)^T = 2(D_{\mathbf{z}} \mathbf{y})^T (D_{\mathbf{z}} \mathbf{y}) - 2(\mathbf{e}^T \otimes \mathbf{I}_K) D_{\mathbf{z}} \text{vec}(D_{\mathbf{z}} \mathbf{y})^T. \quad (3.1.30)$$

Оценим вычислительную сложность шага метода Ньютона (3.1.17). Подсчет градиента оценивается как $\mathcal{O}(KN)$ согласно (2.1.13). Подсчет вычислительной сложности одной из матриц (3.1.26), (3.1.27) представляет собой сумму сложности вычисления первого слагаемого $\mathcal{O}(K^2N)$ и второго $\mathcal{O}(K^2N) + \mathcal{O}(K^2)$. Сложность второго слагаемого оценена с учетом разреженности матрицы $(\mathbf{e}^H \otimes \mathbf{I}_K) D_{\mathbf{z}^*} \text{vec}(D_{\mathbf{z}^*} \mathbf{y})^T = \sum_{j=0}^{N-1} D_{\mathbf{z}^*} (D_{\mathbf{z}^*} \mathbf{y}_j)^T \mathbf{e}_j^*$. Итак оценка вычислительной сложности полного гессиана, состоящего из матриц (3.1.19), (3.1.20), (3.1.26), (3.1.27) представляет собой $\mathcal{O}(K^2(N+1))$.

С учетом обращения полного гессиана (3.1.17), (3.1.30), а также вычисления гра-

диента (2.1.13) оценка вычислительной сложности шага метода Ньютона:

$$\chi_{NM} = \mathcal{O}(KN) + \mathcal{O}(K^2(N+1)) + \mathcal{O}(K^3) = \mathcal{O}(K^3 + K^2N + 2KN). \quad (3.1.31)$$

3.2 Модификации метода Ньютона

Как отмечалось ранее, метод Ньютона сходится квадратично вблизи точки оптимума. При старте алгоритма с удалённой от оптимума начальной точки итеративная процедура может расходиться [**polyak_optimiz**]. Для обеспечения глобальной сходимости широко применяются модификации метода Ньютона.

Алгоритм Левенберга-Марквардта [**polyak_optimiz**] является одной из модификаций метода Ньютона. Метод заключается в том, чтобы внести добавку к гессиану (3.1.17) для улучшения численной устойчивости алгоритма при обращении матрицы:

$$\mathbf{c}_{k+1} = \mathbf{c}_k - (\mathbf{H}_{\mathbf{c}, \mathbf{c}^*} J(\mathbf{c}_k) + \lambda_k \mathbf{I}_{2K})^{-1} D_{\mathbf{c}^*} J(\mathbf{c}_k), \quad (3.2.1)$$

где λ_k – действительное положительное число. Добавка $\lambda_k \mathbf{I}_{2K}$ – регуляризация, которая изменяет направление шага алгоритма в сторону антиградиента тем больше, чем больше норма $\|\lambda_k \mathbf{I}_{2K}\|$:

$$\lim_{\lambda_k \rightarrow \infty} (\mathbf{H}_{\mathbf{c}, \mathbf{c}^*} J(\mathbf{c}_k) + \lambda_k \mathbf{I}_{2K})^{-1} = \mu \mathbf{I}_{2K}, \quad \mu \rightarrow 0.$$

Число λ_k подбирается каждую итерацию при помощи одномерной оптимизации. Такие алгоритмы подбора λ_k вычислительно проще обращения матрицы.

Также существует модификация алгоритма Левенберга-Марквардта, идея которой заключается в адаптивной подборе параметра регуляризации λ_k (3.2.1) – алгоритм 1. Алгоритм производит линейный поиск параметра λ_k таким образом, чтобы обеспечить убывание функции потерь.

Кроме того, практическое применение находит демпфированный метод Ньютона [**nesterov**], представленный алгоритмом 2. Идея модификации заключается в том, чтобы на каждой итерации уменьшать шаг алгоритма до тех пор, пока значение целевой функции не станет меньше, чем при исходном значении шага.

На вход демпфированного метода Ньютона поступают векторы сигнала передатчика $\mathbf{x}$ и принимаемого $\mathbf{d}$ сигналов, начальные значения параметров модели $\mathbf{z}$, исходное значение шага μ и желаемое число итераций P . Функция `model(·)` выдает вектор сигналов на выходе адаптивной модели на основе текущих параметров и входа модели.

Далее по методу Ньютона вычисляется вектор шага коэффициентов, после чего определяются новые значения коэффициентов с текущим значением шага μ .

На основе новых параметров получаем выход модели и новое отклонение. Если значение критерия MSE стало меньше после обновления коэффициентов, то шаг μ удваивается. Такое увеличение шага будет происходить пока он меньше единицы.

Algorithm 1: Метод Ньютона с адаптивной регуляризацией на основе алгоритма Левенберга-Марквардта

Data: $\mathbf{x}$, $\mathbf{d}$, model, $\alpha > 1$, $\mu > 0$

Result: $\mathbf{z}$

```

1  Инициализировать регуляризацию  $\lambda \geq 0$ ;
2  Оценить начальное значение ф-ции потерь:  $J \leftarrow \text{loss}(\text{model}(\mathbf{x}, \mathbf{z}), \mathbf{d})$ ;
3  while не достигнут критерий останова do
4      Вычислить Гессиан  $\mathbf{H}$  и градиент  $\mathbf{g}$ ;
5      Запомнить текущий параметры модели:  $\mathbf{z}_{\text{tmp}} \leftarrow \mathbf{z}$ ;
6      Обновить параметры:  $\mathbf{z} \leftarrow \mathbf{z} - \mu(\mathbf{H} + \lambda \|\text{vec}(\mathbf{H})\|_{\infty} I)^{-1} \mathbf{g}$ ;
7      Вычислить новое значение ф-ции потерь:  $J_{\text{tmp}} \leftarrow \text{loss}(\text{model}(\mathbf{x}, \mathbf{z}), \mathbf{d})$ ;
8      if  $J_{\text{tmp}} < J$  then
9           $\lambda \leftarrow \frac{\lambda}{\alpha}$ ;
10     else
11         while  $J_{\text{tmp}} \geq J$  do
12              $\lambda \leftarrow \lambda \cdot \alpha$ ;
13              $\mathbf{z} \leftarrow \mathbf{z}_{\text{tmp}} - \mu(\mathbf{H} + \lambda \|\text{vec}(\mathbf{H})\|_{\infty} I)^{-1} \mathbf{g}$ ;
14              $J_{\text{tmp}} \leftarrow \text{loss}(\text{model}(\mathbf{x}, \mathbf{z}), \mathbf{d})$ ;
15         end
16     end
17      $J \leftarrow J_{\text{tmp}}$ ;
18 end

```

Параметры запоминаются, алгоритм переходит в новую итерацию.

Если значение критерия MSE ухудшилось, алгоритм будет уменьшать значение шага μ до тех пор, пока значение критерия не станет лучше исходного. После такой процедуры алгоритм запомнит значения параметров и запустится новая итерация.

Ввиду того, что в задачах нелинейной обработки сигналов задача вообще говоря не является квадратичной, методу Ньютона понадобится больше одной итерации для поиска точки оптимума.

3.3 Смешанный метод Ньютона

Смешанный метод Ньютона (Mixed Newton method – MNM) — модификация метода Ньютона (3.1.17) в условиях голоморфности вектора ошибки $\mathbf{e} = \mathbf{e}(\mathbf{z}, \mathbf{x})$. Иначе говоря смешанный метод Ньютона работает в предположении независимости вектора ошибки от сопряженных параметров $\mathbf{z}^*$: $\mathbf{e} = \mathbf{e}(\mathbf{x}, \mathbf{z})$:

$$D_{\mathbf{z}^*} \mathbf{e}(\mathbf{x}, \mathbf{z}) = -D_{\mathbf{z}} \mathbf{y}(\mathbf{x}, \mathbf{z}) = \mathbf{0}. \quad (3.3.1)$$

Идея алгоритма заключается в том, чтобы использовать только смешанный гессиан $H_{\mathbf{z}, \mathbf{z}^*} J$ для обучения параметров модели `[mixed_newton]`. Разностное уравнение смешанного метода Ньютона может быть представлено следующим выражением:

$$\mathbf{z}_{k+1} = \mathbf{z}_k - \mu(H_{\mathbf{z}, \mathbf{z}^*} J)^{-1} (D_{\mathbf{z}^*} J)^T, \quad (3.3.2)$$

Algorithm 2: Демпфированный метод Ньютона**Data:** $x, d, z, P, \mu, \text{model}, \alpha > 1$ **Result:** z

```

1 for  $i \in \overline{0, P-1}$  do
2    $y_{prev} = \text{model}(z, x)$ ;
3    $e_{prev} = d - y_{prev}$ ;
4    $\Delta z = H^{-1}g$ ;
5    $z_{tmp} = z + \mu \Delta z$ ;
6    $y_{curr} = \text{model}(z_{tmp}, x)$ ;
7    $e_{curr} = d - y_{curr}$ ;
8   if  $MSE(e_{prev}) - MSE(e_{curr}) \geq 0$  then
9      $\mu = \mu * 2$ ;
10    if  $\mu > 1$  then
11       $\mu = 1$ ;
12     $z = z_{tmp}$ ;
13  else
14    flag = True;
15    while flag do
16       $\mu = \mu / \alpha$ ;
17       $z_{tmp1} = z + \mu \Delta z$ ;
18       $y_{div} = \text{model}(z_{tmp1}, x)$ ;
19       $e_{div} = d - y_{div}$ ;
20      if  $MSE(e_{prev}) - MSE(e_{div}) \geq 0$  then
21        flag = False;
22         $z = z_{div}$ 

```

где J — функция потерь MSE, определенная выражением (1.5.1).

В этом случае MNM обладает важнейшим свойством отталкивания от седловых точек [**mixed_newton**] в то время, как метод Ньютона, использующий полную матрицу вторых производных (3.1.17), может застревать в локальных оптимумах и седловых точках без дополнительных модификаций шага и регуляризации, описанных в разделе 3.2.

Вычислим смешанный гессиан для рассматриваемой функции потерь (1.5.1) в случае голоморфности вектора ошибки. Согласно выражению (3.1.26):

$$H_{z, z^*} J = (D_z y)^H D_z y, \quad (3.3.3)$$

ввиду выражения (3.3.1), а также $D_{z^*} \text{vec}(D_z y)^H = 0$. Последнее выражение справедливо поскольку матрица $(D_z y)^H$ зависит только от z^* и не зависит от z ввиду голоморфности $y = y(x, z)$.

Таким образом, учитывая выражения (3.3.3), (2.1.10) и (3.3.2) алгоритм смешанного метода Ньютона можно представить следующим разностным уравнением:

$$z_{k+1} = z_k + \mu ((D_z y)^H D_z y)^{-1} (D_z y)^H e. \quad (3.3.4)$$

Отдельно отметим, что сложность хранения гессиана может быть оценена как $\mathcal{O}(K^2)$ [**matrix_comput**], если $K \times K$ – размерность гессиана. Обращение гессиана может быть сведено к решению системы из M линейных уравнений. Вычислительная сложность такой операции может быть оценена как $\mathcal{O}(M^3)$ [**matrix_comput**]. В результате, вычислительная сложность шага смешанного метода Ньютона согласно (3.3.4) оценивается как:

$$\chi_{MNM} = \mathcal{O}(KN) + \mathcal{O}(K^2N) + \mathcal{O}(K^2) + \mathcal{O}(K^3) = \mathcal{O}(K^3 + K^2N + KN). \quad (3.3.5)$$

Заметим, что разностное уравнение смешанного метода Ньютона (2.1.9) для вещественной модели $\mathbf{y} \in \mathbb{R}^{N \times 1}$ с вещественными параметрами $\mathbf{z} \in \mathbb{R}^{K \times 1}$ совпадает с разностным уравнением классического метода Ньютона (3.1.28), где гессиан определяется выражением (3.1.30).

Также отметим, что поскольку выход вещественной модели с вещественными параметрами зависит от прямых и сопряженных параметров (2.1.12), ошибка адаптации является неголоморфной, то есть не выполняется условие (2.1.9). Следовательно для вещественной модели с вещественными параметрами смешанный метод Ньютона теряет свойство отталкивания от седловых точек [**mixed_newton_global_opt**].

3.4 Метод LS

Метод LS – Least Squares представляет собой один шаг смешанного метода Ньютона с шагом адаптации $\mu = 1$ (3.3.4). В случае голоморфной по параметрам модели $\mathbf{z}$ ошибки $\mathbf{e} = \mathbf{e}(\mathbf{x}, \mathbf{z})$ и линейности по параметрам модели

$$\begin{aligned} \mathbf{e} &= \mathbf{e}(\mathbf{x}, \mathbf{z}) = \mathbf{d} - \mathbf{y}(\mathbf{x}, \mathbf{z}), \\ \mathbf{y} &= \mathbf{U}(\mathbf{x})\mathbf{z}, \quad \mathbf{U}(\mathbf{x}) - \text{матрица входных данных}, \end{aligned} \quad (3.4.1)$$

функция потерь MSE (1.5.1) является квадратичной по параметрам модели. В этом случае минимизация MSE сводится к решению линейной системы [**convex_opt**]. В связи с этим LS находит глобальный оптимум функции потерь за 1 шаг [**convex_opt**].

Поскольку глобальный оптимум может быть найден из любой начальной точки, включая $\mathbf{z}_0 = \mathbf{0}$, то финальный вид LS метода представлен выражением:

$$\mathbf{z}_{\text{opt}} = ((D_{\mathbf{z}}\mathbf{y})^H D_{\mathbf{z}}\mathbf{y})^{-1} (D_{\mathbf{z}}\mathbf{y})^H \mathbf{d}, \quad (3.4.2)$$

где $D_{\mathbf{z}}\mathbf{y} = \mathbf{U}(\mathbf{x})$ ввиду линейности модели (3.4.1), $\mathbf{e} = \mathbf{d} - \mathbf{U}\mathbf{z}_0 = \mathbf{d}$ – начальная ошибка адаптации.

4. Методы адаптации моделей нелинейных искажений не требующие явного обращения матрицы Гессе

Методы второго порядка подразумевают необходимость накапливать матрицу вторых производных для каждого нового блока данных, хранить в памяти, а также обращать, обеспечивая при этом численную устойчивость процедуры инверсии матрицы `[matrix_comput]`. Такие методы являются вычислительно сложными, кроме того достаточно трудными с точки зрения реализации в целочисленной арифметике. В связи с этим в теории нелинейной обработки сигналов предлагается использовать методы применяющие приближенное вычисление обратной матрицы вторых производных либо приближенное вычисление произведения обратной матрицы и градиента функции потерь.

В данном разделе рассмотрены следующие алгоритмы:

- Метод сопряженных градиентов,
- Метод дихотомического покоординатного спуска,
- Квазиньютоновские методы.

Метод сопряженных градиентов и методы дихотомического покоординатного спуска относятся к методам приближенного вычисления обратной матрицы вторых производных и подразумевают явное вычисление гессиана. При этом некоторые квазиньютоновские методы основаны на оценке произведения обратной матрицы Гессе и градиента функции потерь без явного вычисления матрицы вторых производных.

4.1 Метод сопряженных градиентов

Рассмотрим шаг смешанного метода Ньютона как минимизацию второй нормы ошибки $e(z)$ (1.5.1), разложенной до членов первого порядка малости. Ввиду голоморфности e :

$$\Delta z_k = \arg \min_z f(z) = \arg \min_z \left\| e(z)|_{z=z_k} + D_z e(z)|_{z=z_k} (z - z_k) \right\|_2^2. \quad (4.1.1)$$

Распишем вторую норму разложения ошибки в выражении (4.1.1) и приведем подобные слагаемые, получим следующее выражении для квадратичной формы:

$$\begin{aligned} f(z) &= (z - z_k)^H (D_z e(z))^H \Big|_{z=z_k} D_z e(z) \Big|_{z=z_k} (z - z_k) + \\ &+ e^H(z_k) D_z e(z) \Big|_{z=z_k} (z - z_k) + (z - z_k)^H (D_z e(z))^H \Big|_{z=z_k} e(z_k) + \\ &+ e^H(z_k) e(z_k) = \Delta z_k^H M \Delta z_k + b^H \Delta z_k + \Delta z_k^H b + c, \end{aligned} \quad (4.1.2)$$

где $\mathbf{M} = [(D_{\mathbf{z}} \mathbf{e}(z))^H D_{\mathbf{z}} \mathbf{e}(z)]|_{\mathbf{z}=\mathbf{z}_k} = H_{\mathbf{z}, \mathbf{z}^*} J|_{\mathbf{z}=\mathbf{z}_k}$ — неотрицательно определенная матрица смешанных производных функции потерь MSE (1.5.1), $\mathbf{b} = (D_{\mathbf{z}} \mathbf{e}(z))^H \mathbf{e}(z)|_{\mathbf{z}=\mathbf{z}_k} = (D_{\mathbf{z}^*} J)^T$ — градиент функции потерь MSE (1.5.1), $c = \mathbf{e}^H(\mathbf{z}_k) \mathbf{e}(\mathbf{z}_k)$ — константа. Отметим, что поскольку

$$\arg \min_{\mathbf{z}} f(\mathbf{z}) = \arg \min_{\mathbf{z}} f(\mathbf{z}) - c, \quad (4.1.3)$$

константу c можно отбросить при выводе метода сопряженных градиентов.

Для простоты выражений обозначим $\mathbf{x} \equiv \Delta \mathbf{z}_k$ и перепишем квадратичную форму:

$$f(\mathbf{x}) = \mathbf{x}^H \mathbf{M} \mathbf{x} + \mathbf{b}^H \mathbf{x} + \mathbf{x}^H \mathbf{b}, \quad \mathbf{M} \succcurlyeq 0, \quad (4.1.4)$$

Выведем метод сопряженных градиентов для минимизации квадратичной формы (4.1.4) для поиска приращения параметров модели $\mathbf{x}_k$ на шаге k .

Пусть множество векторов $\{\mathbf{p}_j\}_{j=0}^{K-1} \in \mathbb{C}^{K \times 1}$ — сопряжены относительно матрицы $\mathbf{M}$, т.е. выполняется условие:

$$\mathbf{p}_j^H \mathbf{M} \mathbf{p}_l = 0 \quad \forall k \neq l, \quad (4.1.5)$$

тогда вектора $\{\mathbf{p}_j\}_{j=0}^{K-1}$ — система линейно-независимых векторов по аналогии с вещественным случаем [HestenesStiefel1952], т.е. представляют собой базис в пространстве $\mathbb{C}^{K \times 1}$. Будем искать приращение $\mathbf{x}$ минимизирующее (4.1.4) методом простой итерации, раскладывая приращение на i -ом шаге по линейно-независимым векторам сопряженным относительно $\mathbf{M}$:

$$\mathbf{x}_{i+1} = \mathbf{x}_0 + \sum_{j=0}^i \alpha_j \mathbf{p}_j, \quad (4.1.6)$$

где $\alpha_j \in \mathbb{C}$ — коэффициенты разложения по базису, $\mathbf{x}_0 \in \mathbb{C}^{K \times 1}$ — начальное приближение решения $\mathbf{x}$. Подставим выражение (4.1.6) в квадратичную форму (4.1.4):

$$f(\mathbf{x}_{i+1}) = f(\mathbf{x}_0) + \sum_{j=0}^i \left(\alpha_j (\mathbf{M} \mathbf{x}_0 + \mathbf{b})^H \mathbf{p}_j + \alpha_j^* \mathbf{p}_j^H (\mathbf{M} \mathbf{x}_0 + \mathbf{b}) + |\alpha_j|^2 \mathbf{p}_j^H \mathbf{M} \mathbf{p}_j \right), \quad (4.1.7)$$

где $\mathbf{p}_0 = \mathbf{M} \mathbf{x}_0 + \mathbf{b}$ — первый вектор множества сопряженных векторов, инициализируется как градиент функции $f(\mathbf{x})$, $\alpha_j^* \in \mathbb{C}$ — комплексно сопряжение коэффициента разложения α_j . Найдём коэффициенты разложения α_j из условия минимизации квадратичной формы по коэффициентам разложения $D_{\alpha_j^*} f(\mathbf{x}, \alpha_j)|_{\mathbf{x}=\mathbf{x}_{i+1}} = 0$:

$$\mathbf{p}_j^H \mathbf{p}_0 + \alpha_j \mathbf{p}_j^H \mathbf{M} \mathbf{p}_j = 0, \quad (4.1.8)$$

$$\alpha_j = -\frac{\mathbf{p}_j^H \mathbf{p}_0}{\mathbf{p}_j^H \mathbf{M} \mathbf{p}_j}. \quad (4.1.9)$$

Таким образом рекурсивная формула обновления приближения решения $\mathbf{x}$:

$$\mathbf{x}_{i+1} = \mathbf{x}_i + \alpha_i \mathbf{p}_i = \mathbf{x}_i - \frac{\mathbf{p}_i^H \mathbf{p}_0}{\mathbf{p}_i^H \mathbf{M} \mathbf{p}_i} \mathbf{p}_i. \quad (4.1.10)$$

Отметим, что $\mathbf{p}_i^H \mathbf{p}_0 = \mathbf{p}_i^H (\mathbf{M} \mathbf{x}_0 + \mathbf{b}) = \mathbf{p}_i^H (\mathbf{M} \mathbf{x}_i + \mathbf{b})$ по условию сопряженности векторов (4.1.5). Обозначим градиент функции $f(\mathbf{x})$ в точке $\mathbf{x}_i$ как $\mathbf{r}_i \equiv D_{\mathbf{x}^*} f(\mathbf{x})|_{\mathbf{x}=\mathbf{x}_i} = \mathbf{M} \mathbf{x}_i + \mathbf{b}$, тогда рекурсивное выражение пересчета приближения решения (4.1.10) представляется как:

$$\mathbf{x}_{i+1} = \mathbf{x}_i + \alpha_i \mathbf{p}_i = \mathbf{x}_i - \frac{\mathbf{p}_i^H \mathbf{r}_i}{\mathbf{p}_i^H \mathbf{M} \mathbf{p}_i} \mathbf{p}_i. \quad (4.1.11)$$

В теории метода сопряженного градиента для вещественных систем линейных уравнений методом математической индукции доказывается, что для системы $\{\mathbf{p}_j\}_{j=0}^i$ векторов сопряженных относительно $\mathbf{M}$ (4.1.5) для $i \geq 0$ и $j \leq i$ справедливо выражение [HestenesStiefel1952]:

$$\mathbf{r}_{i+1}^H \mathbf{p}_j = 0. \quad (4.1.12)$$

Выражение (4.1.12) представляет собой физический смысл векторов $\mathbf{p}_j$, $\mathbf{p}_0 = \mathbf{M} \mathbf{x}_0 + \mathbf{b}$. Он заключается в том, что для упомянутой системы сопряженных векторов градиент квадратичной формы (4.1.4) в точке, определяемой итеративным алгоритмом (4.1.6) будет ортогонален всем ранее найденным сопряженным направлениям. Иначе говоря градиент в новой точке не будет содержать избыточности.

В связи с физическим смыслом сопряженных векторов (4.1.12) определим выбор сопряженных направлений следующим итеративным алгоритмом:

$$\mathbf{p}_{i+1} = \mathbf{r}_{i+1} + \beta_{i+1} \mathbf{p}_i, \quad (4.1.13)$$

где параметры β_i определяются также из условия сопряженности (4.1.5):

$$\beta_{i+1} = -\frac{\mathbf{p}_i^H \mathbf{M} \mathbf{r}_{i+1}}{\mathbf{p}_i^H \mathbf{M} \mathbf{p}_i}. \quad (4.1.14)$$

Отметим, что все направления найденные таким итеративным методом (4.1.13), (4.1.14) будут сопряженными, т.е. верно $\mathbf{p}_j^H \mathbf{M} \mathbf{p}_i = 0 \ \forall i > 1, \ \forall j < i$ [HestenesStiefel1952].

Таким образом на основе рекурсивных выражений приближения решения (4.1.11), поиска сопряженных направлений (4.1.13), (4.1.14) метод сопряженных градиентов для приближенного поиска шага смешанного метода Ньютона (4.1.1) представлен алгоритмом 3:

Метод сопряжённых градиентов итерационно устраняет влияние наиболее значимых собственных значений матрицы $\mathbf{M}$ при минимизации квадратичной формы (4.1.4) [HestenesStiefel1952]. В случае решения линейной задачи адаптивной фильтрации роль матрицы $\mathbf{M}$ играет оценка корреляционной матрицы входного сигнала фильтра. Для узкополосных сигналов число наиболее значимых собственных

Algorithm 3: Метод сопряженных градиентов

Require: z_0 – начальные значения параметров модели, T – число обновлений параметров модели, L – число итераций метода сопряженных градиентов между обновлениями параметров модели, μ – величина шага обновления параметров.

Ensure: z_{T-1} – конечное значение параметров модели.

```

1: for  $t = 1$  to  $T$  do
2:   Получить текущие параметры модели  $z_t$ 
3:   Инициализировать приращение  $x_0$ 
4:   Вычислить смешанный гессиан MSE  $M_t = H_{z,z^*} J$ 
5:   Вычислить градиент MSE  $b_t = (D_{z^*} J)^T$ 
6:   Вычислить градиент квадратичной формы  $r_0 = M_t x_0 + b_t$ 
7:   Инициализировать направление  $p_0 = r_0$ 
8:   for  $k = 0$  to  $L - 1$  do
9:      $\xi_k = M_t p_k$ 
10:     $\alpha_k = -\frac{p_k^H r_k}{p_k^H \xi_k}$ 
11:     $x_{k+1} = x_k + \alpha_k p_k$ 
12:     $r_{k+1} = r_k + \alpha_k \xi_k$ 
13:     $\beta_{k+1} = -\frac{\xi_k^H r_{k+1}}{p_k^H \xi_k}$ 
14:     $p_{k+1} = r_{k+1} + \beta_{k+1} p_k$ 
15:   end for
16:   Пересчитать параметры модели:  $z_{t+1} = z_t + \mu x_{K-1}$ 
17: end for
18:
19: return  $z_{T-1}$ 

```

значений корреляционной матрицы невелико [deLamare2015]. По этой причине метод сопряженных градиентов сходится за число итераций существенно меньше числа параметров модели тем самым решая проблему высокой вычислительной сложности смешанного метода Ньютона [mnm_paper_alex_degt] обусловленную обращением матрицы вторых производных.

В алгоритме 3 наиболее вычислительно затратными операциями являются операции вычисления матрицы Гессе, градиента, а также операции подсчета произведения матрицы Гессе и вектора сопряженного направления $\mathcal{O}(K^2)$. Все остальные операции являются линейными по числу параметров K . Таким образом сложность одной итерации пересчета параметров модели по методу сопряженных градиентов представляется как:

$$\chi_{CG} = \mathcal{O}(KN) + \mathcal{O}(K^2N) + \mathcal{O}(TK^2) = \mathcal{O}(KN + K^2N + LK^2), \quad (4.1.15)$$

где (4.1.15) учитывается, что на одну итерацию пересчета параметров модели производится L итераций метода сопряженных градиентов согласно алгоритму 3.

Согласно теории метода сопряженных градиентов [HestenesStiefel1952] алгоритм гарантирует точное решение квадратичной задачи оптимизации (4.1.4) в случае числа итераций алгоритма T совпадающего с рангом матрицы M . Таким обра-

зом, согласно оценкам (3.3.5), (4.1.15) вычислительная сложность метода сопряженных градиентов совпадает с вычислительной сложностью смешанного метода Ньютона (3.3.4) для полноранговой матрицы $\mathbf{M} \in \mathbb{C}^{K \times K} : K = \text{rank}(\mathbf{M})$, если $T = K$.

Однако, поскольку метод сопряженных градиентов последовательно устраняет влияние наиболее значимых собственных значений матрицы смешанных производных $\mathbf{M}$, данный метод может быть использован для приближенного вычисления шага смешанного метода Ньютона путем уменьшения числа итераций на одно обновление параметров модели: $L < K$ с сохранением высокой скорости сходимости. Таким образом данный метод представляет собой компромисс между градиентными методами с низкой вычислительной сложностью (2.1.13) и линейной скоростью сходимости [nesterov2004], и смешанным методом Ньютона с высокими вычислительными затратами (3.3.5) и сверхлинейной скоростью сходимости [mixed_newton].

4.2 Метод DCD

Метод покоординатного спуска (англ. DCD – Dichotomous Coordinate Descent) является методом поиска решения систем линейных уравнений с квадратной матрицей и не относится к методам первого порядка [dcd_alg_thesis].

Идея применения алгоритма, заключается также в том, чтобы аппроксимировать шаг метода Ньютона (3.3.4) путем решения оптимизационной задачи (4.1.4). Как было отмечено в разделе 4.1 поиск шага смешанного метода Ньютона эквивалентен минимизации квадратичной формы (4.1.4), что в свою очередь эквивалентно решению системы линейных уравнений:

$$\mathbf{M}\mathbf{x} = -\mathbf{b}, \quad (4.2.1)$$

где $\mathbf{M} = [(D_{\mathbf{z}} \mathbf{e}(z))^H D_{\mathbf{z}} \mathbf{e}(z)]|_{\mathbf{z}=\mathbf{z}_k} = H_{\mathbf{z}, \mathbf{z}^*} J|_{\mathbf{z}=\mathbf{z}_k}$ — неотрицательно определенная матрица смешанных производных функции потерь MSE (1.5.1), $\mathbf{b} = (D_{\mathbf{z}} \mathbf{e}(z))^H \mathbf{e}(z)|_{\mathbf{z}=\mathbf{z}_k} = (D_{\mathbf{z}^*} J)^T$ — градиент функции потерь MSE (1.5.1).

Введем вектор невязки следующим образом:

$$\mathbf{r} = \mathbf{M}\mathbf{x} + \mathbf{b}. \quad (4.2.2)$$

Идея алгоритма заключается в том, чтобы упростить процедуру обращения матрицы. Для этого на каждой итерации предлагается выделять наибольший по модулю элемент в векторе ошибки $\mathbf{r}$, обнулять его и пересчитывать вектор коэффициентов, двигаясь Таким образом, по направлению убывания среднего квадрата ошибки вдоль соответствующей координаты вектора коэффициентов. Метод DCD для вещественнозначных векторов и матриц описан в алгоритме 4 [dcd_alg_thesis].

Константы K_1, K_2 задаются пользователем. K_1 определяет количество шагов в направлении уменьшения среднего квадрата ошибки, K_2 задаёт число возможных дроблений шага α на каждой итерации перед внесением изменения в вектор прира-

Algorithm 4: Real-valued leading DCD algorithm

Data: M, r, K_1, K_2, T, μ
Result: z_{T-1}, r

```

1 for  $t \in \overline{0, T-1}$  do
2   Инициализация:
3    $\Delta z = 0, \alpha = H, m = 1$ 
4   for  $i \in \overline{0, K_1}$  do
5      $k = \arg \max_{p=\overline{0, P-1}} \{|r_p|\}$ , перейти на строку 9;
6      $m = m + 1, \alpha = \alpha/2$ ;
7     if  $m > K_2$  then
8       завершения алгоритма;
9     if  $|r_k| \leq (\frac{\alpha}{2})M_{k,k}$  then
10      перейти на строку 6;
11      $\Delta z_k = \Delta z_k - \text{sign}(r_k)\alpha$ ;
12      $r = r + \text{sign}(r_k)\alpha M_{:,k}$ 
13   Пересчитать параметры модели:  $z_{t+1} = z_t + \mu \Delta z$ ;
```

щения Δz .

Выбирается индекс k наибольшей по модулю координаты невязки r_k . Далее алгоритм уменьшает шаг α до тех пор, пока условие строки 9 не станет ложным. Таким образом, шаг α будет уменьшаться до тех пор, пока приращение невязки $\alpha M_{:,k}$ не станет меньше модуля самой невязки. Это необходимо для устойчивости алгоритма.

Далее вносится приращение в вектор невязки r . Для того, чтобы преобразование было равносильным, из вектора приращения параметров Δz необходимо добавить поправку $\text{sign}(r_k)\alpha$ по координате с индексом k .

Рассмотрим алгоритм DCD для комплекснозначных векторов и матриц. Такой алгоритм можно получить сведением системы комплекснозначных уравнений к системе вещественнозначных уравнений и воспользовавшись алгоритмом 4. Сгруппируем комплекснозначные вектора и матрицы следующим образом:

$$\begin{aligned}
M &= M_1 + jM_2, \quad M \in \mathbb{C}^{K/2 \times K/2} \\
z &= z_1 + jz_2, \quad z \in \mathbb{C}^{K/2 \times 1} \\
b &= b_1 + jb_2, \quad b \in \mathbb{C}^{K/2 \times 1},
\end{aligned} \tag{4.2.3}$$

где $M_1, M_2, z_1, z_2, b_1, b_2$ – вещественнозначные объекты. Тогда:

$$Mz = (M_1 z_1 - M_2 z_2) + j(M_2 z_1 + M_1 z_2) = c_1 + jc_2, \tag{4.2.4}$$

$$\begin{pmatrix} M_1 z_1 - M_2 z_2 \\ M_2 z_1 + M_1 z_2 \end{pmatrix} = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}, \tag{4.2.5}$$

$$\begin{pmatrix} M_1 & -M_2 \\ M_2 & M_1 \end{pmatrix} \begin{pmatrix} z_1 \\ z_2 \end{pmatrix} = - \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}. \tag{4.2.6}$$

Из матричного уравнения (4.2.6) следует, что решение системы $K/2$ комплекснозначных уравнений с $K/2$ переменными эквивалентно решению K вещественнозначных уравнений с K переменными. Исходя из этого DCD алгоритм для комплекснозначной системы размерности $K/2 \times K/2$ может быть представлен, как алгоритм 5 [dcd_alg_thesis].

Algorithm 5: Complex-valued leading DCD algorithm

Data: K_1, K_2, T, μ
Result: $\mathbf{z}_{T-1}, \mathbf{r}$

```

1 for  $t \in \overline{0, T-1}$  do
2   Инициализация:
3    $\Delta \mathbf{z} = \mathbf{0}, \alpha = H, m = 1, \mathbf{M} = H_{c,c^*} J, \mathbf{r} = \mathbf{M} \mathbf{z}_t + (D_{c^*} J)^T$ 
4   for  $i \in \overline{0, K_1}$  do
5      $[k, s] = \arg \max_{p=\overline{0, (P-1)/2}} \{|Re(r_p)|, |Im(r_p)|\}$ , go to line 13;
6      $m = m + 1, \alpha = \alpha/2$ ;
7     if  $m > K_2$  then
8       └ завершение алгоритма;
9     if  $s = 1$  then
10      └  $r_{tmp} = Re(r_k)$ 
11    else
12      └  $r_{tmp} = Im(r_k)$ 
13    if  $|r_{tmp}| \leq (\frac{\alpha}{2}) M_{k,k}$  then
14      └ перейти на строку 6;
15     $\Delta z_k = \Delta z_k - \text{sign}(r_k) s \alpha$ ;
16     $\mathbf{r} = \mathbf{r} + \text{sign}(r_n) s \alpha \mathbf{M}_{:,k}$ 
17  Пересчитать параметры модели:  $\mathbf{z}_{t+1} = \mathbf{z}_t + \mu \Delta \mathbf{z}$ ;
```

Сначала производится поиск индекса k наибольшего модуля среди вещественных и мнимых частей элементов вектора отклонения $\mathbf{r}$. В переменную s записывается 1, если в наибольшей по модулю является вещественная часть одной из координат $\mathbf{r}$, $s = j$, если мнимая. Эта переменная учитывает вещественный или мнимый характер приращения невязки и поправки на вектор коэффициентов.

Затем, как и для вещественнозначного случая, шаг алгоритма уменьшается до тех пор, пока приращение вектора невязки $\mathbf{r}$ не станет меньше модуля самой невязки. После чего производится пересчёт вектора приращения коэффициентов $\Delta \mathbf{z}$ и вектора невязки $\mathbf{r}$.

В результате алгоритм 5 выдаёт вектор невязки $\mathbf{r}$ и вектор приращения коэффициентов $\Delta \mathbf{z}$, после чего производится обновление коэффициентов.

Алгоритм является методом приближенного решения системы линейных уравнений и работает итеративно. В связи с приближенным характером решения СЛАУ вблизи точки оптимума процедура DCD не гарантирует монотонной сходимости.

Наиболее вычислительно затратными операциями алгоритма 5 являются пересчет гессиана $\mathcal{O}(K^2 N)$ операций, а также подсчет градиента (2.1.10) $\mathcal{O}(KN)$. Пере-

счет параметров в соответствии со схемой DCD оценивается как $\mathcal{O}(K_1 K)$.

Итоговая оценка вычислительной сложности DCD:

$$\chi_{DCD} = \mathcal{O}(K^2 N) + \mathcal{O}(KN) + \mathcal{O}(K_1 K) = \mathcal{O}(K^2 N + K(N + K_1)). \quad (4.2.7)$$

4.3 Квазиньютоновские методы

Как отмечалось ранее, метод Ньютона обладает локальной квадратичной сходимостью, высокой точностью решения. Кроме того он является аффинно инвариантным [nesterov], что означает, что вид разностного уравнения и скорость сходимости не меняются при аффинном преобразовании координат. Однако, для реализации метода требуется хранение гессиана в памяти, также операция обращения гессиана, которая является вычислительно сложной.

Для снижения вычислительной сложности применяют методы, которые обладают скоростью сходимости выше, чем у градиентного спуска, имея при этом накладные расходы меньше, чем у метода Ньютона. Квазиньютоновские методы объединяют в себе простоту градиентного спуска с точки зрения вычислительной сложности и высокую скорость сходимости.

Как отмечать в разделе 4.1 смешанный метод Ньютона раскладывает целевую функцию в окрестности точки (4.1.2) z_k :

$$p(z_{k+1}) = J(z_k) + (z_{k+1} - z_k)^H (D_{z^*} J)^T + (z_{k+1} - z_k)^T (D_{z^*} J)^H + \frac{1}{2} (z_{k+1} - z_k)^H H_{z, z^*} \nabla_J (z_{k+1} - z_k). \quad (4.3.1)$$

Идея квазиньютоновских алгоритмов в том, чтобы заменить матрицу Гессе на её оценку:

$$H_{z, z^*} \rightarrow B_k, \quad B_k \succ 0. \quad (4.3.2)$$

Отметим, что искомая оценка гессиана должна быть положительно определённой. Выполним замену:

$$z_{k+1} - z_k = \Delta z_k, \quad (4.3.3)$$

тогда из (4.3.1), (4.3.2) и (4.3.3) получим:

$$p(\Delta z_k + z_k) = J(z_k) + \Delta z_k^H (D_{z_k^*} J)^T + \Delta z_k^T (D_{z_k^*} J)^H + \frac{1}{2} \Delta z_k^H B_k \Delta z_k. \quad (4.3.4)$$

По аналогии со смешанным методом Ньютона (3.3.2) квазиньютоновский метод будет иметь вид:

$$z_{k+1} = z_k - \mu B_k^{-1} \nabla_J(z_k) = z_k - \mu H_k \nabla_J(z_k), \quad (4.3.5)$$

где B_k, H_k – оценки прямого и обратного гессиана соответственно.

Требования, которые предъявляются к оценке гессиана:

- Быстрое обновление $B_k \rightarrow B_{k+1}$ в условиях, когда доступны только градиенты

- Быстрый поиск направления:

$$\Delta \mathbf{z}_k = \mu \mathbf{B}_k^{-1} \nabla_J(\mathbf{z}_k) = \mu \mathbf{H}_k \nabla_J(\mathbf{z}_k) \quad (4.3.6)$$

- Компактное хранение $\mathbf{B}_{k+1}$
- Сверхлинейная сходимость

Получим уравнение на поиск матрицы $\mathbf{B}_{k+1}$. Для этого сформулируем так называемое правило двух градиентов [fletcher]:

$$\left. \frac{\partial p(\Delta \mathbf{z}_{k+1} + \mathbf{z}_{k+1})}{\partial \Delta \mathbf{z}_{k+1}^H} \right|_{\Delta \mathbf{z}_{k+1} = \mathbf{0}} = (D_{\mathbf{z}_{k+1}^*} J)^T, \quad (4.3.7)$$

$$\left. \frac{\partial p(\Delta \mathbf{z}_{k+1} + \mathbf{z}_{k+1})}{\partial \Delta \mathbf{z}_{k+1}^H} \right|_{\Delta \mathbf{z}_{k+1} = -\mu \Delta \mathbf{z}_k} = (D_{\mathbf{z}_k^*} J)^T. \quad (4.3.8)$$

Требование (4.3.7) следует напрямую из (4.3.4). Вычислим производную в левой части (4.3.8):

$$\left. \frac{\partial p(\Delta \mathbf{z}_{k+1} + \mathbf{z}_{k+1})}{\partial \Delta \mathbf{z}_{k+1}^H} \right|_{\Delta \mathbf{z}_{k+1} = -\mu \Delta \mathbf{z}_k} = (D_{\mathbf{z}_{k+1}^*} J)^T - \frac{1}{2} \mathbf{B}_{k+1} \Delta \mathbf{z}_{k+1} = (D_{\mathbf{z}_{k+1}^*} J)^T - \mu \mathbf{B}_{k+1} \Delta \mathbf{z}_k \quad (4.3.9)$$

Требование (4.3.8) приводит к квазиньютоновскому уравнению (англ. Secant equation):

$$(D_{\mathbf{z}_{k+1}^*} J)^T - (D_{\mathbf{z}_k^*} J)^T = \mu \mathbf{B}_{k+1} \Delta \mathbf{z}_k \quad (4.3.10)$$

Сделаем замену и получим квазиньютоновское уравнение в следующем виде:

$$\mathbf{s}_k = \mu(\mathbf{z}_{k+1} - \mathbf{z}_k), \quad (4.3.11)$$

$$\mathbf{f}_k = (D_{\mathbf{z}_{k+1}^*} J)^T - (D_{\mathbf{z}_k^*} J)^T, \quad (4.3.12)$$

$$\mathbf{B}_{k+1} \mathbf{s}_k = \mathbf{f}_k. \quad (4.3.13)$$

В уравнении (4.3.13) векторы $\mathbf{s}_k, \mathbf{f}_k$ определяются в процессе вычислений. Квазиньютоновское уравнение является уравнением на поиск матрицы $\mathbf{B}_{k+1}$.

Отметим, что ввиду требования положительной определённости $\mathbf{B}_{k+1}$ (4.3.2), уравнение (4.3.13) не будет иметь решение в случае $\text{Re}(\mathbf{s}_k^H \mathbf{f}_k) < 0$. При выборе шага важно следить за тем, чтобы это произведение было неотрицательным.

Кроме того, пусть система (4.3.13) имеет F уравнений, тогда она будет иметь $\frac{F(F-1)}{2}$ неизвестных ввиду симметричности оценки гессиана. Это означает, что требуются дополнительные условия для обеспечения единственности решения.

Для устойчивости алгоритма соседние оценки гессиана $\mathbf{B}_k, \mathbf{B}_{k+1}$ должно быть близки друг к другу.

Далее рассмотрим следующие примеры квазиньютоновских методов: DFP, BFGS и Barzilai-Borwein [**bb_method**] [**pract_optimiz**].

4.4 Метод Barzilai-Borwein

Данный метод аппроксимирует гессиан диагональной матрицей. Пусть шаг алгоритма – величина переменная, подстраиваемая на каждой новой итерации. Распишем алгоритм градиентного спуска:

$$\begin{aligned} z_{k+1} &= z_k - \mu_k (D_{z_k^*} J)^T = z_k - \mu_k \mathbf{I} (D_{z_k^*} J)^T = \\ &= z_k - \left(\frac{1}{\mu_k} \mathbf{I} \right)^{-1} (D_{z_k^*} J)^T = z_k - \mathbf{B}_k^{-1} (D_{z_k^*} J)^T, \end{aligned} \quad (4.4.1)$$

Квазиньютоновское уравнение будет иметь вид приближенного равенства, поскольку $\mathbf{s}_k, \mathbf{f}_k$ заранее известны, а $\mathbf{B}_{k+1}$ приближается всего одним числом, чего не достаточно для строгого равенства:

$$\mu_k^{-1} \mathbf{s}_{k-1} \approx \mathbf{f}_{k-1}, \quad (4.4.2)$$

где приближенное равенство формализуется следующей задачей минимизации [**bb_method**]:

$$\min_{\mu_k} \left\| \mathbf{s}_{k-1} - \mu_k \mathbf{f}_k \right\|_2 \Rightarrow \mu_k = \frac{\mathbf{s}_{k-1}^H \mathbf{f}_{k-1}}{\mathbf{f}_{k-1}^T \mathbf{f}_{k-1}}. \quad (4.4.3)$$

Выражение (4.4.3) задаёт способ обновления шага.

Данный метод не является градиентный спуском, поскольку учитывает два предыдущих вектора коэффициентов и градиента для получения нового вектора коэффициентов.

4.5 Метод DFP

Метод DFP (англ. Davidon-Fletcher-Powell) использует поиск оценки матрицы Гёссе на каждой новой итерации [**pract_optimiz**]. Учтём ранее упомянутое требование, которое заключается в близости оценок гессианов на соседних итерациях. Формульно такая задача может быть поставлена следующим образом [**pract_optimiz**]:

$$\begin{cases} \min_{\mathbf{B}_{k+1}} \left\| \mathbf{B}_k - \mathbf{B}_{k+1} \right\|_2, \\ \mathbf{B}_{k+1} = \mathbf{B}_{k+1}^H, \\ \mathbf{B}_{k+1} \mathbf{s}_k = \mathbf{f}_k. \end{cases} \quad (4.5.1)$$

Аналитическое решение задачи (4.5.1) имеет вид [**fletcher**]:

$$\mathbf{B}_{k+1} = (\mathbf{I} - \rho_k \mathbf{f}_k \mathbf{s}_k^H) \mathbf{B}_k (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{f}_k^H) + \rho_k \mathbf{f}_k \mathbf{f}_k^H, \quad (4.5.2)$$

$$\rho_k = \frac{1}{\mathbf{f}_k^H \mathbf{s}_k}. \quad (4.5.3)$$

По формуле Шермана-Вудбери-Моррисона [**matrix_calc**] (лемма об обращении матриц) решение (4.5.2) можно преобразовать:

$$\mathbf{B}_{k+1}^{-1} \equiv \mathbf{H}_{k+1} = \mathbf{H}_k - \frac{\mathbf{H}_k \mathbf{f}_k \mathbf{f}_k^H \mathbf{H}_k}{\mathbf{f}_k^H \mathbf{H}_k \mathbf{f}_k} + \frac{\mathbf{s}_k \mathbf{s}_k^H}{\mathbf{f}_k^H \mathbf{s}_k}. \quad (4.5.4)$$

Формула (4.5.4) задаёт аналитическое выражение для вычисления оценки обратного гессиана. Для вычисления вектора коэффициентов на новой итерации эта оценка подставляется в разностное уравнение (4.3.5).

Сложность хранения оценки обратной матрицы может быть оценена как $o(K^2)$ – такая же как и для метода Ньютона. Оценим вычислительную сложность пересчета оценки гессиана. В выражении (4.5.4) сложность подсчета третьего слагаемого оценивается как $o(K^2)$, поскольку $\mathbf{s}_k \mathbf{s}_k^T$ представляет собой векторное произведение, в результате которого получается матрица размерности $K \times K$.

Второе слагаемое также вычисляется за $o(K^2)$. Выражение $\mathbf{H}_k \mathbf{f}_k$ вычисляется за $o(K^2)$. При этом $\mathbf{f}_k^H \mathbf{H}_k = (\mathbf{H}_k \mathbf{f}_k)^H$ ввиду эрмитовости $\mathbf{H}_k$. Остается произвести векторное умножение в числителе, сложность которого $o(K^2)$, а в знаменателе скалярное умножение векторов, сложность которого $o(K)$.

4.6 Метод BFGS

Метод BFGS (англ. Broyden–Fletcher–Goldfarb–Shanno). Вместо того, чтобы искать оценку гессиана, напрямую поставим задачу поиска оценки обратного гессиана [**pract_optimiz**]:

$$\begin{cases} \min_{\mathbf{H}_{k+1}} \left\| \mathbf{H}_k - \mathbf{H}_{k+1} \right\|_2, \\ \mathbf{H}_{k+1} = \mathbf{H}_{k+1}^H, \\ \mathbf{H}_{k+1} \mathbf{f}_k = \mathbf{s}_k. \end{cases} \quad (4.6.1)$$

Аналитическое решение задачи (4.6.1) записывается в виде выражения [**bfgs_fletcher**]:

$$\mathbf{H}_{k+1} = (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{f}_k^H) \mathbf{H}_k (\mathbf{I} - \rho_k \mathbf{f}_k \mathbf{s}_k^H) + \rho_k \mathbf{s}_k \mathbf{s}_k^H, \quad (4.6.2)$$

$$\rho_k = \frac{1}{\mathbf{f}_k^H \mathbf{s}_k}. \quad (4.6.3)$$

BFGS обладает локальной сверхлинейной сходимостью.

На практике приведенный метод является наиболее предпочтительным квазиньютоновским методом поскольку обладает свойством самокоррекции.

Сложность хранения и обращения гессиана оценивается как $\mathcal{O}(K^2)$, что следует из формулы (4.6.2). Таким образом, вычислительная сложность шага BFGS, с учетом вычисления гессиана и градиента, может быть оценена как:

$$\chi_{BFGS} = \mathcal{O}(K^3) + \mathcal{O}(K^2 N) + \mathcal{O}(K^2) + \mathcal{O}(KN) = \mathcal{O}(K^3 + K^2(N+1) + KN). \quad (4.6.4)$$

Отметим, что для вычисления коэффициентов на новой итерации необходима не сама матрица Гёссе (или обратная к ней), а эффективная процедура умножения матрицы на вектор $(D_{z_k^*} J)^T$. Кроме того, значения векторов $\mathbf{f}$, $\mathbf{s}$, полученные на первых итерациях могут портить оценки $\mathbf{B}$, $\mathbf{H}$ на более поздних итерациях. Для подсчет оценки обратного гесса предлагается хранить в очереди и использовать последние $m \ll K$ значений векторов $\mathbf{f}$, $\mathbf{s}$. На этой идее основана модификация Limited-Memory BFGS [lbfgs].

4.7 Квазиньютоновские методы для моделей с вещественными параметрами

Представленные выше квазиньютоновские алгоритмы приведены для случая моделей с комплексными параметрами. Однако исторически квазиньютоновские методы были первоначально предложены для решения задач оптимизации с вещественными параметрами [davidon1959variable]. Позже квазиньютоновские методы были перенесены на пространство комплексных переменных с использованием производных Виртингера [sorber2012unconstrained].

В качестве примера рассмотрим метод BFGS в пространстве вещественных векторов. В данном случае метод производит оценку шага классического метода Ньютона, где матрица $\mathbf{H}_k \in \mathbb{R}^{K \times K}$ оценивает обратную матрицу вторых производных $(\mathbf{H}_{z,z} J)^{-1} \in \mathbb{R}^{K \times K}$. Приращение шага параметров и градиенты представлены соответственно:

$$\begin{aligned} \mathbf{s}_k &= \mathbf{z}_{k+1} - \mathbf{z}_k \in \mathbb{R}^{K \times 1} \\ \mathbf{f}_k &= (D_{\mathbf{z}_{k+1}} J)^T - (D_{\mathbf{z}_k} J)^T \in \mathbb{R}^{K \times 1}. \end{aligned}$$

Условие эрмитовости оценки обратной матрицы Гёссе (4.6.1) сводится к условию симметричности:

$$\mathbf{H}_k = \mathbf{H}_k^T. \quad (4.7.1)$$

В результате, разностное уравнение оценки обратной матрицы Гёссе выражается по аналогии с (4.6.2), (4.6.3):

$$\mathbf{H}_{k+1} = (\mathbf{I} - \rho_k \mathbf{s}_k \mathbf{f}_k^T) \mathbf{H}_k (\mathbf{I} - \rho_k \mathbf{f}_k \mathbf{s}_k^T) + \rho_k \mathbf{s}_k \mathbf{s}_k^T, \quad (4.7.2)$$

$$\rho_k = \frac{1}{\mathbf{f}_k^T \mathbf{s}_k}. \quad (4.7.3)$$

Отметим, что также как и для метода BFGS построенного для решения задачи оптимизации комплексных параметров, для вещественного BFGS важнейшим условием сходимости является выполнение неравенства $\mathbf{f}_k^T \mathbf{s}_k > 0$ гарантирующего уменьшение функции потерь в задаче минимизации [pract_optimiz].

5. Математические модели линейных и нелинейных искажений в системах связи

В этом разделе изложена теория, необходимая для реализации рассмотренных алгоритмов адаптации. Рассмотренные модели нелинейных искажений делятся на голоморфные по параметрам модели $\mathbf{y} = \mathbf{y}(\mathbf{x}, \mathbf{z})$ и неголоморфные $\mathbf{y} = \mathbf{y}(\mathbf{x}, \mathbf{z}, \mathbf{z}^*)$, $\mathbf{y} \in \mathbb{C}^{N \times 1}$ – выходные отсчеты модели.

К голоморфным моделям применимы методы адаптации на основе градиентного спуска и его модификации 2.1, 2.2, метод Ньютона и его модификации 3.1, 3.2, смешанный метод Ньютона 3.3 и методы построенные на его основе 4.1, 4.2, а также квазиньютоновские методы 4.3.

Для реализации смешенного метода Ньютона, а также методов, построенных на его основе достаточно вычислить матрицу $D_{\mathbf{z}} \mathbf{y}$ – якобиан выхода голоморфной модели по параметрам модели (2.1.10), (3.3.3). В связи с этим данным разделе основной целью рассмотрения голоморфных моделей является аналитический вывод матрицы $D_{\mathbf{z}} \mathbf{y}$.

К неголоморфным моделям применимы методы адаптации на основе градиентного спуска и его модификации 2.1, 2.2, метод Ньютона и его модификации 3.1, 3.2, а также квазиньютоновские методы 4.3. Отметим также, что методы на основе аппроксимации шага метода Ньютона (метод сопряженных градиентов, покоординатный спуск и др.) реализуемы в рамках решения задачи адаптации неголоморфных моделей. Тем не менее, данная работа фокусируется на исследовании алгоритмов адаптации голоморфных моделей ввиду их малой вычислительной сложности. По этой причине методы аппроксимации метода Ньютона для неголоморфных моделей не рассматриваются.

Для реализации метода Ньютона для неголоморфных моделей (3.1.17) необходимо вычисление 6 матриц $D_{\mathbf{z}} \mathbf{y}$, $D_{\mathbf{z}^*} \mathbf{y}$, $D_{\mathbf{z}} \text{vec}(D_{\mathbf{z}^*} \mathbf{y})^T$, $D_{\mathbf{z}} \text{vec}(D_{\mathbf{z}^*} \mathbf{y})^H$, $D_{\mathbf{z}^*} \text{vec}(D_{\mathbf{z}} \mathbf{y})^T$, $D_{\mathbf{z}^*} \text{vec}(D_{\mathbf{z}} \mathbf{y})^H$. Ввиду громоздкости аналитического вывода последних 4-х структур для неголоморфных моделей, в данном разделе рассматривается аналитический вывод матриц $D_{\mathbf{z}} \mathbf{y}$, $D_{\mathbf{z}^*} \mathbf{y}$, вычисления которых является достаточным для построения градиентных и квазиньютоновских методов.

5.1 Линейная модель искажений сигнала в системах связи

Одним из видов линейных по параметрам моделей в адаптивной обработке сигналов является КИХ-фильтр, фильтр с конечной импульской характеристикой. КИХ-фильтр описывается набором комплексных коэффициентов $\{w_k \in \mathbb{C}\}_{k=0}^{M-1}$, которые можно представить в векторной форме $\mathbf{w} = \{w_k\}_{k=0}^{M-1}$, здесь $M = 2D + 1$ – порядок

фильтра. Выход КИХ-фильтра описывается линейной свёрткой `[dsp_layons]`:

$$y_n = \sum_{k=-D}^D w_k x_{n-k}. \quad (5.1.1)$$

В векторном виде выход КИХ-фильтра будет иметь следующий вид:

$$y_n = \mathbf{u}_n^T \mathbf{w} = \begin{pmatrix} x_{n+D} & x_{n+D-1} & \cdots & x_{n-D} \end{pmatrix} \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_{M-1} \end{pmatrix}, \quad (5.1.2)$$

где $\mathbf{u}_n$ – вектор состояния КИХ-фильтра M -ого порядка в момент времени n :

$$\mathbf{u}_n^T = \begin{pmatrix} x_{n+D} & x_{n+D-1} & \cdots & x_{n-D} \end{pmatrix}. \quad (5.1.3)$$

Рассмотрим последовательность из N комплексных отсчетов сигнала на входе фильтра:

$$\mathbf{x} = \{x_n \in \mathbb{C}\}_{n=0}^{N-1}. \quad (5.1.4)$$

Введём матрицу состояния `[adapt_filt_haykin]` фильтра $\mathbf{U} \in \mathbb{C}^{N \times M}$:

$$\mathbf{U} = \begin{pmatrix} \mathbf{u}_0^T \\ \mathbf{u}_1^T \\ \vdots \\ \mathbf{u}_{N-2}^T \\ \mathbf{u}_{N-1}^T \end{pmatrix} = \begin{pmatrix} x_D & \cdots & x_1 & x_0 & 0 & \cdots & 0 \\ x_{D+1} & \cdots & x_2 & x_1 & x_0 & \cdots & 0 \\ \vdots & & & \ddots & & & \vdots \\ 0 & \cdots & x_{N-1} & x_{N-2} & x_{N-3} & \cdots & x_{N-D-2} \\ 0 & \cdots & 0 & x_{N-1} & x_{N-2} & \cdots & x_{N-D-1} \end{pmatrix}. \quad (5.1.5)$$

Тогда отсчеты на выходе фильтра можно получить в виде векторно-матричного произведения:

$$\mathbf{y} = \mathbf{U} \mathbf{w}. \quad (5.1.6)$$

Матрица состояния фильтра в уравнении (5.1.6) учитывает задержку фильтра D_{FIR} равную половине длины фильтра. Такой способ выражения выходных отсчетов фильтра предлагается для того чтобы сохранить неизменными размерности векторов $\mathbf{y} \in \mathbb{C}^{N \times 1}$ и $\mathbf{x} \in \mathbb{C}^{N \times 1}$, что в дальнейшем будет необходимо для реализации численных алгоритмов.

Ввиду того, что изначально при симуляции алгоритмов адаптации неизвестна задержка сигнала $\mathbf{x}$ передатчика от сигнала помехи $\mathbf{d}$, то не имеет значение, какой именно задавать задержку D_{FIR} . Для выравнивания отсчётов передатчика относительно отсчётов приёмника по времени, предлагается задать D_{FIR} равной половине длины фильтра, поскольку такая структура позволит описать как минимальнофазовые, так и линейно-фазовые каналы распространения помехи `[dsp_oppenheim]`.

Якобиан выхода модели по параметрам вычисляется из выражения:

$$d\mathbf{y} = D_{\mathbf{w}} \mathbf{y} d\mathbf{w} = \mathbf{U} d\mathbf{w}. \quad (5.1.7)$$

Таким образом, для адаптивного КИХ-фильтра якобиан имеет вид матрицы состояния:

$$D_{\mathbf{w}} \mathbf{y} = \mathbf{U}. \quad (5.1.8)$$

Отметим, что метод LS 3.4 находит оптимальные параметры КИХ-фильтра за 1 шаг. При этом матрица Гессе представляет собой оценку корреляционной матрицы КИХ-фильтра:

$$H_{\mathbf{z}, \mathbf{z}^*} J = \check{\mathbf{R}}_{xx} \equiv \check{\mathbb{E}} \left(\mathbf{u}_n^* \mathbf{u}_n^T \right) = \mathbf{U}^H \mathbf{U}, \quad (5.1.9)$$

а градиент является оценкой кросс-корреляционного вектора сигнала и ошибки адаптации:

$$(D_{\mathbf{z}^*} J)^T = \check{\mathbf{r}}_{xe} \equiv \check{\mathbb{E}} \left(\mathbf{u}_n^* e_n \right) = \mathbf{U}^H \mathbf{e} \quad (5.1.10)$$

Уравнение (5.1.9), (5.1.10) отражают итеративный способ накопления корреляционной матрицы и кросс-корреляционного вектора:

$$\check{\mathbf{R}}_{xx,n} = \check{\mathbf{R}}_{xx,n-1} + \mathbf{u}_{n-1}^* \mathbf{u}_{n-1}^T, \quad (5.1.11)$$

$$\check{\mathbf{r}}_{xe,n} = \check{\mathbf{r}}_{xe,n-1} + \mathbf{u}_{n-1}^* e_{n-1} \quad (5.1.12)$$

В данном случае оценка тем ближе к истинному значению матожидания, чем больше отсчетов сигнала поступило на вход системы. Такой подход связан с реализацией стохастических методов и успешно применяется в случае потоковой обработки сигнала.

Отметим, также, что корреляционная матрица является эрмитовой, поскольку из (5.1.9) видно, что:

$$\mathbf{R}_{xx} = \mathbf{R}_{xx}^H \succcurlyeq 0 \quad (5.1.13)$$

Корреляционная матрица `[adapt_filt_haykin]` является центральным объектом при построении алгоритмов адаптации линейных фильтров.

5.2 Полиномиальная модель нелинейных искажений в системах связи

Существует множество моделей, аппроксимирующих нелинейность усилителей мощности `[pa_models]`, таких как модель Винера, Гаммерштейна, Винера-Гаммерштейна, а также полиномиальные модели с памятью и без памяти `[dpd_models]`. Перечисленные модели являются следствием упрощения ряда Вольтерра.

Основной моделью паразитных нелинейных помех в приёмном тракте мобильного терминала является модель Гаммерштейна, описанная в разделе 5.5. Поскольку мо-

дель содержит КИХ-фильтр, который помимо задержек распространения помехи по различным путям от приёмника к передатчику учитывает инерционность усилителя мощности, то модель усилителя мощности можно выбирать безынерционной. Среди перечисленных моделей нелинейности усилителя безынерционной является полиномиальная модель без памяти.

В данном разделе рассматриваются две основные модели нелинейности: полиномиальная модель без памяти, а также метод улучшения численной устойчивости при адаптации этой модели, и модель кусочно-линейной аппроксимации.

Перед тем, как рассмотреть полиномиальную модель нелинейности усилителя мощности, рассмотрим общий способ описания нелинейной амплитудной характеристики.

На вход нелинейной модели поступает последовательность из N отсчетов модуля входного сигнала $\{|x_n|\}_{n=0}^{N-1}$. Общая модель нелинейности описывается выражением [dpd_models]:

$$s_n = f(x_n) = g(|x_n|)x_n = \left[\sum_{p=0}^{P-1} h_p \varphi_p(|x_n|) \right] x_n, \quad (5.2.1)$$

где $\{\varphi_p(|x|)\}_{p=0}^{P-1}$ – набор базисных функций модели нелинейности, P – порядок нелинейности. Выражение (5.2.1) учитывает тот факт, что нелинейное искажение сигнала на выходе усилителя рассматривается на несущей частоте сигнала передатчика, поэтому множитель x_n линейно входит в выражение для выхода нелинейности.

Рассмотрим полиномиальную модель без памяти, описывающую нелинейность усилителя мощности. Базисные функции полиномиальной модели без памяти имеют вид [dpd_models]:

$$\varphi_p(|x_n|) = |x_n|^p, \quad (5.2.2)$$

тогда модель нелинейности будет иметь вид:

$$g(|x_n|) = \sum_{p=0}^P h_p |x_n|^p. \quad (5.2.3)$$

В случае использования данной модели для описания нелинейной характеристики АМ-АМ [dpd_models] усилителя мощности на выходе нелинейной модели будут отсчеты:

$$s_n = g(|x_n|)x_n = \left[\sum_{p=0}^P h_p |x_n|^p \right] x_n, \quad (5.2.4)$$

в векторной форме выходные отсчеты нелинейности будут иметь вид:

$$\begin{aligned} s_n &= \mathbf{h}_n^T \mathbf{v}_n = \begin{pmatrix} h_0 & h_1 & \cdots & h_{P-1} \end{pmatrix} \begin{pmatrix} x_n \varphi_0(|x_n|) & x_n \varphi_1(|x_n|) & \cdots & x_n \varphi_{P-1}(|x_n|) \end{pmatrix}^T = \\ &= \begin{pmatrix} h_0 & h_1 & \cdots & h_P \end{pmatrix} \begin{pmatrix} x_n & x_n |x_n| & \cdots & x_n |x_n|^{P-1} \end{pmatrix}^T, \end{aligned} \quad (5.2.5)$$

где $\mathbf{v}$ – вектор состояния модели нелинейности, который вводится по аналогии с вектором состояния фильтра (5.1.3).

Матрицу состояния полиномиальной модели для случая блочной обработки по ограниченной выборке сигнала можно ввести по аналогии с матрицей состояния КИХ-фильтра через вектора состояния (5.1.5):

$$\mathbf{V} = \begin{pmatrix} \mathbf{v}_0^T \\ \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_{N-1}^T \end{pmatrix} = \begin{pmatrix} x_0 & x_0|x_0| & \cdots & x_0|x_0|^{P-1} \\ x_1 & x_1|x_1| & \cdots & x_1|x_1|^{P-1} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N-1} & x_{N-1}|x_{N-1}| & \cdots & x_{N-1}|x_{N-1}|^{P-1} \end{pmatrix}. \quad (5.2.6)$$

Таким образом, выход нелинейной модели в матричном виде описывается выражением:

$$\mathbf{s} = \mathbf{V}\mathbf{h}. \quad (5.2.7)$$

В связи с этим, якобиан выхода модели по адаптивным параметрам может быть вычислен из выражения:

$$d\mathbf{s} = D_{\mathbf{h}}\mathbf{s}d\mathbf{h} = \mathbf{V}d\mathbf{h}. \quad (5.2.8)$$

Таким образом, для адаптивного КИХ-фильтра якобиан имеет вид матрицы состояния:

$$D_{\mathbf{h}}\mathbf{s} = \mathbf{V}. \quad (5.2.9)$$

Отметим, что матрица Гессе полиномиальной модели $H_{\mathbf{h},\mathbf{h}^*}J = \mathbf{V}^H\mathbf{V}$ является плохо обусловленной для высоких значений степеней полинома $P \gg 1$.

Для улучшения обусловленности гессиана модели используются ортогональные полиномы. Использование ортогональных полиномов позволяет повысить порядок полинома вплоть до $P = 100$ с сохранением численной устойчивости алгоритмов адаптации. В случае полиномиальной модели без памяти базисные функции будут иметь вид `[dpd_models]`:

$$\varphi_p(|x_n|) = P_p(|x_n|^p). \quad (5.2.10)$$

Полиномы Лежандра `[spec_func]`:

$$P_{p+1}(x) = \frac{2p+1}{p+1}xP_p(x) - \frac{p}{p+1}P_{p-1}(x), \quad (5.2.11)$$

$$P_0(x) = 1, P_1(x) = x,$$

являются ортогональными на отрезке $[-1; 1]$.

Полиномы Чебышёва 1-ого рода `[spec_func]`:

$$T_{p+1}(x) = 2xT_p(x) - T_{p-1}(x),$$

$$(5.2.12)$$

$$T_0(x) = 1, T_1(x) = x,$$

являются ортогональными на отрезке $[-1; 1]$. Кроме того, полином Чебышёва 1-ого рода степени n меньше всего отклоняется от нуля на отрезке $[-1; 1]$ среди полиномов степени n .

Полиномы Чебышёва 2-ого рода `[spec_func]`:

$$U_{p+1}(x) = 2xU_p(x) - U_{p-1}(x),$$

$$(5.2.13)$$

$$U_0(x) = 1, U_1(x) = 2x,$$

являются ортогональными на отрезке $[-1; 1]$. Кроме того, интеграл модуля полинома Чебышёва 2-ого рода степени n меньше всего отклоняется от нуля на отрезке $[-1; 1]$ среди полиномов степени n .

Полиномы Эрмита `[spec_func]`:

$$H_{p+1}(x) = 2xH_p(x) - 2pH_{p-1}(x),$$

$$(5.2.14)$$

$$H_0(x) = 1, H_1(x) = 2x,$$

являются ортогональными на всей числовой оси.

5.3 Модель нелинейных искажений в системах связи на основе сплайновых полиномов

Полином на основе сплайнов первого порядка реализует кусочно-линейную интерполяцию при построении нелинейной модели. Данный вид базисных функций эффективен с точки зрения числа операций, осуществляемых в единицу времени при вычислении значений полинома. В связи с этим, метод кусочно-линейной аппроксимации активно используется в цифровой технике для аппроксимации выходных характеристик нелинейных компонент, таких как аналоговые усилители мощности, дуплексеры и другие `[dpsd_lut]`.

Кусочно-линейная функция может быть задана, как на рис. 6. Здесь расстояние между отсчетами коэффициентов h_k равно 1.

Обозначим Δ_n – расстояние между модулем входного отсчета $|x_n|$ и ближайшим целым $p < |x_n|$ по оси абсцисс, h_p – отсчет с координатой p по оси абсцисс. Тогда

$$\frac{\Delta_n}{1} = \frac{g(|x_n|) - h_p}{h_{p+1} - h_p},$$

$$(5.3.1)$$




Рис. 6. Кусочно-линейная функция $g(|x_n|)$ сплайнового полинома

$$g(|x_n|) = \Delta_n h_{p+1} + (1 - \Delta_n) h_p. \quad (5.3.2)$$

Подставим выражение (5.3.2) в выражение для выходных отсчетов нелинейности (5.2.1) и перепишем в виде скалярного произведения векторов:

$$s_n = \mathbf{v}_n^T \mathbf{h} = \begin{pmatrix} 0 & \dots & 0 & (1 - \Delta_n)x_n & \Delta_n x_n & 0 & \dots & 0 \end{pmatrix} \cdot \begin{pmatrix} h_0 & \dots & h_{p-1} & h_p & h_{p+1} & h_{p+2} & \dots & h_{P-1} \end{pmatrix}^T, \quad (5.3.3)$$

где $\mathbf{v}_n^T$ – строка матрицы состояния модуля, которая представляет собой вектор состояния модуля кусочно-линейной аппроксимации:

$$\mathbf{v}_n^T = \begin{pmatrix} 0 & \dots & 0 & (1 - \Delta_n)x_n & \Delta_n x_n & 0 & \dots & 0 \end{pmatrix}. \quad (5.3.4)$$

Полная матрица состояния может быть раписана следующим образом:

$$\mathbf{V} = \begin{pmatrix} \mathbf{v}_0^T \\ \mathbf{v}_1^T \\ \vdots \\ \mathbf{v}_{N-1}^T \end{pmatrix} = \begin{pmatrix} 0 & \dots & 0 & (1 - \Delta_0)x_n & \Delta_0 x_n & 0 & \dots & 0 \\ 0 & \dots & (1 - \Delta_1)x_n & \Delta_1 x_n & 0 & 0 & \dots & 0 \\ \vdots & & & \ddots & & & & \vdots \\ 0 & \dots & 0 & (1 - \Delta_{N-1})x_n & \Delta_{N-1} x_n & 0 & \dots & 0 \end{pmatrix} \quad (5.3.5)$$

Вектор выходных отсчетов $\mathbf{z}$ может быть раписан:

$$\mathbf{s} = \mathbf{V} \mathbf{h}. \quad (5.3.6)$$

Отметим также, что кусочно-линейная функция, аппроксимирующая нелинейную амплитудную характеристику усилителя мощности может быть представлена через

базисные функции (5.2.1) следующего вида `[dpd_lut]`:

$$\varphi_p(|x_n|) = \begin{cases} |x_n| - (p - 1), & \text{если } (p - 1 \leq |x_n| < p) \vee (0 < p \leq P - 1), \\ -|x_n| + (p + 1), & \text{если } (p \leq |x_n| < p + 1) \vee (0 \leq p < P - 1). \end{cases} \quad (5.3.7)$$

5.4 Модель Вольтерра нелинейных искажений в системах связи

Модель Вольтерра представляет собой наиболее общую модель нелинейной адаптивной обработки сигналов и является функциональным обобщением линейной свертки `[volterra1959theory, schetzen1980volterra, mathews1991adaptive]`. Для комплекснозначных сигналов выходной отсчёт s_n выражается через входной сигнал x_n в виде обобщённого функционального ряда:

$$s_n = \sum_{p=0}^P \sum_{q=0}^p \sum_{d_1=0}^{D-1} \cdots \sum_{d_p=0}^{D-1} h_{p,q,d_1,\dots,d_p} \prod_{j=1}^q x_{n-d_j} \prod_{j=q+1}^p x_{n-d_j}^*, \quad (5.4.1)$$

где: $h_{p,q,d_1,\dots,d_p}$ – ядро Вольтерры (p, q) -го порядка, P – порядок нелинейности, то есть максимальная степень нелинейных членов, D – глубина памяти системы, то есть максимальная задержка, x_{n-d_j} – задержанные входные отсчёты, индекс q определяет количество не сопряжённых членов, $(p - q)$ – количество сопряжённых членов.

Структура ряда включает:

- **Нулевой порядок** ($p = 0$): $h_{0,0}$ – постоянная составляющая
- **Первый порядок** ($p = 1$):
 - $q = 1$: $\sum_{d_1=0}^{D-1} h_{1,1}(d_1)x_{n-d_1}$ – линейная фильтрация
 - $q = 0$: $\sum_{d_1=0}^{D-1} h_{1,0}(d_1)x_{n-d_1}^*$ – линейная фильтрация сопряжённого сигнала
- **Второй порядок** ($p = 2$): включает члены x^2 , xx^* и $(x^*)^2$
- **Высшие порядки** ($p \geq 3$): описывают более сложные нелинейные эффекты

По аналогии с (5.2.1) базисная функция модели Вольтерра представляет собой следующее выражение:

$$\varphi_{p,q,d_1,\dots,d_p}(x_n) = \prod_{j=1}^q x_{n-d_j} \prod_{j=q+1}^p x_{n-d_j}^*. \quad (5.4.2)$$

Такая структура позволяет полностью описать нелинейные системы с памятью включая эффекты взаимного влияния квадратурных составляющих.




Рис. 7. Модель Гаммерштейна

5.5 Модель Гаммерштейна нелинейных искажений в системах связи

Модель Гаммерштейна является частным случаем модели Вольтерра (5.4.1) и представляет собой двухслойную модель. Первый слой модели описывает нелинейные искажения сигнала, обусловленные нелинейной характеристикой передатчика, второй слой описывает линейные искажения, обусловленные многолучевым распространением сигнала и передатчика в приёмник. В связи с этим, модель является эффективной в задачах компенсации нелинейных помех в приёмнике приемопередающих устройств [mnm_paper_alex_degt].

Модель состоит из последовательно соединенных нелинейного блока и адаптивного КИХ-фильтра. Нелинейный блок может быть представлен любой моделью, нелинейной по входному сигналу, включая полиномиальную модель без памяти (5.2.5), сплайновый полином (5.3.3) и другие. Схема модели Гаммерштейна представлена на рис. 7.

Выход модели Гаммерштейна представлен выражением:

$$y_n = \sum_{m=-D}^D w_m \sum_{p=0}^{P-1} h_p x_{n-m} \varphi_p(|x_{n-m}|), \quad (5.5.1)$$

где $\mathbf{h} \in \mathbb{C}^{P \times 1}$ – адаптивные параметры блока нелинейности, P – порядок полинома, параметры адаптивного КИХ-фильтра [haykin] $\mathbf{w} \in \mathbb{C}^{M \times 1}$, $M = 2D + 1$ – число адаптивных коэффициентов фильтра, $\{\varphi_p(\cdot)\}_{p=0}^{P-1}$ – базисные функции нелинейности.

Представим общий вектор параметров модели Гаммерштейна следующим образом:

$$\mathbf{z} = \begin{pmatrix} \mathbf{h} \\ \mathbf{w} \end{pmatrix}, \mathbf{z}^* = \begin{pmatrix} \mathbf{h}^* \\ \mathbf{w}^* \end{pmatrix} \in \mathbb{C}^{(P+L) \times 1}. \quad (5.5.2)$$

Якобиан выходного вектора модели Гаммерштейна по параметрам представлен выражением:

$$D_{\mathbf{z}} \mathbf{y} = \begin{pmatrix} D_{\mathbf{h}} \mathbf{y} & D_{\mathbf{w}} \mathbf{y} \end{pmatrix} \in \mathbb{C}^{N \times (P+L)}. \quad (5.5.3)$$

Таким образом, для подсчета матрицы Гёссе и градиента целевой функции необходимо вычислить производную выходного вектора модели по параметрам слоя нелинейности и КИХ-фильтра.

Согласно теории адаптивной фильтрации [haykin] вектор выходных отсчётов

КИХ-фильтра может быть выражен через матрицу состояния $\mathbf{U}$ (5.1.6), где матрица $\mathbf{U}$ заполнена задержанными отсчетами $s_n = g(|x_n|)x_n$ выхода нелинейного слоя (5.2.1). Тогда производная выхода модели по параметрам фильтра выражается через матрицу состояния фильтра (5.1.8):

$$D_{\mathbf{w}}\mathbf{y} = \mathbf{U} = \mathbf{U}(\mathbf{s}). \quad (5.5.4)$$

Согласно (5.2.7), (5.3.6) выход нелинейной модели выражается через матрично-векторное произведение матрицы состояния $\mathbf{V}$ и параметров нелинейности $\mathbf{h}$. Тогда выход модели Гаммерштейна можно представить как:

$$\mathbf{y} = \text{conv}_{\mathbf{w}}(\mathbf{s}) = \text{conv}_{\mathbf{w}}(\mathbf{V}\mathbf{h}), \quad (5.5.5)$$

где $\text{conv}_{\mathbf{w}}(\cdot)$ — одномерный линейный оператор свёртки. Запишем матрицу состояния через её столбцы:

$$\mathbf{V} = \begin{pmatrix} \mathbf{v}_0 & \mathbf{v}_1 & \cdots & \mathbf{v}_{P-1} \end{pmatrix}, \quad (5.5.6)$$

тогда входной вектор фильтра (5.2.7), (5.3.6) $\mathbf{s}$ может быть выражен как:

$$\mathbf{s} = h_0\mathbf{v}_0 + h_1\mathbf{v}_1 + \cdots + h_{P-1}\mathbf{v}_{P-1}. \quad (5.5.7)$$

Используя свойство линейности свёртки из уравнений (5.5.7) и (5.5.5) получаем выход модели Гаммерштейна через матрично-векторное умножение:

$$\begin{aligned} \mathbf{y} &= \text{conv}_{\mathbf{w}}(h_0\mathbf{v}_0 + \cdots + h_{P-1}\mathbf{v}_{P-1}) = h_0\text{conv}_{\mathbf{w}}(\mathbf{v}_0) + \cdots + h_{P-1}\text{conv}_{\mathbf{w}}(\mathbf{v}_{P-1}) = \\ &= \begin{pmatrix} \text{conv}_{\mathbf{w}}(\mathbf{v}_0) & \cdots & \text{conv}_{\mathbf{w}}(\mathbf{v}_{P-1}) \end{pmatrix} \mathbf{h} \equiv \mathbf{V}_f\mathbf{h}. \end{aligned} \quad (5.5.8)$$

Таким образом, выходной вектор модели Гаммерштейна выводится через произведение матрицы состояния нелинейности, фильтрованной по столбцам, и вектора параметров нелинейности. Отметим, что матрица $\mathbf{V}_f$ не зависит от параметров полинома $\mathbf{h}$.

В результате, используя уравнение (5.5.8), получаем производную выхода модели по параметрам нелинейности:

$$D_{\mathbf{h}}\mathbf{y} = D_{\mathbf{h}}(\mathbf{V}_f\mathbf{h}) = \mathbf{V}_f. \quad (5.5.9)$$

Подставляя (5.5.4), (5.5.9) в (5.5.3) получаем финальное выражение производной выхода модели Гаммерштейна по общему вектору параметров (5.5.2):

$$D_{\mathbf{z}}\mathbf{y} = \begin{pmatrix} \mathbf{U} & \mathbf{V}_f \end{pmatrix} \in \mathbb{C}^{N \times (P+M)}. \quad (5.5.10)$$




Рис. 8. Модель Винера

5.6 Модель Винера нелинейных искажений в системах связи

Модель Винера представляет собой двухслойную модель, описывающую нелинейность с памятью. Первым слоем является КИХ-фильтр описывающий инерционные свойства передающего тракта, второй слой представляет собой нелинейность без памяти, описывающую нелинейный характер передающего тракта. Схема модели Гаммерштейна представлена на рис. 8.

Выход модели Винера представлен выражением:

$$y_n = \sum_{p=0}^{P-1} h_p s_n \varphi_p(|s_n|),$$

$$s_n = \sum_{m=-D}^D w_m x_{n-m} \quad (5.6.1)$$

где $\mathbf{h} \in \mathbb{C}^{P \times 1}$ – адаптивные параметры блока нелинейности, P – порядок полинома, параметры адаптивного КИХ-фильтра [haykin] $\mathbf{w} \in \mathbb{C}^{M \times 1}$, $M = 2D + 1$ – число адаптивных коэффициентов фильтра, $\{\varphi_p(\cdot)\}_{p=0}^{P-1}$ – базисные функции нелинейности.

Представим параметры модели в виде вектора содержащего параметры фильтра и нелинейности (5.5.3) по аналогии с моделью Гаммерштейна.

Заметим, выход модели Винера не является голоморфным относительно параметров КИХ-фильтра $\{w_m\}_{-D}^D$ ввиду наличия операции взятия модуля перед блоком нелинейности:

$$\mathbf{y} = \mathbf{y}(\mathbf{x}, \mathbf{h}, \mathbf{w}, \mathbf{w}^*), \quad (5.6.2)$$

$$d\mathbf{y} = D_{\mathbf{h}} \mathbf{y} d\mathbf{h} + D_{\mathbf{w}} \mathbf{y} d\mathbf{w} + D_{\mathbf{w}^*} \mathbf{y} d\mathbf{w}^*. \quad (5.6.3)$$

В связи с этим (5.6.3) для реализации алгоритмов на основе градиентного спуска (2.1.8) необходимо вычислить матрицы производных по прямым и сопряженным параметрам модели:

$$D_{\mathbf{z}} \mathbf{y} = \begin{pmatrix} D_{\mathbf{h}} \mathbf{y} & D_{\mathbf{w}} \mathbf{y} \end{pmatrix} \in \mathbb{C}^{N \times (P+M)},$$

$$D_{\mathbf{z}^*} \mathbf{y} = \begin{pmatrix} \mathbf{0} & D_{\mathbf{w}^*} \mathbf{y} \end{pmatrix} \in \mathbb{C}^{N \times (P+M)}, \quad (5.6.4)$$

Поскольку нелинейность является выходным слоем модели Винера, то производ-

ная выхода модели по параметрам нелинейности вычисляется как:

$$D_h \mathbf{y} = \mathbf{V} = \mathbf{V}(\mathbf{s}), \quad (5.6.5)$$

где $\mathbf{V}$ – матрица состояния нелинейности, заполненная отсчетами вида $s_n \varphi_p(|s_n|)$, s_n – выходные отсчеты фильтра, $\varphi_p(\cdot)$ – p -я базисная функция нелинейности.

Распишем дифференциал выхода (5.6.3) модели используя структуру модели Винера (5.6.1):

$$\begin{aligned} d\mathbf{y} &= \begin{pmatrix} d[s_n \varphi_0(|s_n|)] & \cdots & d[s_n \varphi_{P-1}(|s_n|)] \\ \vdots & \ddots & \vdots \\ d[s_{n-N+1} \varphi_0(|s_{n-N+1}|)] & \cdots & d[s_{n-N+1} \varphi_{P-1}(|s_{n-N+1}|)] \end{pmatrix} \mathbf{h} + \mathbf{V} d\mathbf{h} \\ &= \mathbf{D} \mathbf{h} + \mathbf{V} d\mathbf{h}. \end{aligned} \quad (5.6.6)$$

Из равенства выражений (5.6.3) и (5.6.6) следует, что первое слагаемое в (5.6.6) содержит компоненты соответствующие производным по параметрам фильтра. Далее будем рассматривать именно это слагаемое для поиска $D_w \mathbf{y}$, $D_w^* \mathbf{y}$.

Рассмотрим один элемент матрицы дифференциалов $\mathbf{D}$ (5.6.6):

$$\begin{aligned} d[s_n \varphi_j(|s_n|)] &= ds_n \varphi_j(|s_n|) + s_n d\varphi_j(|s_n|) = \\ &= \varphi_j(|s_n|) \mathbf{u}_n^T d\mathbf{w} + s_n d\varphi_j(|s_n|), \end{aligned} \quad (5.6.7)$$

где $s_n = \mathbf{u}_n^T \mathbf{w}$ – выходной отсчет фильтра, представленный в виде скалярного произведения вектора состояния (одной строки матрицы состояния $\mathbf{U}$) и параметров фильтра по аналогии с (5.1.6).

Из (5.6.7) следует, что матрица дифференциалов $\mathbf{D}$ разбивается на сумму двух матриц:

$$\mathbf{D} = \mathbf{D}_1 + \mathbf{D}_2, \quad (5.6.8)$$

где $\mathbf{D}_1$ состоит из элементов $\varphi_j(|s_n|) \mathbf{u}_n^T d\mathbf{w}$, $\mathbf{D}_2$ состоит из элементов $s_n d\varphi_j(|s_n|)$.

Из (5.6.6) и (5.6.8) следует, что $\mathbf{D} \mathbf{h} = \mathbf{D}_1 \mathbf{h} + \mathbf{D}_2 \mathbf{h}$. Рассмотрим первое слагаемое:

$$\begin{aligned} \mathbf{D}_1 \mathbf{h} &= \begin{pmatrix} \varphi_0(|s_n|) \mathbf{u}_n^T d\mathbf{w} & \cdots & \varphi_{P-1}(|s_n|) \mathbf{u}_n^T d\mathbf{w} \\ \vdots & \ddots & \vdots \\ \varphi_0(|s_{n-N+1}|) \mathbf{u}_{n-N+1}^T d\mathbf{w} & \cdots & \varphi_{P-1}(|s_{n-N+1}|) \mathbf{u}_{n-N+1}^T d\mathbf{w} \end{pmatrix} \mathbf{h} = \\ &= \begin{pmatrix} \varphi_n^T \mathbf{h} \mathbf{u}_n^T \\ \vdots \\ \varphi_{n-N+1}^T \mathbf{h} \mathbf{u}_{n-N+1}^T \end{pmatrix} d\mathbf{w} = \begin{pmatrix} (y_n/s_n) \mathbf{u}_n^T \\ \vdots \\ (y_{n-N+1}/s_{n-N+1}) \mathbf{u}_{n-N+1}^T \end{pmatrix} d\mathbf{w} = \\ &= \text{diag}(\mathbf{y} \odot \frac{1}{\mathbf{s}}) \mathbf{U} d\mathbf{w}. \end{aligned} \quad (5.6.9)$$

В выкладках (5.6.9) использовались обозначения

$$\begin{pmatrix} \varphi_0(|s_n|) & \cdots & \varphi_{P-1}(|s_n|) \end{pmatrix} \mathbf{h} = \boldsymbol{\varphi}_n \mathbf{h} = (y_n/s_n), \quad (5.6.10)$$

$\mathbf{u}_n \in \mathbb{C}^{M \times 1}$ – вектор состояния фильтра, $\mathbf{u}_n^T \in \mathbb{C}^{1 \times M}$ – строка матрицы состояния фильтра $\mathbf{U}$, $\odot$ – поэлементное произведение векторов, $\text{diag}(\mathbf{x})$ – преобразование вектора $\mathbf{x}$ в диагональную матрицу.

Рассмотрим теперь второе слагаемое в выражении (5.6.7):

$$s_n d\varphi_j(|s_n|) = s_n D_{|s_n|} \varphi_j(|s_n|) d|s_n| = s_n r_{j,n} d|s_n|, \quad (5.6.11)$$

где $r_{j,n}$ – производная базисной функции нелинейности по ее входу. Вычислим дифференциал модуля выходного отсчета фильтра (5.6.11):

$$d|s_n| = d\sqrt{s_n^* s_n} = \frac{s_n ds_n^* + s_n^* ds_n}{2|s_n|} = \frac{s_n \mathbf{u}_n^H d\mathbf{w}^* + s_n^* \mathbf{u}_n^T d\mathbf{w}}{2|s_n|} \quad (5.6.12)$$

Подставим выражение (5.6.12) в (5.6.11):

$$s_n d\varphi_j(|s_n|) = \frac{s_n^2 r_{j,n} \mathbf{u}_n^H d\mathbf{w}^*}{2|s_n|} + \frac{|s_n| r_{j,n} \mathbf{u}_n^T d\mathbf{w}}{2} \quad (5.6.13)$$

Получим выражение для второго слагаемого суммы (5.6.8) используя выражение (5.6.13):

$$\mathbf{D}_2 \mathbf{h} = \text{diag}(\mathbf{s}^2 \odot \frac{1}{2|\mathbf{s}|} \odot \mathbf{R} \mathbf{h}) \mathbf{U}^* d\mathbf{w}^* + \frac{1}{2} \text{diag}(|\mathbf{s}| \odot \mathbf{R} \mathbf{h}) \mathbf{U} d\mathbf{w}, \quad (5.6.14)$$

где $\mathbf{s}^2$, $|\mathbf{s}|$, $1/\mathbf{s}$ – поэлементное возведение в квадрат, взятие модуля и деление соответственно, $\mathbf{R}$ – матрица производных базисных функций по их аргументу:

$$\mathbf{R} = \begin{pmatrix} D_{x_n} \varphi_0(x_n) & \cdots & D_{x_n} \varphi_{P-1}(x_n) \\ \vdots & \ddots & \vdots \\ D_{x_{n-N+1}} \varphi_0(x_{n-N+1}) & \cdots & D_{x_{n-N+1}} \varphi_{P-1}(x_{n-N+1}) \end{pmatrix}. \quad (5.6.15)$$

Объединяя выражения (5.6.9), (5.6.14) в (5.6.8) и учитывая (5.6.3) получаем выражения для производных выхода модели Винера по прямым и сопряженным параметрам фильтра:

$$\begin{aligned} D_{\mathbf{w}} \mathbf{y} &= \text{diag}(\mathbf{y} \odot \frac{1}{\mathbf{s}} + \frac{1}{2} |\mathbf{s}| \odot \mathbf{R} \mathbf{h}) \mathbf{U} \\ D_{\mathbf{w}^*} \mathbf{y} &= \text{diag}(\mathbf{s}^2 \odot \frac{1}{2|\mathbf{s}|} \odot \mathbf{R} \mathbf{h}) \mathbf{U}^*. \end{aligned} \quad (5.6.16)$$

Тогда проивзодные по всем прямыми и сопряженным параметрам модели (5.6.4) мо-




Рис. 9. Модель Винера-Гаммерштейна

гут быть представлены следующим образом:

$$\begin{aligned} D_z \mathbf{y} &= \begin{pmatrix} \mathbf{V} & \text{diag}(\mathbf{y} \odot \frac{1}{s} + \frac{1}{2}|\mathbf{s}| \odot \mathbf{R}\mathbf{h}) \mathbf{U} \end{pmatrix} \in \mathbb{C}^{N \times (P+M)}, \\ D_{z^*} \mathbf{y} &= \begin{pmatrix} \mathbf{0} & \text{diag}(\mathbf{s}^2 \odot \frac{1}{2|\mathbf{s}|} \odot \mathbf{R}\mathbf{h}) \mathbf{U}^* \end{pmatrix} \in \mathbb{C}^{N \times (P+M)}. \end{aligned} \quad (5.6.17)$$

Отметим, что в выражениях (5.6.17) произведение диагональной и квадратной матрицы может быть представлено в виде численно-эффективной операции по-столбцового произведения диагонали и квадратной матрицы:

$$\text{diag}(\mathbf{a})\mathbf{B} = \mathbf{a} \odot \mathbf{B}, \quad (5.6.18)$$

где $\odot$ представляет собой поэлементное произведение вектора $\mathbf{a}$ с каждым столбцом матрицы $\mathbf{B}$. Данная операция не требует хранения диагональной матрицы $\text{diag}(\mathbf{a})$, состоящей преимущественно из нулей.

5.7 Модель Винера-Гаммерштейна нелинейных искажений в системах связи

Модель Винера-Гаммерштейна объединяет в себе преимущества модели Винера 5.6 и модели Гаммерштейна 5.5. Модель является трех-слойной и включает в себя последовательно соединенные адаптивный КИХ-фильтр, описывающий инерционные свойства канала передатчика, безынерционную нелинейность, а также выходной адаптивный КИХ-фильтр, описывающий многолучевое распространение помехи в канале передатчик-приёмник. Модель Винера-Гаммерштейна является эффективной структурой с точки зрения описания как нелинейных искажений возникающих в передатчике приема-передающего устройства, так и паразитных помех, возникающих в приемнике приема-передающего устройства. Схема модели Гаммерштейна представлена на рис. 9.

Выходной отсчет модели Винера-Гаммерштейна представлен выражением:

$$\begin{aligned} y_n &= \sum_{m=-D_2}^{D_2} w_{2,m} \sum_{p=0}^{P-1} h_p g_{n-m} \varphi_p(|g_{n-m}|), \\ g_n &= \sum_{m=-D_1}^{D_1} w_{1,m} x_{n-m}, \end{aligned} \quad (5.7.1)$$

где $\mathbf{h} \in \mathbb{C}^{P \times 1}$ – адаптивные параметры блока нелинейности, P – порядок полинома, $\mathbf{w}_1 \in \mathbb{C}^{M_1 \times 1}$ – параметры входного адаптивного КИХ-фильтра, $M_1 = 2D_1 + 1$ – число адаптивных коэффициентов входного фильтра, $\mathbf{w}_2 \in \mathbb{C}^{M_2 \times 1}$ – параметры выходного адаптивного КИХ-фильтра, $M_2 = 2D_2 + 1$ – число адаптивных коэффициентов выходного фильтра, $\{\varphi_p(\cdot)\}_{p=0}^{P-1}$ – базисные функции нелинейности.

Представим параметры модели в виде вектора содержащего параметры фильтра и нелинейности по аналогии с моделью Винера и моделью Гаммерштейна:

$$\mathbf{z} = \begin{pmatrix} \mathbf{h} \\ \mathbf{w}_1 \\ \mathbf{w}_2 \end{pmatrix}, \mathbf{z}^* = \begin{pmatrix} \mathbf{h}^* \\ \mathbf{w}_1^* \\ \mathbf{w}_2^* \end{pmatrix} \in \mathbb{C}^{(P+M_1+M_2) \times 1}. \quad (5.7.2)$$

Заметим, выход модели Винера-Гаммерштейна не является голоморфным относительно параметров входного КИХ-фильтра $\{w_{1,m}\}_{-D_1}^{D_1}$ ввиду наличия операции взятия модуля перед блоком нелинейности:

$$\mathbf{y} = \mathbf{y}(x, \mathbf{h}, \mathbf{w}_1, \mathbf{w}_1^*, \mathbf{w}_2), \quad (5.7.3)$$

$$d\mathbf{y} = D_{\mathbf{h}}\mathbf{y}d\mathbf{h} + D_{\mathbf{w}_1}\mathbf{y}d\mathbf{w}_1 + D_{\mathbf{w}_1^*}\mathbf{y}d\mathbf{w}_1^* + D_{\mathbf{w}_2}\mathbf{y}d\mathbf{w}_2. \quad (5.7.4)$$

В связи с этим (5.7.4) также как и для модели Винера для реализации алгоритмов на основе градиентного спуска (2.1.8) необходимо вычислить матрицы производных по прямым и сопряженным параметрам модели:

$$\begin{aligned} D_{\mathbf{z}}\mathbf{y} &= \begin{pmatrix} D_{\mathbf{h}}\mathbf{y} & D_{\mathbf{w}_1}\mathbf{y} & D_{\mathbf{w}_2}\mathbf{y} \end{pmatrix} \in \mathbb{C}^{N \times (P+M_1+M_2)}, \\ D_{\mathbf{z}^*}\mathbf{y} &= \begin{pmatrix} 0 & D_{\mathbf{w}_1^*}\mathbf{y} & 0 \end{pmatrix} \in \mathbb{C}^{N \times (P+M_1+M_2)}, \end{aligned} \quad (5.7.5)$$

Выход модели Винера-Гаммерштейна может быть представлен следующим образом:

$$\mathbf{y} = \text{conv}_{\mathbf{w}_2}(\mathbf{s}) = \text{conv}_{\mathbf{w}_2}(\mathbf{V}\mathbf{h}), \quad (5.7.6)$$

тогда дифференциал выхода модели выражается как:

$$d\mathbf{y} = \mathbf{U}_2 d\mathbf{w}_2 + \mathbf{V}_{f, \mathbf{w}_2} d\mathbf{h} + \text{conv}_{\mathbf{w}_2}(d\mathbf{s}), \quad (5.7.7)$$

где $\mathbf{V}_{f, \mathbf{w}_2}$ – матрица состояния нелинейности со столбцами фильтрованными выходным фильтром, получена из условия линейности свертки по аналогии с (5.5.8). Тогда производная выхода модели по параметрам выходного КИХ-фильтра и нелинейности вычисляется аналогично модели Гаммерштейна:

$$D_{\mathbf{w}_2}\mathbf{y} = \mathbf{U}_2 = \mathbf{U}_2(\mathbf{s}), \quad (5.7.8)$$

$$D_{\mathbf{h}}\mathbf{y} = \mathbf{V}_{f, \mathbf{w}_2}, \quad (5.7.9)$$




Рис. 10. Схема нейросетевой модели на основе полносвязного перцептрона

где U_2 – матрица состояния выходного фильтра, заполненная отсчетами s_n , V_{f,w_2} – заполнена выходными отсчетами входного фильтра g_n .

Распишем третье слагаемое суммы (5.7.7):

$$\begin{aligned} \text{conv}_{w_2}(ds) &= \text{conv}_{w_2}(D_{w_1} s dw_1) + \text{conv}_{w_2}(D_{w_1^*} s dw_1^*) = \\ &= (D_{w_1} s)_{f,w_2} dw_1 + (D_{w_1^*} s)_{f,w_2} dw_1^* = \\ &= (D_{w_1} y) dw_1 + (D_{w_1^*} y) dw_1^*. \end{aligned} \quad (5.7.10)$$

Заметим, что $D_{w_1} s$, $D_{w_1^*} s$ – производные выхода нелинейного слоя по параметрам внутреннего фильтра, уже найдены в разделе, посвященном модели Винера (5.6.17). Согласно (5.6.17), (5.7.10) матрицы Якоби выхода модели Винера-Гаммерштейна по параметрам внутреннего фильтра могут быть найдены следующим образом:

$$\begin{aligned} D_{w_1} y &= [\text{diag}(s \odot \frac{1}{g} + \frac{1}{2}|g| \odot Rh) U_1]_{f,w_2} \\ D_{w_1^*} y &= [\text{diag}(g^2 \odot \frac{1}{2|g|} \odot Rh) U_1^*]_{f,w_2}. \end{aligned} \quad (5.7.11)$$

Тогда проивзодные по всем прямыми и сопряженным параметрам модели (5.7.5) выражаются как:

$$\begin{aligned} D_z y &= \left(V_{f,w_2} \quad [\text{diag}(s \odot \frac{1}{g} + \frac{1}{2}|g| \odot Rh) U_1]_{f,w_2} \quad U_2 \right) \in \mathbb{C}^{N \times (P+M_1+M_2)}, \\ D_{z^*} y &= \left(0 \quad [\text{diag}(g^2 \odot \frac{1}{2|g|} \odot Rh) U_1^*]_{f,w_2} \quad 0 \right) \in \mathbb{C}^{N \times (P+M_1+M_2)}, \end{aligned} \quad (5.7.12)$$

5.8 Применение нейросетевых структур для аппроксимации нелинейных искажений приемо-передающего тракта

Схема нейросетевой модели на основе полносвязного перцептрона представлена на рис. 10. Пусть на входе модели матрица $x \in \mathbb{C}^{2C \times M}$, где C – число входных каналов x_{n-d} и $|x_{n-d}|$, M – число отсчетов на одно обновление параметров, то есть длина

блока:

$$\mathbf{x} = \begin{pmatrix} x_n & x_{n-1} & \cdots & x_{n-M+1} \\ x_{n-1} & x_{n-2} & \cdots & x_{n-M} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n-C+1} & x_{n-C} & \cdots & x_{n-C-M+2} \\ |x_n| & |x_{n-1}| & \cdots & |x_{n-M+1}| \\ |x_{n-1}| & |x_{n-2}| & \cdots & |x_{n-M}| \\ \vdots & \vdots & \ddots & \vdots \\ |x_{n-C+1}| & |x_{n-C}| & \cdots & |x_{n-C-M+2}| \end{pmatrix} \in \mathbb{C}^{2C \times M}. \quad (5.8.1)$$

Обозначим число выходных каналов каждого слоя C_j , где $j = \overline{0, L-1}$, L – число слоев модели. Таким образом, полносвязная модель определяется следующей системой:

$$\hat{\mathbf{y}}_j = \sigma_j(\hat{\mathbf{M}}_j \hat{\mathbf{y}}_{j-1} + \hat{\mathbf{b}}_j^T \mathbf{1}_M^T), \quad j = \overline{0, L-1}, \quad (5.8.2)$$

где $\hat{\mathbf{M}}_j \in \mathbb{C}^{C_j \times C_{j-1}}$, $\hat{\mathbf{b}}_j \in \mathbb{C}^{1 \times C_j}$, $j = \overline{0, L-1}$, $\mathbf{1}_M^T = (1 \ 1 \ \cdots \ 1)$, $\sigma_j(\cdot)$ – статическая функция активации без обучаемых параметров. Таким образом в (5.8.3) $\hat{\mathbf{b}}_j^T$ складывается с каждым столбцом матрицы $\hat{\mathbf{M}}_j \hat{\mathbf{y}}_{j-1} \in \mathbb{C}^{C_j \times M}$. Кроме того, отметим, что $C_{L-1} = 1$, т.е. $\hat{\mathbf{M}}_{L-1} \in \mathbb{C}^{1 \times C_{L-2}}$, $\hat{\mathbf{b}}_{L-1} \in \mathbb{C}$ – скаляр, поэтому $\hat{\mathbf{y}} \equiv \mathbf{y}_{L-1} \in \mathbb{C}^{1 \times M}$. Также отметим, что нелинейная функция активации $\sigma_j(\cdot)$ применяется поэлементно. Также отметим, что по определению (5.8.2) входные данные модели представляют собой матрицу $\hat{\mathbf{y}}_{-1} = \mathbf{x} \in \mathbb{C}^{C_{-1} \times M}$, $C_{-1} = 2C$ (5.8.1).

Для простоты выкладок первоначально будем считать, что на внешнем слое модели (5.8.2) функция активации $\sigma_{L-1}(\mathbf{x}) \neq \mathbf{x}$ представляет собой некоторую нелинейную функцию.

Перепишем выражение (5.8.2) в более удобной форме:

$$\mathbf{y}_j = \sigma_j(\mathbf{y}_{j-1} \mathbf{M}_j + \mathbf{1}_M \mathbf{b}_j^T), \quad j = \overline{0, L-1}, \quad (5.8.3)$$

где $\mathbf{y}_j = \hat{\mathbf{y}}_j^T \in \mathbb{C}^{M \times C_j}$, $\mathbf{M}_j = \hat{\mathbf{M}}_j^T \in \mathbb{C}^{C_{j-1} \times C_j}$, $\mathbf{b}_j^T = \hat{\mathbf{b}}_j \in \mathbb{C}^{1 \times C_j}$. Теперь выходной вектор модели $\mathbf{y}_{L-1} \in \mathbb{C}^{M \times 1}$ – представляет собой вектор-столбец и можно пользоваться введенными правилами матричного дифференцирования, представленными в разделе 2.1. Кроме того, размерности обучаемых весов выходного слоя $\mathbf{M}_{L-1} \in \mathbb{C}^{C_{L-1} \times 1}$, $\mathbf{b}_{L-1} \in \mathbb{C}^{1 \times 1}$ – скаляр.

Дифференциал выходного вектора (5.8.3) может быть раписан как:

$$\begin{aligned}
 d\mathbf{y} &\equiv d\mathbf{y}_{L-1} = d\sigma_{L-1}(\mathbf{y}_{L-2}\mathbf{M}_{L-1} + \mathbb{1}_M \mathbf{b}_{L-1}^T) = d\sigma_{L-1}(\mathbf{z}_{L-1}) = \\
 &= \begin{pmatrix} d\sigma_{L-1}(z_{L-1,0}) \\ \vdots \\ d\sigma_{L-1}(z_{L-1,M-1}) \end{pmatrix} = \begin{pmatrix} \sigma'_{L-1}(z_{L-1,0})dz_{L-1,0} \\ \vdots \\ \sigma'_{L-1}(z_{L-1,M-1})dz_{L-1,M-1} \end{pmatrix} = \\
 &= \text{diag}[\sigma'_{L-1}(\mathbf{z}_{L-1})]d\mathbf{z}_{L-1}, \tag{5.8.4}
 \end{aligned}$$

где $\mathbf{z}_{L-1} = \mathbf{y}_{L-2}\mathbf{M}_{L-1} + \mathbb{1}_M \mathbf{b}_{L-1}^T$, $\sigma'_j(\cdot)$ – оператор производной функции $\sigma_j(\cdot)$, который применяется поэлементно к вообще говоря матричному аргументу, $\text{diag}(\cdot)$ – оператор формирования диагональной матрицы из векторного аргумента. Таким образом, $\sigma'_{L-1}(\mathbf{z}_{L-1}) \in \mathbb{C}^{M \times 1}$, $\text{diag}[\sigma'_{L-1}(\mathbf{z}_{L-1})] \in \mathbb{C}^{M \times M}$, $d\mathbf{z}_{L-1} \in \mathbb{C}^{M \times 1}$.

Поскольку $\mathbf{y} \equiv \mathbf{y}_{L-1} \in \mathbb{C}^{M \times 1}$, $d\mathbf{z}_{L-1} \in \mathbb{C}^{M \times 1}$, то выражение (5.8.4) может быть переписано следующим образом:

$$d\mathbf{y} = d\text{vec} \mathbf{y} = \text{diag}[\sigma'_{L-1}(\text{vec} \mathbf{z}_{L-1})]d\text{vec} \mathbf{z}_{L-1}, \tag{5.8.5}$$

где $\text{vec}(\cdot)$ – оператор преобразования вообще говоря матрицы в вектор-столбец; пусть $\mathbf{A} \in \mathbb{C}^{D_1 \times D_2}$, тогда $\text{vec}(\mathbf{A}) \in \mathbb{C}^{D_1 D_2 \times 1}$:

$$\begin{aligned}
 \text{vec}(\mathbf{A}) &= \text{vec} \begin{pmatrix} a_{0,0} & \cdots & a_{0,D_2-1} \\ \vdots & \ddots & \vdots \\ a_{D_1,0} & \cdots & a_{D_1-1,D_2-1} \end{pmatrix} = \\
 &= \begin{pmatrix} a_{0,0} & \cdots & a_{D_1,0} & \cdots & a_{0,D_2-1} & \cdots & a_{D_1-1,D_2-1} \end{pmatrix}^T. \tag{5.8.6}
 \end{aligned}$$

Рапишем дифференциал выражения под функцией активации:

$$\begin{aligned}
 d\text{vec} \mathbf{z}_{L-1} &= d\text{vec}(\mathbf{y}_{L-2}\mathbf{M}_{L-1} + \mathbb{1}_M \mathbf{b}_{L-1}^T) = \\
 &= \text{vec}(d\mathbf{y}_{L-2}\mathbf{M}_{L-1} + \mathbf{y}_{L-2}d\mathbf{M}_{L-1} + \mathbb{1}_M d\mathbf{b}_{L-1}^T) = \\
 &= \text{vec}(\mathbf{I}_M d\mathbf{y}_{L-2}\mathbf{M}_{L-1} + \mathbf{y}_{L-2}d\mathbf{M}_{L-1}\mathbf{I}_{C_{L-1}} + \mathbb{1}_M d\mathbf{b}_{L-1}^T) = \\
 &= \text{vec}(\mathbf{I}_M d\mathbf{y}_{L-2}\mathbf{M}_{L-1}) + \text{vec}(\mathbf{y}_{L-2}d\mathbf{M}_{L-1}\mathbf{I}_{C_{L-1}}) + \text{vec}(\mathbb{1}_M d\mathbf{b}_{L-1}^T\mathbf{I}_{C_{L-1}}), \tag{5.8.7}
 \end{aligned}$$

здесь $\mathbf{I}_M \in \mathbb{R}^{M \times M}$, $\mathbf{I}_{C_{L-1}} \in \mathbb{R}^{C_{L-1} \times C_{L-1}} = \mathbb{R}^{1 \times 1}$ – единичные матрицы, $d\mathbf{y}_{L-2} \in \mathbb{C}^{M \times C_{L-2}}$, $d\mathbf{M}_{L-1} \in \mathbb{C}^{C_{L-2} \times C_{L-1}}$, поэтому $d\mathbf{y}_{L-2} = \mathbf{I}_M d\mathbf{y}_{L-2}$, $d\mathbf{M}_{L-1} = d\mathbf{M}_{L-1}\mathbf{I}_{C_{L-1}}$. Кроме того, в (5.8.7) используем свойство линейности оператора векторизации (5.8.6) [**wirt_deriv**].

Далее используем следующее матричное преобразование для выделения дифференциалов векторов обучаемых параметров [**wirt_deriv_book**]:

$$\text{vec}(\mathbf{A}\mathbf{B}\mathbf{C}) = \left(\mathbf{C}^T \otimes \mathbf{A}\right) \text{vec} \mathbf{B}. \tag{5.8.8}$$

Данное свойство (5.8.8) справедливо для любых прямоугольных матриц $\mathbf{A}$, $\mathbf{B}$, $\mathbf{C}$,

для которых существует произведение $\mathbf{A}\mathbf{B}\mathbf{C}$, т.е. согласуются по размерностям.

Применяя (5.8.8) к (5.8.7), получаем:

$$\begin{aligned} d\text{vec}\mathbf{z}_{L-1} &= (\mathbf{M}_{L-1}^T \otimes \mathbf{I}_M) d\text{vec}\mathbf{y}_{L-2} + \\ &+ (\mathbf{I}_{C_{L-1}} \otimes \mathbf{y}_{L-2}) d\text{vec}\mathbf{M}_{L-1} + (\mathbf{I}_{C_{L-1}} \otimes \mathbf{1}_M) d\mathbf{b}_{L-1}, \end{aligned} \quad (5.8.9)$$

где $\text{vec}(d\mathbf{b}_{L-1}^T) = d\mathbf{b}_{L-1} \in \mathbb{C}^{C_{L-1} \times 1}$.

Подставим выражение (5.8.9) в (5.8.5):

$$\begin{aligned} d\mathbf{y} \equiv d\mathbf{y}_{L-1} &= d\text{vec}\mathbf{y}_{L-1} = \text{diag}[\sigma'_{L-1}(\text{vec}\mathbf{z}_{L-1})] (\mathbf{M}_{L-1}^T \otimes \mathbf{I}_M) d\text{vec}\mathbf{y}_{L-2} + \\ &+ \text{diag}[\sigma'_{L-1}(\text{vec}\mathbf{z}_{L-1})] (\mathbf{I}_{C_{L-1}} \otimes \mathbf{y}_{L-2}) d\text{vec}\mathbf{M}_{L-1} + \\ &+ \text{diag}[\sigma'_{L-1}(\text{vec}\mathbf{z}_{L-1})] (\mathbf{I}_{C_{L-1}} \otimes \mathbf{1}_M) d\mathbf{b}_{L-1} \end{aligned} \quad (5.8.10)$$

Дифференциал выхода полносвязной модели, представленный в форме (5.8.10) позволяет найти производные выхода модели по параметрам выходного слоя $j = L - 1$:

$$\begin{aligned} D_{\text{vec}\mathbf{M}_{L-1}} \mathbf{y} &= \text{diag}[\sigma'_{L-1}(\text{vec}\mathbf{z}_{L-1})] (\mathbf{I}_{C_{L-1}} \otimes \mathbf{y}_{L-2}) \in \mathbb{C}^{C_{L-1} C_{L-2} \times 1} \\ D_{\mathbf{b}_{L-1}} \mathbf{y} &= \text{diag}[\sigma'_{L-1}(\text{vec}\mathbf{z}_{L-1})] (\mathbf{I}_{C_{L-1}} \otimes \mathbf{1}_M) \in \mathbb{C}^{C_{L-1} \times 1}. \end{aligned} \quad (5.8.11)$$

Кроме того, из выражения (5.8.10) видна связь между дифференциалами выходов соседних слоев:

$$d\text{vec}\mathbf{y}_{L-1} = \text{diag}[\sigma'_{L-1}(\text{vec}\mathbf{z}_{L-1})] (\mathbf{M}_{L-1}^T \otimes \mathbf{I}_M) d\text{vec}\mathbf{y}_{L-2} + C. \quad (5.8.12)$$

Таким образом, из выражения для дифференциала выхода модели (5.8.10) по методу математической индукции могут быть доказаны следующие выражения для производных выхода полносвязной модели по параметрам скрытого слоя j :

$$\begin{aligned} D_{\text{vec}\mathbf{M}_j} \mathbf{y} &= \left[\prod_{k=j+1}^{L-1} \text{diag}[\sigma'_k(\text{vec}\mathbf{z}_k)] (\mathbf{M}_k^T \otimes \mathbf{I}_M) \right] \text{diag}[\sigma'_j(\text{vec}\mathbf{z}_j)] (\mathbf{I}_{C_j} \otimes \mathbf{y}_{j-1}) \\ D_{\mathbf{b}_j} \mathbf{y} &= \left[\prod_{k=j+1}^{L-1} \text{diag}[\sigma'_k(\text{vec}\mathbf{z}_k)] (\mathbf{M}_k^T \otimes \mathbf{I}_M) \right] \text{diag}[\sigma'_j(\text{vec}\mathbf{z}_j)] (\mathbf{I}_{C_j} \otimes \mathbf{1}_M), \end{aligned} \quad (5.8.13)$$

где произведение $\prod_{k=j+1}^{L-1} \mathbf{A}_k = \mathbf{A}_{L-1} \cdots \mathbf{A}_{j+2} \mathbf{A}_{j+1}$ раскрывается справа налево.

Изначально предполагалось, что в полносвязной модели на рис. 10 отсутствует выходная функция активации. Данное предположение основано на том, чтобы позволить модели адаптивно подстраиваться под динамический диапазон искаженного сигнала. В выражениях (5.8.13) это может учтено как $\sigma_{L-1}(\mathbf{z}_{L-1}) = \mathbf{z}_{L-1} \in \mathbb{C}^{M \times 1}$, значит $\text{diag}[\sigma'_{L-1}(\mathbf{z}_{L-1})] = \mathbf{I}_M$. В результате, производные (5.8.13) могут быть пере-

писаны в более компактной форме:

$$\begin{aligned} D_{\text{vec} \mathbf{M}_j} \mathbf{y} &= \left[\prod_{k=j+1}^{L-1} (\mathbf{M}_k^T \otimes \mathbf{I}_M) \text{diag}[\sigma'_{k-1}(\text{vec} \mathbf{z}_{k-1})] \right] (\mathbf{I}_{C_j} \otimes \mathbf{y}_{j-1}) \\ D_{\mathbf{b}_j} \mathbf{y} &= \left[\prod_{k=j+1}^{L-1} (\mathbf{M}_k^T \otimes \mathbf{I}_M) \text{diag}[\sigma'_{k-1}(\text{vec} \mathbf{z}_{k-1})] \right] (\mathbf{I}_{C_j} \otimes \mathbf{1}_M). \end{aligned} \quad (5.8.14)$$

5.9 Применение канонического тензорного разложения для аппроксимации многомерной структуры

Рассмотрим двумерную нелинейную структуру описывающую нелинейные искажения, возникающие в двухканальной передатчике. В этом случае нелинейные искажения, возникающие в канале А попадают в канал В и наоборот. Отсчет на выходе двумерного нелинейного преобразования, описывающего такой физический процесс, представляет собой выражение:

$$y_n = g(|x_{n,A}|, |x_{n,B}|)x_n = \left[\sum_{i=0}^{P_2} \sum_{j=0}^{P_1} h_{i,j} \varphi_{i,j}(|x_{n,A}|, |x_{n,B}|) \right] x_{n,A}, \quad (5.9.1)$$

где в качестве примера за основу был взят нелинейный терм $x_{n,A}g(|x_{n,A}|, |x_{n,B}|)$ соответствующий комбинационным составляющим первого порядка `[dpd_models]`, появляющимся в канале А с учетом нелинейных искажений, возникающих в канале В. Элементы двумерного функционального базиса представляют собой произведение одномерных базисных функций:

$$\varphi_{i,j}(|x_{n,A}|, |x_{n,B}|) = \varphi_i(|x_{n,A}|) \varphi_j(|x_{n,B}|). \quad (5.9.2)$$

Из выражения (5.9.1) следует, что число параметров такой адаптивной модели составляет $P_1 P_2$. Таким образом, число параметров растет экспоненциально с ростом числа каналов, что отражает "проклятие размерности" многомерных функций `[bellman1961adap]`.

По аналогии с (5.2.5) выражение для выходного отсчета многомерной модели (5.9.1) может быть представлено через скалярное произведение векторов:

$$\begin{aligned} y_n &= \mathbf{h}^T \mathbf{v}_n = \begin{pmatrix} h_{0,0} & h_{0,1} & \cdots & h_{P_1-1, P_2-1} \end{pmatrix} \cdot \\ &\cdot \begin{pmatrix} x_{n,A} \varphi_0(|x_{n,A}|) \varphi_0(|x_{n,B}|) & x_{n,A} \varphi_0(|x_{n,A}|) \varphi_1(|x_{n,B}|) & \cdots & x_{n,A} \varphi_{P_1-1}(|x_{n,A}|) \varphi_{P_2-1}(|x_{n,B}|) \end{pmatrix}^T = \\ &= \begin{pmatrix} h_{0,0} & h_{0,1} & \cdots & h_{P_1-1, P_2-1} \end{pmatrix} \cdot \\ &\cdot \left[\begin{pmatrix} x_{n,A} \varphi_0(|x_{n,A}|) & \cdots & x_{n,A} \varphi_{P_1-1}(|x_{n,A}|) \end{pmatrix}^T \otimes \begin{pmatrix} x_{n,A} \varphi_0(|x_{n,B}|) & \cdots & x_{n,A} \varphi_{P_2-1}(|x_{n,B}|) \end{pmatrix}^T \right] = \\ &= \mathbf{h}^T (\mathbf{v}_{n,A} \otimes \mathbf{v}_{n,B}) = (\mathbf{v}_{n,A}^T \otimes \mathbf{v}_{n,B}^T) \mathbf{h}, \end{aligned} \quad (5.9.3)$$

где $\mathbf{v}_n \in \mathbb{C}^{P_1 P_2 \times 1}$ – вектор состояния двумерной модели, $\mathbf{v}_{n,A} \in \mathbb{C}^{P_1 \times 1}$, $\mathbf{v}_{n,B} \in \mathbb{C}^{P_2 \times 1}$ – векторы состояния одномерных нелинейных функций, $\mathbf{h} \in \mathbb{C}^{P_1 P_2 \times 1}$ – вектор коэффициентов двумерной модели.

Выходной отсчет двумерной модели (5.9.3) может быть преобразован при помощи (5.8.8). Применяя (5.8.8) к (5.9.3) получаем выражение:

$$y_n = \mathbf{v}_{n,B}^T \mathbf{H} \mathbf{v}_{n,A}, \quad (5.9.4)$$

где $\text{vec}(\mathbf{H}) = \mathbf{h}$, $\mathbf{H} \in \mathbb{C}^{P_1 \times P_2}$ – матрица коэффициентов модели представленная следующим образом:

$$\mathbf{H} = \begin{pmatrix} h_{0,0} & \cdots & h_{P_2-1,0} \\ \vdots & \ddots & \vdots \\ h_{0,P_1-1} & \cdots & h_{P_2-1,P_1-1} \end{pmatrix} \in \mathbb{C}^{P_1 \times P_2} \quad (5.9.5)$$

Заметим, что вектор выходных отсчетов (5.9.4) двумерной нелинейных модели может быть представлен как:

$$\mathbf{y} = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_{N-1} \end{pmatrix} = \begin{pmatrix} \mathbf{v}_{0,B}^T \mathbf{H} \mathbf{v}_{0,A} \\ \mathbf{v}_{1,B}^T \mathbf{H} \mathbf{v}_{1,A} \\ \vdots \\ \mathbf{v}_{N-1,B}^T \mathbf{H} \mathbf{v}_{N-1,A} \end{pmatrix} = \text{diag}(\mathbf{V}_A \mathbf{H} \mathbf{V}_B^T) \in \mathbb{C}^{N \times 1}, \quad (5.9.6)$$

где $\text{diag}(\mathbf{V}_A \mathbf{H} \mathbf{V}_B^T)$ – оператор взятия диагонали квадратной матрицы $\mathbf{V}_A \mathbf{H} \mathbf{V}_B^T \in \mathbb{C}^{N \times N}$, N – длина блока данных, матрицы $\mathbf{V}_A$, $\mathbf{V}_B$ выражаются через их строки следующим образом:

$$\mathbf{V}_A = \begin{pmatrix} \mathbf{v}_{0,A}^T \\ \mathbf{v}_{1,A}^T \\ \vdots \\ \mathbf{v}_{N-1,A}^T \end{pmatrix} \in \mathbb{C}^{N \times P_1}, \quad \mathbf{V}_B = \begin{pmatrix} \mathbf{v}_{0,B}^T \\ \mathbf{v}_{1,B}^T \\ \vdots \\ \mathbf{v}_{N-1,B}^T \end{pmatrix} \in \mathbb{C}^{N \times P_2} \quad (5.9.7)$$

Как было отмечено ранее число адаптивных параметров такой двумерной модели (5.9.6) экспоненциально растет с ростом размерности модели. В данной работе предлагается использовать каноническое тензорное разложение `[matrix_calc]` для уменьшения вычислительных ресурсов требуемых для аппаратной реализации адаптивной модели.

Пусть дана прямоугольная матрица $\mathbf{H} \in \mathbb{C}^{P_1 \times P_2}$ ранга R , тогда существуют вектора $\tilde{\mathbf{h}}_r \in \mathbb{C}^{P_1 \times 1}$, $\mathbf{h}_r \in \mathbb{C}^{P_2 \times 1}$, $r = \overrightarrow{1, R}$, такие что выполняется `[matrix_calc]`:

$$\mathbf{H} = \sum_{r=1}^R \tilde{\mathbf{h}}_r \mathbf{h}_r^T \quad (5.9.8)$$

Подставим выражение (5.9.8) в (5.9.6), получим:

$$\begin{aligned} \mathbf{y} &= \text{diag}(\mathbf{V}_A \mathbf{H} \mathbf{V}_B^T) = \sum_{r=1}^R \text{diag}(\mathbf{V}_A \tilde{\mathbf{h}}_r \mathbf{h}_r^T \mathbf{V}_B^T) = \\ &= \sum_{r=1}^R \text{diag}(\mathbf{V}_A \tilde{\mathbf{h}}_r (\mathbf{V}_B \mathbf{h}_r)^T) = \sum_{r=1}^R \text{diag}(\mathbf{z}_{r,A} \mathbf{z}_{r,B}^T) = \sum_{r=1}^R \mathbf{z}_{r,A} \odot \mathbf{z}_{r,B}, \end{aligned} \quad (5.9.9)$$

где $\mathbf{z}_{r,A} = \mathbf{V}_A \tilde{\mathbf{h}}_r$, $\mathbf{z}_{r,B} = \mathbf{V}_B \mathbf{h}_r$ – выходные векторы одномерных нелинейных моделей, $\text{diag}(\mathbf{z}_{r,A} \mathbf{z}_{r,B}^T) = \mathbf{z}_{r,A} \odot \mathbf{z}_{r,B}$ – диагональ матрицы $\mathbf{z}_{r,A} \mathbf{z}_{r,B}^T$ является поэлементный произведение векторов $\mathbf{z}_{r,A}$, $\mathbf{z}_{r,B}$.

Таким образом, из выражения (5.9.9) следует, что двумерная нелинейная функция с числом параметров $P_1 P_2$ может быть точно представлена суммой произведений одномерных нелинейных функций с общим числом параметров $R(P_1 + P_2)$.

Кроме того, при помощи разложения (5.9.9) многомерную функцию можно аппроксимировать суммой произведений одномерных функций с числом элементов суммы $\tilde{R} \leq R$. Такая малоранговая аппроксимация позволяет найти компромисс между вычислительными ресурсами необходимыми для аппаратной реализации адаптивной модели, а также уровнем компенсации нелинейных искажений.

Отметим, что выход модели (5.9.9) является голоморфным, т.е. не зависит от сопряженных параметров $\tilde{\mathbf{h}}_r^*$, $\mathbf{h}_r^*$. Это значит, что к такой модели применим смешанный метод Ньютона (3.3.4). Кроме того, уравнение итеративного обновления параметров модели по методу градиентного спуска представлено выражением (2.1.10).

Отметим также, что функция потерь MSE (1.5.1) для такой модели (5.9.9) не является квадратичной. В связи с этим, глобальный оптимум вообще говоря не может быть найден методом LS (раздел 3.4) за один шаг.

Обновлении параметров модели (5.9.9) методами смешанного метода Ньютона (3.3.4), градиентного спуска (2.1.10) и др. для голоморфной модели подразумевают вычисление матрицы Якоби $D_z \mathbf{y}$. Получим аналитическое выражение якобиана для рассматриваемой модели.

Заметим, что поэлементное произведение векторов (5.9.9) может быть представлено как векторно-матричное произведение диагональной матрицы и вектора:

$$\begin{aligned} \mathbf{y} &= \sum_{r=1}^R \mathbf{z}_{r,A} \odot \mathbf{z}_{r,B} = \sum_{r=1}^R \text{diag}(\mathbf{z}_{r,A}) \mathbf{z}_{r,B} = \sum_{r=1}^R \text{diag}(\mathbf{V}_A \tilde{\mathbf{h}}_r) \mathbf{V}_B \mathbf{h}_r = \\ &= \sum_{r=1}^R \text{diag}(\mathbf{V}_B \mathbf{h}_r) \mathbf{V}_A \tilde{\mathbf{h}}_r. \end{aligned} \quad (5.9.10)$$

Тогда полный дифференциал выхода модели представлен выражением:

$$\begin{aligned} d\mathbf{y} &= \sum_{r=1}^R \left[D_{\tilde{\mathbf{h}}_r} \mathbf{y} d\tilde{\mathbf{h}}_r + D_{\mathbf{h}_r} \mathbf{y} d\mathbf{h}_r \right] = \\ &= \sum_{r=1}^R \left[\text{diag}(\mathbf{V}_B \mathbf{h}_r) \mathbf{V}_A d\tilde{\mathbf{h}}_r + \text{diag}(\mathbf{V}_A \tilde{\mathbf{h}}_r) \mathbf{V}_B d\mathbf{h}_r \right] \end{aligned} \quad (5.9.11)$$

Из (5.9.11) следуют выражения для якобианов выхода модели по параметрам $\tilde{\mathbf{h}}_r, \mathbf{h}_r$, $r = \overrightarrow{1, R}$:

$$D_{\tilde{\mathbf{h}}_r} \mathbf{y} = \text{diag}(\mathbf{V}_B \mathbf{h}_r) \mathbf{V}_A = \mathbf{V}_B \mathbf{h}_r \odot \mathbf{V}_A \quad (5.9.12)$$

$$D_{\mathbf{h}_r} \mathbf{y} = \text{diag}(\mathbf{V}_A \tilde{\mathbf{h}}_r) \mathbf{V}_B = \mathbf{V}_A \tilde{\mathbf{h}}_r \odot \mathbf{V}_B, \quad (5.9.13)$$

где оператор $\mathbf{a} \odot \mathbf{B}$ между вектором и матрицей подразумевает поэлементное произведение вектора $\mathbf{a}$ с каждым столбцом матрицы $\mathbf{B}$. Такое обозначение эквивалентно $\text{diag}(\mathbf{a})\mathbf{B}$ и введено поскольку $\text{diag}(\mathbf{a})\mathbf{B}$ подразумевает хранение большой матрицы $\text{diag}(\mathbf{a}) \in \mathbb{C}^{N \times N}$, N – длина блока данных, которая в последующих численных экспериментах будет принимать значение $\approx 10^5$. Такой способ вычисления неэффективен по памяти в отличие от поэлементного произведения $\mathbf{a} \odot \mathbf{B}$.

Полная матрица Якоби выхода модели $\mathbf{y} \in \mathbb{C}^{N \times 1}$ по вектору всех параметров модели (5.9.6)

$$\mathbf{z} = \left(\tilde{\mathbf{h}}_1^T \quad \cdots \quad \tilde{\mathbf{h}}_R^T \quad \mathbf{h}_1^T \quad \cdots \quad \mathbf{h}_R^T \right)^T \in \mathbb{C}^{R(P_1+P_2) \times 1} \quad (5.9.14)$$

представлен выражением

$$\begin{aligned} D_{\mathbf{z}} \mathbf{y} &= \left(D_{\tilde{\mathbf{h}}_1} \mathbf{y} \quad \cdots \quad D_{\tilde{\mathbf{h}}_R} \mathbf{y} \quad D_{\mathbf{h}_1} \mathbf{y} \quad \cdots \quad D_{\mathbf{h}_R} \mathbf{y} \right) = \\ &= \left(\mathbf{V}_B \mathbf{h}_1 \odot \mathbf{V}_A \quad \cdots \quad \mathbf{V}_B \mathbf{h}_R \odot \mathbf{V}_A \quad \mathbf{V}_A \tilde{\mathbf{h}}_1 \odot \mathbf{V}_B \quad \cdots \quad \mathbf{V}_A \tilde{\mathbf{h}}_R \odot \mathbf{V}_B \right), \end{aligned} \quad (5.9.15)$$

где $D_{\mathbf{z}} \mathbf{y} \in \mathbb{C}^{N \times R(P_1+P_2)}$.

Отметим также, что Якобиан выхода полной двумерной модели (5.9.3) выражается как

$$D_{\mathbf{z}} \mathbf{y} = (\mathbf{V}_A \otimes \mathbf{1}_{P_B}^T) \odot (\mathbf{1}_{P_A}^T \otimes \mathbf{V}_B) = \mathbf{V}_A \boxtimes \mathbf{V}_B \in \mathbb{C}^{N \times P_1 P_2}, \quad (5.9.16)$$

где $\mathbf{1}_{P_A} \in \mathbb{C}^{P_1 \times 1}$, $\mathbf{1}_{P_B} \in \mathbb{C}^{P_2 \times 1}$ – вектора состоящие из единиц, $\boxtimes$ – построчное произведение Кронекера.

Глава II

Исследование эффективности методов адаптивной компенсации нелинейных искажений в устройствах связи

1. Структура тестовой платформы

В данном разделе описывается тестовая установка, на которой сформирован сигнал, имитирующий нелинейно искаженный сигнал усилителем мощности в передатчике устройства связи.

Измерительная установка состоит из персонального компьютера (ПК), генератора сигналов (ГС) R&S SMW200A, анализатора спектра (АС) R&S FSW85 и испытуемого усилителя мощности ZKY66291-11.

ПК загружает синфазную и квадратурную составляющие базовой полосы (IQ-данные) в ГС, который осуществляет модуляцию, переносит сигнал на несущую частоту $f_{\text{гет}} = 1,8$ ГГц и передает сигнал на вход УМ. Выходной сигнал УМ с нелинейными искажениями поступает на АЦП анализатора спектра с частотой дискретизации $f_s = 245.76$ МГц, выбранной в соответствии со стандартом 5G [3gpp_sample_rate]. После этого IQ-данные базовой полосы передаются в ПК для последующей обработки сигнала на языке программирования Python.

Регулировка входной мощности УМ осуществлялась с помощью ГС. В экспериментах использовался комплексный 20-МГц ортогональный сигнал с частотным мультиплексированием (OFDM) сигнал со 100 ресурсными блоками.

Выделение нелинейно искаженного сигнала на выходе УМ $PA(\mathbf{x})$ из потока цифрового сигнала происходит путём подсчета взаимной корреляции сигнала $PA(\mathbf{x})$ и нелинейного терма передатчика $\mathbf{x} \odot |\mathbf{x}|$, как изображено на рис. 12, где $\mathbf{x} \odot |\mathbf{x}|$ – вектор j -ым элементом которого является отсчет $x_{n-j}|x_{n-j}|$.

Таким образом получены сигнал передатчика $\mathbf{x}$ и сигнал на выходе УМ $PA(\mathbf{x})$. Спектральные плотности мощности этих сигналов изображены на рис. 13а, 13б.




Рис. 11. Установка формирования нелинейных искажений в передатчике устройства связи.




Рис. 12. Модуль функции взаимной корреляции сигнала на выходе УМ $PA(x)$ и нелинейного термина $x \odot |x|$.

2. Формирование тестовых наборов данных

Общая схема формирования нелинейных искажений в сигнале передатчика представлена в разделе 1. В данном разделе рассматриваются схемы формирования данных под конкретные задачи компенсации искажений в устройствах связи.

2.1 Формирование обучающей выборки для задачи компенсации нелинейной помехи в приёмнике полнодуплексной системы связи

Полнодуплексная система связи подразумевает передачу и приём данных в одной и той же полосе частот. Поскольку в реальных устройствах связи существуют




Рис. 13. Спектральная плотность мощности: (а) сигнал, формируемый на передатчике для отправки в канал связи x ; (б) сигнал $PA(x)$, образованный после прохождения сигнала передатчика через усилитель мощности

проблемы в обеспечении изоляции передатчика и приёмника, сигнал передатчика высокой мощности попадает в канал приёмника и ухудшает качество приёма.

Будем считать, что канал распространения помехи передатчик-приёмник линейный. Частотная характеристика этого канала сформирована при помощи программного обеспечения Python в соответствии с данными о реальном канале распространения помехи и представлена на рис. 14а

Для симуляции прохождения нелинейной помехи по различным путям распространения от передатчика к приёмнику производится свёртка массива отсчётов $PA(x)$ с коэффициентами w импульсной характеристики канала:

$$d = \text{conv}_w PA(x) \quad (2.1.1)$$

Таким образом, получаем сигнал d , имитирующий сигнал паразитной помехи передатчика на приёмнике мобильного терминала. Спектральная плотность мощности сигнала паразитной помехи d изображена на рис. 14б.

2.2 Формирование обучающей выборки для задачи компенсации нелинейных комбинационных искажений второго порядка в приёмнике системы связи

Ввиду сложности обеспечения изоляции дуплексного фильтра приемо-передатчики, работающие в режиме частотного разделения каналов, подвержены утечке передаваемого сигнала в приемный тракт. Утечка сигнала в сочетании с нелинейностью маломощного усилителя (МШУ) и смесителя понижения частоты приемника может привести к генерации интермодуляционных искажений второго порядка, что значительно снижает чувствительность приемника на частоте базовой полосы.

Схема генерации нелинейных искажений второго порядка представлена на рис. 15.




Рис. 14. (а) Амплитудно-частотная характеристика канала распространения второй гармоники от передатчика к приёмнику; (б) паразитная помеха на приёмнике d

Экспериментальная установка состоит из компьютера (ПК), усилителя мощности




Рис. 15. Установка формирования нелинейных искажений второго порядка в приёмнике устройства связи.

(УМ) ZRL-3500+. Выход УМ подключен к полосовому фильтру, который представляет собой дуплексный фильтр (ДФ) с подавлением 30 дБ в полосе заграждения. Выход ДФ подключен к маломощному усилителю (МШУ) ZRL-3500+ с коэффициентом усиления 26 дБ. Для преобразования частоты использовался частотный смеситель ZX05-63LN-S+. В передающей и приемной частях дополнительные аналоговые фильтры не использовались.

Для экспериментов использовался комплексный сигнал OFDM с шириной полосы 5 МГц, $f_{Tx} = 814$ МГц, $f_{Rx} = 859$ МГц, дуплексное разделение 45 МГц (5G NR Band 26). Сигнал LTE передается генератором сигналов R&S SMW 200A и усиливается усилителем мощности (УМ). Передаваемый сигнал после нелинейного УМ проникает через полосу заграждения дуплексера с частотным сдвигом 45 МГц относительно




Рис. 16. Спектральная плотность мощности: (а) сигнала передатчика до прохождения нелинейных компонент; (б) на выходе нелинейного УМ $PA(x)$

сигнала гетеродина и усиливается МШУ. Усиленный сигнал генерирует интермодуляционные помехи на выходе частотного смесителя. После понижения частоты сигнал захватывается цифровым осциллографом DSO9254A. Сигнал гетеродина мощностью 10 дБм для ZX05-63LN-S+ формируется генератором сигналов R&S SMW 200A.

Передаваемая мощность на выходе УМ установлена на уровне $P_{Tx} = 8$ дБм, что в сочетании с аттенуацией дуплексного фильтра 30 дБ (при $f_{Tx} = 814$ МГц) и усилением МШУ 26 дБ обеспечивает мощность паразитного сигнала на входе смесителя понижения частоты $P = 8 \text{ дБм} - 30 \text{ дБ} + 26 \text{ дБ} \approx 4 \text{ дБм}$.

Сигнал передатчика x на нулевой частоте, а также сигнал на выходе нелинейного УМ $PA(x)$ изображены на рис. 16. Заметим, что нелинейное искажение второго порядка x^2 формируется за счет нелинейности компонент смесителя. Этот процесс можно формально разделить на 2 шага: формирование 2-ой гармоники x^2 , а затем перенос на несущую частоту передатчика $x^2 e^{j2\pi f_{Tx} t}$. **Уточнить процесс формирования второй гармоники.**

2.3 Формирование обучающей выборки для задачи цифровых предсказаний в передатчике двухканальной системы связи

Система цифрового предсказания для двухканальной системы связи изображена на рис. 17. Цифровые сигналы каналов А и В на нулевой частоте: x_A и x_B соответственно, - проходят через цифровой повышающий преобразователь (ЦПП), преобразовываются в аналоговый сигнал. Затем суммарный двухканальный сигнал переносится на несущую частоту $f_{\text{гет}} = 1990$ МГц. Частотный разнос каналов составляет 300 МГц. Таким образом сигналы каналов А и В находятся на несущих 1840 МГц и 2140 МГц соответственно [NCC2020IS2051]. Спектральная плотность мощности суммарного узкополосного сигнала передатчика на выходе УМ изображена на




Рис. 17. Схема компенсации нелинейных искажений в передатчике двухканальной системы связи.

рис. 18.




Рис. 18. Спектральная плотность мощности двухканального узкополосного сигнала передатчика до прохождения нелинейного УМ.

Суммарный узкополосный сигнал далее проходит через нелинейный УМ и отправляется в петлю обратной связи через направленный ответвитель. Спектральная плотность мощности узкополосного сигнала на выходе УМ изображена на рис. 19.

В петле обратной связи узкополосный сигнал переносится на нулевую частоту, оцифровывается и проходит через цифровой понижающий преобразователь (ЦПП). ЦПП разделяет каналы и переносит их на нулевую частоту. В результате получаем 2 цифровых нелинейно искаженных сигнала передатчика d_A , d_B на нулевой частоте.

В разделе 1.4 главы I показано, что задача компенсации нелинейных искажений в передатчике сводится к идентификации нелинейных искажений на основе исходного сигнала передатчика [dpd_thesis]. Таким образом, обучающая выборка состоит из исходных сигналов передатчика на нулевой частоте x_A , x_B , а также сигналов





Рис. 19. Спектральная плотность мощности двухканального узкополосного сигнала передатчика после прохождения нелинейного УМ.

отклонения выхода УМ от входа:


$$e_A = d_A - x_A$$

$$e_B = d_B - x_B.$$

Спектральные плотности мощности нелинейных искажений на нулевой частоте e_A , e_B изображены на рис. 20.



(а)



(б)

Рис. 20. Спектральная плотность мощности сигнала нелинейных искажений: (а) канал А; (б) канал В

2.4 Формирование обучающей выборки для задачи цифровых предсказаний в передатчике одноканальной системы связи в условиях динамически меняющегося режима работы усилителя мощности

В реальных системах связи для соответствия требованиям протоколов связи [3gpp_36_804] производится динамическое распределение ресурсных блоков в рамках кадра данных в соответствии с реальным трафиком. Это распределение вызывает кратковременные изменения уровня мощности, что, в свою очередь, снижает коэффициент полезного действия (КПД) усилителя мощности. Указанный факт противоречит предположению о работе алгоритма цифрового предсказания в стационарном режиме. Данная проблема исследуется в работе [Dynamic_DPD_RB_Alloc].

В то же время, для повышения энергоэффективности требуется увеличение динамического диапазона входной мощности УМ. Компенсация нелинейных искажений, индуцированных сигналами в широком динамическом диапазоне, требует повторной калибровки коэффициентов модели DPD в реальном времени, что на практике неэффективно с точки зрения распределения ресурсов системы.

Кроме того, переходные процессы, сопровождающие переключение режимов мощности УМ, генерируют нестационарные искажения. Эти искажения, передаваемые по каналу связи, являются причиной кратковременных нарушений протоколов связи и деградации спектральной маски излучаемого сигнала. Как следствие, прямое применение параметров модели DPD, полученных для одного режима мощности УМ, к сигналам другого режима приводит к значительной деградации характеристик системы.

Обучающая выборка для исследования динамического режима работы усилителя мощности состоит из комплексного OFDM сигнала шириной полосы 20 МГц со 100 ресурсными блоками на несущей частоте $f_{LO} = 1.8$ ГГц. Выборка включает в себя $C = 61$ исходных сигналов передатчика в динамическом диапазоне 15 дБ:

$$\begin{aligned} &25.1 \text{ мкВт}, 37.9 \text{ мкВт}, 50.8 \text{ мкВт}, \dots, 794.3 \text{ мкВт} \\ &14.0 \text{ дБмк}, 15.8 \text{ дБмк}, 17.1 \text{ дБмк}, \dots, 29.0 \text{ дБмк}. \end{aligned} \quad (2.4.1a)$$

Им соответствуют $C = 61$ сигналов на выходе УМ в динамическом диапазоне 11.2 дБ:

$$\begin{aligned} &0.069 \text{ Вт}, 0.107 \text{ Вт}, 0.143 \text{ Вт}, \dots, 0.912 \text{ Вт} \\ &-11.6 \text{ дБВт}, -9.7 \text{ дБВт}, -8.4 \text{ дБВт}, \dots, -0.4 \text{ дБВт} \end{aligned} \quad (2.4.2)$$

На рис. 21 изображены распределения входной и выходной мощности УМ в линейном масштабе. Как видно из рис. 21a мощность входного сигнала УМ распределена равномерно. Для исключения смещения модели в процессе её обучения в пользу какого-

либо уровня мощности, входная мощность УМ имеет равномерное распределение во всем динамическом диапазоне. Заметим, что согласно рис. 21б распределение выходной мощности УМ отличается от равномерного ввиду нелинейности характеристики УМ.

figures/data_for_thesis/DPD_dynamic_single

(a)

figures/data_for_thesis/DPD_dynamic_single

(б)

Рис. 21. Динамический диапазон мощности УМ: (а) входная мощность УМ; (б) выходная мощность УМ

На рис. 22 изображены спектральные плотности мощности нормированного входного сигнала УМ 22а и нормированного выходного сигнала УМ 22б для 4-х случаев выходной мощности: -0.4 дБВт, -4.6 дБВт, -8.5 дБВт, -11.6 дБВт. Заметим, что 4-м случаям выходной мощности соответствуют неискаженные сигналы передатчика с мощностями 29.0 дБмк, 21.9 дБмк, 17.1 дБмк, 14.0 дБмк соответственно.

Отметим, что графики СПМ входных сигналов УМ различной мощности совпадают с СПМ на рис. 22а с точностью до смещения в константу раз.

figures/data_for_thesis/DPD_dynamic_single

(a)

figures/data_for_thesis/DPD_dynamic_single

(б)

Рис. 22. Спектральная плотность мощности: (а) входного сигнала УМ; (б) выходного сигнала УМ

3. Исследование алгоритмов и адаптивных моделей компенсации паразитной помехи на приёмнике устройств СВЯЗИ

3.1 Компенсация паразитной помехи на приёмнике полнодуплексной системы связи методом адаптации модели Гаммерштейна

В данном разделе рассматривается задача компенсации паразитных помех, возникающих в приёмнике полнодуплексной системы связи. Процесс возникновения помехи, а также тестовая установка формирования паразитных помех данного типа описаны в разделах 1, 2.1 главы II.

Адаптивная модель [behav_model] компенсации паразитной помехи строится таким образом, чтобы отражать физические процессы возникновения данного рода

помех. Согласно схемы возникновения и компенсации паразитных помех на приёмнике на рис. 3 в сигнал передатчика искажается вследствие нелинейности характеристик усилителя передатчика и дуплексера. Затем сигнал искажается вследствие распространения по каналу TX-RX.

Таким образом, модель Винера-Гаммерштейна [**behav_model**], представленная на рис. 9 отражает процесс возникновения собственной помехи в приёмном тракте и может быть использована для решения задачи идентификации помехи.

Согласно результатам эксперимента, представленным в текущем разделе, эффекты инерционности УМ проявляются слабо. В связи с этим в данном эксперименте использована модель Гаммерштейна (рис. 7), которая является упрощением модели Винера-Гаммерштейна (рис. 9) для случая нелинейных эффектов без памяти.

В качестве нелинейного блока модели Гаммерштейна (5.5.1) выбраны линейные сплайновые полиномы, описанные в разделе 5.3 главы I. Линейно-сплайновые полиномы в данном эксперименте выбраны ввиду его низкой вычислительной сложности и простоты аппаратной реализации [**dpd_models**, **lut_dpd**].

Для экспериментов была выбрана модель Гаммерштейна с адаптивным фильтром с $L = 45$ числом параметров, а также кусочно-линейной функцией, содержащей $P = 8$ сплайнов первого порядка.

Полный набор данных состоит из 80000 отсчётов, 50% из которых используется как тренировочная выборка, остальные отсчёты используются как тестовая выборка.

В данном эксперименте проводится сравнение блочного градиентного спуска (BGD, Block Gradient Descent), стохастического градиентного спуска (SGD, Stochastic Gradient Descent), описанных в разделе 2.1 главы I со смешанным методом Ньютона (раздел 3.3 главы I). Отметим, что ввиду голоморфности выхода модели Гаммерштейна (5.5.1), метод градиентного спуска для адаптации данной модели по методу наименьших квадратов представлен выражением (2.1.10). Отметим также, что в данном эксперименте отличие блочного и стохастического градиентного спуска заключается в формировании блока данных для шага адаптации.

Шаг адаптации смешанного метода Ньютона и блочного градиентного спуска пересчитывается на всей тренировочной последовательности. Другими словами, якобиан выхода модели по параметрам модели $D_z \mathbf{y}$, представленный выражением (5.5.10), а также вектор ошибки $\mathbf{e}$ (2.1.10) вычисляются для $N = 40000$ отсчётов.

С другой стороны, в случае стохастического градиентного спуска вся тренировочная последовательность делится на неперекрывающиеся блоки, которые упаковываются в 50 блоков по 200 отсчётов каждый. Таким образом, за одну эпоху (одно прохождение всей тренировочной последовательности) модель тренируется на 4 блоках. Градиенты вычисляются для каждого блока (по 200 отсчётов) и усредняются (по 50 блоков). Размер блока был выбран экспериментально с точки зрения максимизации результирующего уровня качества модели.

Кроме того, в данном численном эксперименте рассмотрены ускоренные версии

градиентного спуска, представленные оптимизаторами Adam и Momentum, описанными в разделе 2.2 главы I.

В следующих симуляциях нормированная среднеквадратичная ошибка NMSE (1.5.2) отслеживается на каждой эпохе на тренировочной и тестовой последовательности, что отражено на рис. 23, 24.




Рис. 23. Кривые сходимости на тренировочной и тестовой последовательностях. Сравнение BGD с оптимизаторами Momentum, Adam и смешанного метода Ньютона. BGD – блочный градиентный спуск, MNM – смешанный метод Ньютона, NMSE – нормированная среднеквадратичная ошибка, Adam, Momentum – оптимизаторы градиентного спуска.

Сравнение скорости сходимости блочного градиентного спуска с оптимизаторами Momentum и Adam, а также смешанного метода Ньютона показано на рис. 23. Смешанный метод Ньютона требует 30 эпох для достижения результирующего значения уровня компенсации, в то время как блочным градиентный спуск с оптимизаторами требуют ~ 10000 эпох для достижения такого же значения NMSE.

На рис. 24 представлены кривые обучения, полученные для стохастического градиентного спуска с оптимизаторами Momentum и Adam и смешанного метода Ньютоном. Графики сходимости отражают тот факт, что стохастический градиентный спуск также требует приблизительно 10000 эпох для достижения уровня компенсации паразитной помехи, полученного при помощи смешанного метода Ньютона.

Отметим, что параметры оптимизаторов и темп обучения градиентного спуска, были выбраны с точки зрения наилучшего результирующего качества модели и высокой скорости сходимости.

Спектральные плотности мощности () исходной и компенсированной различными методами помехи изображены на рис. 25. Графики СПМ построены на основе тестовой последовательности.

Таблица 1 отражает заметное увеличение скорости сходимости смешанного мето-




Рис. 24. Кривые сходимости на тренировочной и тестовой последовательностях. Сравнение SGD с оптимизаторами Momentum, Adam и смешанного метода Ньютона. SGD – стохастический градиентный спуск, MNM – смешанный метод Ньютона, NMSE – нормированная среднеквадратичная ошибка, Adam, Momentum – оптимизаторы градиентного спуска.




Рис. 25. Спектральные плотности мощности исходной и компенсированных помех. BGD – блочный градиентный спуск, SGD – стохастический градиентный спуск, Adam, Momentum – оптимизаторы градиентного спуска, MNM – смешанный метод Ньютона, NMSE – нормированная среднеквадратичная ошибка.

да Ньютона по сравнению с классическими градиентными методами. Для достижения сопоставимого уровня компенсации для смешанного метода Ньютона требуется всего 30 эпох. Несмотря на то, что при использовании метода второго порядка требуется существенно меньшее число шагов оптимизации, каждый шаг адаптации вычисляется ~ 5 в раз дольше. Тем не менее, общее время, затрачиваемое на обучение модели, существенно меньше по сравнению с методами первого порядка.

Таблица 1. Сравнение уровня компенсации помехи и скорости сходимости

Алгоритм	BGD Moment.	BGD Adam	SGD Moment.	SGD Adam	MNM
Номер эпохи	10000	10000	10000	10000	30
Время за эпоху, 10^{-2} с	3.8	4.0	3.7	4.1	21
Общее время работы, с	380	403	386	412	6.2
NMSE, dB	-45.1	-46.7	-46.6	-46.5	-46.9

Как было отмечено ранее, итерация смешанного метода Ньютона подразумевает обращение матрицы Гёссе (3.3.4). В связи с этим вычислительная сложность шага смешанного метода Ньютона `[mixed_newton_global_opt]` высока по сравнению с алгоритмами на основе градиентного спуска `[polyak1964some]`, `[kingma2014adam]`. Тем не менее, число шагов, необходимых для достижения такого же уровня компенсации, значительно меньше для смешанного Ньютона (таблица 1). Таким образом, смешанный метод Ньютона отлично подходит для исследования возможного уровня качества моделей. Кроме того, смешанный метод Ньютона можно использовать для онлайн обучения моделей, так как в реальных приложениях требуется накопление матрицы Гёссе и, как следствие, частота шагов оптимизации существенно меньше по сравнению с методами первого порядка.

Таким образом, несмотря на то, что вычисление шага оптимизации смешанного метода Ньютона требует в ~ 5 раз больше времени, общая длительность обучения уменьшена до 30 эпох, по сравнению 10000 эпох необходимых для классических методов оптимизации первого порядка, для достижения того же уровня компенсации 46.9 дБ.

3.2 Компенсация паразитных комбинационных помеховых составляющих второго порядка на основе адаптации классических и нейросетевых структур

В данном разделе рассматривается задача компенсации нелинейных паразитных комбинационных составляющих второго порядка, возникающих в приемном тракте устройств связи `[sic_imd2_phd]`. Проблема возникновения и экспериментальная установка для генерации комбинационных помех второго порядка описана в разделе 2.2 главы II.

Ввиду того, что комбинационные искажения второго порядка возникают на нулевой частоте в приёмнике устройства связи, предлагается использовать нелинейную

модель следующего вида:

$$y_n = \sum_{k=0}^{K-1} \sum_{p=0}^{P-1} h_{k,p} T_p(|x_{n-d_k}|) \in \mathbb{R}, \quad (3.2.1)$$

где $h_{k,p} \in \mathbb{R}$, $p \in \overrightarrow{0, P-1}$, $k \in \overrightarrow{0, K-1}$ – адаптивные параметры нелинейности, P и K – порядок полинома и число полиномов в адаптивной модели соответственно. В качестве базисных функций будем использовать полиномы Чебышева 1-го рода (5.2.12), представленные тригонометрической формой:

$$T_p(|x_{n-d_k}|) = \cos(p \cdot \arccos(|x_{n-d_k}|)). \quad (3.2.2)$$

Полиномы Чебышева 1-го рода выбраны в качестве базиса с целью улучшения обусловленности задачи ввиду их ортогональности на отрезке $[-1, 1]$ [**spec_func**].

Отметим, что каждый полином в модели (3.2.1) входит в сумму с аргументами с задержанными на d_k аргументами. Такая структура модели позволяет учесть инерционные свойства нелинейности. В то же время функция потерь (1.5.1) остается квадратичной по параметрам модели, что гарантирует глобальную сходимость градиентных методов [**convex_opt**].

Помимо классической полиномиальной структуры в данном исследовании рассматривается полносвязная нейросетевая структура. В отличие от полиномиальных моделей, где нелинейность задается фиксированным набором базисных функций, а обучаемыми параметрами являются лишь их коэффициенты, архитектура полносвязного перцептрона обеспечивает адаптивный выбор нелинейного базиса. Теоретическим обоснованием этого служит свойство универсальной аппроксимации, доказанное для сетей с хотя бы одним скрытым слоем и нелинейной функцией активации [**cybenko1989approximation**]. Каждый нейрон скрытого слоя формирует адаптивную базисную функцию в виде суперпозиции линейной комбинации входов и элементарной нелинейности (например, ReLU или sigmoid). Это позволяет сети в процессе обучения конструировать иерархические представления данных, оптимальные для конкретной задачи, что приводит к эффективному параметрическому описанию сложных нелинейных преобразований по сравнению с полиномами [**montufar2014number**], которые страдают от "проклятия размерности" при попытке достичь аналогичной точности.

Структура полносвязного перцептрона с комплексными входными данными и комплексными параметрами рассмотрена в разделе 5.8 главы I и представлена на рис. 10. В задаче компенсации комбинационных искажений второго порядка используется частный случай рассмотренной модели, представленный моделью с вещественными входными и выходными данными, а также вещественными параметрами. Рассматриваемая модель изображена на рис. 26.




Рис. 26. Вещественная нейросетевая модель на основе полносвязного перцептрона

Выходной отсчет выбранной полносвязной модели представлен выражением:

$$y_n = \mathbf{M}_{\text{out}} \sigma_{L-1}(\mathbf{M}_{L-1} \cdots \sigma_1(\mathbf{M}_1 \sigma_0(\mathbf{W}_0 \mathbf{f}_n))), \quad (3.2.3)$$

$$\mathbf{f}_n = \left(|x_{n-d_0}| \quad |x_{n-d_1}| \quad \cdots \quad |x_{n-d_{M-1}}| \right)^T. \quad (3.2.4)$$

где M — количество задержек сигнала, $\sigma_i(\cdot)$ — функция активации i -го слоя, $\mathbf{M}_0 \in \mathbb{R}^{K \times M}$, $\mathbf{M}_j \in \mathbb{R}^{K \times K}$, $j \in \overline{0, L-1}$ — матрицы весов скрытых линейных слоев, K — количество выходных каналов скрытого слоя, L — количество скрытых слоев, $\mathbf{M}_{\text{out}} \in \mathbb{R}^{1 \times K}$ — матрица весов выходного линейного слоя, $\mathbf{f}_n \in \mathbb{R}^{M \times 1}$ — вектор, состоящий из абсолютных значений входного задержанного сигнала.

Таким образом, модель построена по аналогии с классической моделью (3.2.1) и учитывает инерционные свойства нелинейных искажений путём подачи M -канального сигнала, где каждый канал представляет собой задержанный на d_k отсчет абсолютного значения сигнала. При этом скрытые слои с параметрами $\mathbf{M}_j$, $j \in \overline{0, L-1}$ могут быть интерпретированы как адаптивный базис.

Для адаптации предложенных моделей используется ускоренный метод градиентного спуска на основе алгоритма Adam, рассмотренный в разделе 2.2 главы I ввиду его эффективности в задачах невыпуклой оптимизации, а также простоты аппаратной реализации [kingma2014adam].

Кроме того, в работе приводится в сравнение метод L-BFGS - модификация квазиньютоновского метода BFGS, рассмотренного в разделе 4.6 главы I, в условиях ограничений по памяти. Метод L-BFGS доказал свою эффективность в задачах невыпуклой оптимизации [liu1989limited] и обладает сверхлинейностью сходимостью в окрестности оптимума, а также является линейным по памяти.

Также для сравнения уровня компенсации помех при помощи адаптации полиномиальной модели алгоритмами Adam и L-BFGS приводится уровень компенсации полученный при помощи алгоритма LS, рассмотренного в разделе 3.4 главы I, поскольку метод LS гарантирует достижение глобального оптимума за 1 шаг для квадратичной задачи оптимизации. Заметим, что функция потерь (1.5.1) не является квадратичной по параметрам в случае многослойной полносвязной модели (3.2.4), поэтому метод LS в данном случае не гарантирует достижение глобального опти-

му за 1 шаг. Уровень компенсации помехи при помощи адаптации нейросетевой модели оценивается при помощи метода L-BFGS.

Для численных экспериментов сравнения скорость сходимости и критериев качества моделей выбрана полиномиальная модель (3.2.1) с параметрами $K = 3$, $P = 8$ и полносвязная структура (3.2.4) с $M = 3$, $L = 2$, $\mathbf{W}_0 \in \mathbb{R}^{3 \times 3}$, $\mathbf{W}_1 \in \mathbb{R}^{2 \times 3}$, $\mathbf{W}_{\text{out}} \in \mathbb{R}^{1 \times 2}$. Таким образом, полиномиальная модель имеет 24 вещественных параметра, в то время как модель на основе нейронной сети имеет 17 вещественных параметров.


Критерием качества компенсации комбинационных составляющих второго порядка выбрана нормированная среднеквадратичная ошибка, вычисленная на всей обучающей выборке длиной 100000 отсчетов.

Графики сходимости методов ускоренного метода градиентного спуска и квази-ньютонского алгоритма для обеих моделей приведены на рис. 27а и рис. 27б.


Графики спектральной плотности мощности (СПМ) комбинационных помех второго порядка и остаточных ошибок после работы алгоритма LS для полиномиальной модели (3.2.1), (3.2.2) и алгоритма L-BFGS для полносвязной модели (3.2.3) изображены на рис. 28.

Модель	Алгоритм	Количество итераций				
		1000	2000	5000	10000	20000
Полиномиальная	LS	-23.59	-23.59	-23.59	-23.59	-23.59
	Adam	-21.96	-22.40	-22.76	-22.83	-22.91
	L-BFGS	-23.41	-23.41	-23.41	-23.41	-23.41
Полносвязная	LS	N/A	N/A	N/A	N/A	N/A
	Adam	-21.00	-21.69	-22.03	-23.28	-23.35
	L-BFGS	-23.20	-23.63	-23.63	-23.63	-23.63

Таблица 2. Сравнение результатов моделирования для полиномиальной и полносвязной модели при использовании различных оптимизаторов: уровень компенсации помехи в зависимости от числа итераций



(а) Adam и L-BFGS, 400 итераций



(б) Adam и L-BFGS, 20000 итераций

Рис. 27. Кривые обучения при различном количестве эпох

Согласно результатам, представленным в таблице 2 и на рис. 27, метод L-BFGS обеспечивает уровень компенсации для обеих архитектур, близкий к решению LS для полиномиальной модели с $\text{NMSE} = -23,59$ дБ. Более того, скорость сходимости L-BFGS для обеих структур занимает менее 2000 итераций (таблица 2), в то время как




Рис. 28. Графики СПМ сигнала приёмника, ошибки после компенсации помехи в результате адаптации полинома Чебышёва и нейросетевой модели

ускоренный метод градиентного спуска достигает максимального значения уровня компенсации $\text{NMSE} = -23.35$ дБ для полносвязной модели 20000 итераций. Текущие результаты показывают его практическую значимость данного метода ввиду локальной сверхлинейной сходимости.

Согласно рис. 27а, 27б, а также таблице 2 полносвязная модель обучается дольше классической полиномиальной модели, однако конечное значение уровня компенсации выше на 0.5 дБ, что составляет увеличение уровня компенсации энергии ошибки на 12%. При этом число параметров полносвязной модели меньше на 45%.

Проведенные численные эксперименты демонстрируют фундаментальное свойство нейросетевых архитектур — их способность к обучению релевантного признакового пространства (feature learning). В контексте поставленной задачи это проявляется в адаптивной параметризации функционального базиса, где каждый слой сети формирует нелинейные комбинации признаков предыдущего уровня. Однако данная гибкость достигается за счет существенного усложнения ландшафта оптимизационной задачи: переход от решения системы линейных уравнений для фиксированного базиса к поиску глобального минимума в высокоразмерном невыпуклом пространстве параметров.

Результаты вычислительного исследования демонстрируют высокую эффективность квазиньютоновских методов, в частности L-BFGS, для решения полученной невыпуклой задачи оптимизации. Их практическое преимущество перед классическими ускоренными методами первого порядка заключается в локальной сверхлинейной скорости сходимости, достигаемой за счет аппроксимации гессиана без явного вычисления вторых производных. Это свойство оказывается критически важным для компенсации нелинейных искажений, где точное определение направления убывания в сложном параметрическом пространстве напрямую влияет на качество итоговой модели и скорость обучения.

4. Исследование алгоритмов и адаптивных моделей компенсации нелинейных искажений в передатчике устройств связи

Усилители мощности (УМ) вносят нелинейные искажения, которые существенно влияют на качество радиочастотных сигналов, приводя к ухудшению характеристик передаваемого сигнала. Искажения, вносимые УМ, могут быть классифицированы как внутрисполосные и внеполосные.

В случае отсутствия методов линеаризации передающего тракта нелинейные искажения приводят к увеличению вероятности битовой ошибки (BER) на приёмной стороне, возникновению комбинационных помеховых составляющих, а также к ухудшению качества передачи сигналов в соседних частотных каналах.

Для компенсации нелинейных искажений в современных базовых станциях и пользовательских устройствах широко применяется метод цифровой предискажения (Digital Pre-Distortion – DPD) [dpd_models, GuoYan_PA_DPD_2015, GuoYan_PA_DP].

Система DPD реализуется в виде блока с обратной нелинейной характеристикой, который реализует предварительное преобразование входного сигнала усилителя мощности с целью минимизации нелинейных искажений на выходе УМ (рис. 5). Постановка задачи оптимизации метода цифрового предискажения подробно описана в разделе 1.4 главы I.

4.1 Компенсация нелинейных искажений в передатчике устройств связи в условиях динамического изменения выходной мощности нелинейного усилителя


Фундаментальным условием корректного функционирования системы цифрового предискажения является предположение о стационарности нелинейных искажений, а также исходного сигнала передатчика [dpd_models]. Сходимость алгоритмов адаптации модели цифрового предискажения (1.4.3) основана на допущении, согласно которому входной и опорный сигналы формируются одной и той же стационарной статистической моделью, то есть принадлежат одному и тому же распределению. В условиях нестационарности входных данных и/или опорных сигналов нарушаются предпосылки корректного обучения, что, как следствие, приводит к отсутствию сходимости алгоритма адаптации [widrow1985adaptive].

Тем не менее, в системах связи для выполнения заданных требований ресурсные блоки (RB) в составе кадра данных могут динамически распределяться в зависимости от текущей нагрузки трафика. Это приводит к кратковременным изменениям уровня мощности, что, в свою очередь, снижает эффективность работы усилителя мощности. Данное обстоятельство противоречит предположению о стационарном ре-


жиме функционирования системы цифрового предискажения. Указанная проблема была рассмотрена в работе [Dynamic_DPD_RB_Alloc].

С другой стороны, для повышения энергетической эффективности требуется существенное изменение уровней входной мощности усилителя мощности. В зависимости от класса базовой станции стандартные спецификации 3GPP/ETSI предписывают различные пределы выходной мощности: для Medium Range устройств до $\approx +38$ dBm, для Local Area — около $\approx +24$ dBm, и для домашних станций — до $\approx +20$ dBm на один передатчик. Соответственно, динамический диапазон регулировки выходной мощности может достигать 20–30 дБ относительно максимума, что существенно влияет на нелинейные характеристики усилителей мощности и требует адаптивных методов линейзации [etsi_ts_136104]. Для компенсации искажений, вызванных изменениями мощности, система цифрового предискажения должна быть перенастроена в реальном времени, что на практике зачастую оказывается экономически нецелесообразным.

Кроме того, переходные процессы, возникающие при переключении режимов выходной мощности усилителя, приводят к дополнительным искажениям, распространяющимся по каналу связи. Это вызывает кратковременные нарушения протоколов связи и ухудшению спектральной маски. Как следствие, модель цифрового предискажения, обученная для статического режима выходной мощности УМ, теряет эффективность при обработке сигналов с иным уровнем выходной мощности. Данный эффект наглядно демонстрируется анализом мгновенной спектральной плотности мощности, представленным на рис. 29.



(а) Применение одномерной модели.
Обучение при мощности 0.912 Вт,
тестирование при мощности 0.069 Вт



(б) Применение одномерной модели.
Обучение при мощности 0.741 Вт,
тестирование при мощности 0.589 Вт

Рис. 29. Спектральная плотность мощности на выходе усилителя. Иллюстрация нестационарности при динамическом изменении режимов мощности

На рис. 29а параметры одномерной полиномиальной модели (5.2.3), обученные для случаев выходной мощности 0.069 Вт (зелёная кривая) и 0.912 Вт (синяя кривая), применяются к сигналу с выходной мощностью 0.069 Вт. Можно наблюдать ухудшение коэффициента утечки в соседний канал ACLR (1.5.3) до 32 дБ, обусловленное различиями в поведении нелинейной характеристики усилителя мощности

при выбранных режимах.

В то же время, при обучении модели на близких значениях выходной мощности усилителя, а именно 0.598 Вт (зелёная кривая) и 0.714 Вт (синяя кривая) (рис. 29б), ухудшение компенсации внеполосных искажений составляет 7.5 дБ.

В результате усиленные нелинейные искажения могут распространяться по каналу связи в процессе адаптации параметров модели. В связи с этим более предпочтительным является подход, ориентированный на предсказание нелинейных искажений для всех рабочих режимов усилителя мощности, а не на отслеживание отдельных уровней выходной мощности.

Одним из методов предсказания нелинейных искажений, обусловленных различными режимами мощности усилителя, являются методы пересчёта параметров модели относительно выбранного опорного режима.

Так, в работе [GuoYan_PA_DPD_2015] предложено разделение обучаемых параметров модели на статическую и динамическую составляющие, при этом динамические параметры переключаются в зависимости от режима мощности усилителя. В работе [GuoYan_PA_DPD_Poly] данная концепция была расширена путём применения модели адаптивного поворота векторного разложения (power-adaptive decomposed vector rotation, PDVR).

Другой класс методов основан на использовании алгоритмов искусственного интеллекта [Dynamic_DPD_ANN, Dynamic_DPD_CNN]. В частности, в работе [Dynamic_DPD_ANN] предлагается использовать нейронную сеть для извлечения признаков, связанной с различными типами нелинейностей, и последующего преобразования параметров обобщённой полиномиальной модели с памятью [dpd_models] в параметры, соответствующие требуемому уровню мощности, что позволяет прогнозировать нелинейное поведение усилителя мощности для заданного режима.

В данном разделе предлагается альтернативный метод предсказания нелинейных искажений в условиях динамически изменяющейся выходной мощности усилителя, основанный на адаптации двумерного полинома Чебышёва. По сути, данный подход представляет собой классический метод, в котором динамические условия учитываются за счёт использования дополнительных признаков, соответствующих различным режимам работы УМ.

Отметим, что функция потерь для задачи цифрового предсказания для динамического режима работы УМ состоит из суммы элементарных функций потерь (1.4.3), соответствующих различным режимам:

$$J = \sum_{i=0}^{C-1} \|f(\mathbf{x}, \mathbf{p}, \mathbf{h}) - \mathbf{e}_i\|_2^2 \rightarrow \min_{\mathbf{h}}, \quad (4.1.1)$$

где C — количество режимов выходной мощности усилителя, $\mathbf{p} \in \mathbb{C}^{N \times 1}$ — вектор признаков входной мощности усилителя. Таким образом, пара $(\mathbf{x}, \mathbf{p})$ образует двумерный вход модели, а $\mathbf{h} \in \mathbb{C}^{K \times 1}$ является вектором параметров модели цифрового

предыскажения.

Классической моделью нелинейных искажений является полиномиальная модель на основе полиномов Чебышева 1-го рода (раздел 5.2 главы I):

$$y_n = \sum_{d=-D}^D \sum_{i=0}^{P_1-1} h_{k,i} x_{n-d} T_i(|x_{n-d}|),$$

$$T_i(|x_{n-d}|) = \cos(i \arccos(|x_{n-d}|)) \quad (4.1.2)$$

где $B = 2D + 1$ – количество ветвей модели, $T_i(\cdot)$, $i = \overline{0, P_1 - 1}$ – функциональный базис. Базис Чебышева 1-го рода позволяет увеличить обусловленность задачи. Отметим, что для учёта инерционных свойств УМ модель (4.1.2) включает в себя сумму нелинейных функций – ветвей, каждая из которых обрабатывает задержанный сигнал $|x_{n-d}|$, где d – задержка сигнала, соответствующая d -й ветви модели.

Заметим, однако, что классическая одномерная (1D) модель (4.1.2) не обладает достаточной обобщающей способностью для описания динамического режима работы УМ (рис. 29). В связи с этим предлагается двумерная (2D) нелинейная модель, входными признаками которой являются амплитуда сигнала $|x_n|$, а также признак, отражающий текущий режим мощности УМ p_n . Признак p_n соответствует входной мощности УМ, равномерно возрастающей в линейном масштабе. Всего рассматривается 61 уровень мощности (2.4.1а), описанных в разделе 2.4 главы II.




Рис. 30. Двумерная модель компенсации нелинейных искажений в условиях динамического режима работы УМ на основе полиномов Чебышева 1-го рода

Предлагаемая двумерная полиномиальная модель изображена на рис. 30 и представляет собой следующее выражение:

$$y_n = \sum_{d=-D}^D \sum_{i=0}^{P_1-1} \sum_{j=0}^{P_2-1} h_{i,j,d} x_{n-d} T_{i,j}(|x_{n-d}|, p_{n-d}),$$

$$T_{i,j}(|x_n|, p_n) = T_i(|x_n|) T_j(p_n) = \cos(i \arccos(|x_n|)) \cos(j \arccos(p_n)), \quad (4.1.3)$$

где $B = 2D + 1$ – число веток модели, P_1, P_2 – порядки двумерного полинома Чебышёва по измерениям амплитуды сигнала и режима мощности соответственно, $\{h_{i,j}\}_{i=0,j=0}^{P_1-1,P_2-1}$ – настраиваемые параметры двумерного полинома. Базисные функции двумерной нелинейности $T_{i,j}(\cdot)$ выражаются через произведение одномерных базисных функций $T_i(\cdot)$ и $T_j(\cdot)$, соответствующих амплитуде сигнала и мощности УМ. Отметим, что амплитуда входного сигнала $|x_n|$ и признак режима УМ p_n нормируются в единый диапазон $[-1, 1]$ как для стандартизации данных, так и для выполнения условий ортогональности полиномов Чебышёва.

Модель (4.1.3) обучается на $C = 31$ (4.1.1) сигнале, которые соответствуют четным элементами последовательности (2.4.1а). Таким образом обучение модели производится на данных, соответствующие входной мощности p_n :

$$\begin{aligned} &25.1 \text{ мкВт}, 50.8 \text{ мкВт}, \dots, 794.3 \text{ мкВт} \\ &14.0 \text{ дБмк}, 17.1 \text{ дБмк}, \dots, 29.0 \text{ дБмк}, \end{aligned} \quad (4.1.4a)$$

а также выходной мощности УМ:

$$\begin{aligned} &0.069 \text{ Вт}, 0.143 \text{ Вт}, \dots, 0.912 \text{ Вт} \\ &-11.6 \text{ дБВт}, -8.4 \text{ дБВт}, \dots, -0.4 \text{ дБВт} \end{aligned} \quad (4.1.5)$$

В данном разделе производится сравнение обобщающей способности 2-х моделей (4.1.2), (4.1.3). Параметры обеих моделей представлены в таблице 3.

Модель	Число веток B	Порядок P_1	Порядок P_2	Число параметров
1D-полином (4.1.2)	37	24	—	888
2D-полином (4.1.3)	9	8	12	864

Таблица 3. Параметры моделей компенсации нелинейных искажений в условиях динамического изменения режима УМ

Поскольку моделей (4.1.2), (4.1.3) линейные по параметрам и, как следствие, функция потерь (1.5.1) является квадратичной, то глобальный оптимум в обоих случаях может быть найден методом LS (3.4.2) за один шаг (раздел 3.4 главы I). Будем адаптировать модели при помощи метода LS, а также ускоренного при помощи оптимизатора Adam блочного градиентного спуска (раздел 2.2 главы I).

Метод LS адаптирует модель на полном массиве тренировочных данных длиной $31 \cdot 147384 = 4568904$ отсчетов. При этом стохастическая версия градиентного спуска обучается модели на матрице данных размерности 31×267 , где блоки длиной 267 выбираются из массивов соответствующих различным режимам УМ (4.1.4). Всего $147384/267 = 552$ блоков на всю тренировочную выборку. Градиенты (2.1.10), посчитанные на блоках для разных режимов УМ агрегируются для пересчета параметров

модели:

$$\mathbf{z}_{k+1} = \mathbf{z}_k + \frac{\mu}{C} \sum_{i=0}^{C-1} (D_{\mathbf{z}} \mathbf{y}_i)^H \mathbf{e}_i. \quad (4.1.6)$$

Такой способ формирования обучающих блоков данных обеспечивает равномерное усвоение параметрами модели информации, соответствующей данным с различными статистическими характеристиками.

Якобианы $D_{\mathbf{z}} \mathbf{y}_i$, $i = 0, C-1$ (4.1.6) для метода градиентного спуска и метода LS для адаптации двумерной модели (4.1.3) вычисляются в соответствии с формулами (5.9.16).

Порядок полинома Чебышёва P_2 (таблица 3) выбран таким образом, чтобы обеспечить приемлемые значения коэффициента утечки в соседний канал (ACLR) было на уровне не хуже -50 дБ во всём диапазоне режимов работы УМ.

Общее число параметров одномерной модели выбрано примерно равным числу параметров двумерной модели (таблица 3) с целью обеспечения корректного сравнения.

Уровень компенсации обеих моделей представлен на рис. 31. Согласно результатам численных экспериментов, двумерная модель обеспечивает уровень ACLR < -50 дБ во всём диапазоне выходных мощностей усилителя мощности. Более того, по сравнению с одномерной полиномиальной моделью достигается улучшение ACLR до 14 дБ для всех рассмотренных режимов выходной мощности усилителя.

На рис. 32 представлены спектральные плотности мощности сигнала передатчика до применения нелинейного корректора и после коррекции с использованием предварительно обученных одномерной и двумерной моделей на основе полиномов Чебышёва. Оценка качества компенсации внеполосных искажений выполнена как на обучающей, так и на тестовой выборках, при этом соответствующие спектральные







Рис. 31. Уровень компенсации внеполосных искажений в передатчике устройства связи за счет адаптации 1D- и 2D-моделей на основе полиномов Чебышёва 1-го рода




(а) DPD выкл.



(б) DPD выкл./вкл., 1D- и 2D-модели на основе полиномов Чебышёва 1-го рода



(в) DPD вкл., 1D-модель



(г) DPD вкл., 2D-модель

Рис. 32. СПМ сигнала на выходе УМ. Результат применения 1D- и 2D-моделей на основе полиномов Чебышева 1-го рода

плотности мощности выходного сигнала усилителя мощности приведены на рис. 32.

На рис. 32а показана цветовая шкала спектральной плотности мощности сигнала передатчика до применения нелинейного корректора для всех рассматриваемых значений выходной мощности усилителя. В свою очередь, на рис. 32в и 32г приведены цветовые шкалы спектров сигнала на выходе УМ при включенном блоке DPD на основе одномерной и двухмерной моделей Чебышёва соответственно. Дополнительно, на рис. 32б представлены СПМ сигнала передатчика до и после применения нелинейной коррекции на одном графике с нормированными уровнями выходной мощности для различных режимов работы УМ.

Таким образом, согласно рис. 31, 32в и 32г, двумерная модель цифровых предсказаний (4.1.3) обеспечивает существенное увеличение уровня компенсации внеполосных искажений по сравнению с одномерной моделью (4.1.2), достигающее 14 дБ, во всём динамическом диапазоне выходной мощности усилителя: 0.069 Вт, ..., 0.912 Вт.

Результаты демонстрируют существенное повышение обобщающей способности двумерной модели (4.1.3) относительно классического одномерного подхода (4.1.2). Данное улучшение обусловлено введением дополнительного измерения, параметри-

зующего текущий мощный режим работы усилителя мощности.

Такая параметризация позволяет модели предсказывать нелинейные искажения в условиях динамического изменения мощности входного сигнала. Следовательно, устраняется необходимость калибровки и пересчёта параметров модели для различных режимов работ УМ, что в свою очередь минимизирует вероятность кратковременных нарушений протокола связи, вызванных процедурами перенастройки цифрового предсказания.

Рассмотрим скорость сходимости ускоренного градиентного спуска с оптимизатором Adam (раздел 2.2 главы I). В данном вычислительном эксперименте использовалось линейное изменение скорости шага для ускорения обучения модели [he2016deep]:

$$\mu_k = \mu_{\text{start}} + \frac{k}{N-1}(\mu_{\text{end}} - \mu_{\text{start}}). \quad (4.1.7)$$

где μ_{start} , μ_{end} – начальное и конечное значение шага обучения. Таким образом, в (4.1.7) шаг линейно обнуляется от $\mu_{\text{start}} = 10^{-4}$ до $\mu_{\text{end}} = 10^{-7}$. Индекс шага обучения $k = \overrightarrow{0, N-1}$, N – число шагов обучения $N = 552 \cdot E = 552 \cdot 50 = 27600$, где $E = 50$ – число эпох, т.е. количество проходов алгоритма обучения по всей длине тренировочной выборки.

На рис. 33 изображено сравнение кривой сходимости ускоренного блочного градиентного спуска с уровнем компенсации нелинейных искажений, полученным при помощи адаптации двумерной модели алгоритмом LS.




Рис. 33. Сравнение кривой сходимости ускоренного блочного градиентного спуска с уровнем компенсации, полученным при помощи алгоритма LS

Кривая сходимости, а также уровень компенсации метода LS получен путём подсчета нормированной среднеквадратичной ошибки (1.5.2) на всей длине тренировочных данных. При этом в качестве опорного сигнала $\mathbf{d}$ (1.5.2) взят исходный сигнал нелинейных искажений на выходе УМ до включения алгоритма адаптации, т.е. разность выхода и входа УМ: $\text{PA}(\mathbf{x}) - \mathbf{x}$. Таким образом, значения NMSE считаются по

формуле:

$$\text{NMSE} = 10 \cdot \lg \left(\frac{\sum_{i=0}^{C-1} (\text{PA}(\mathbf{x}_i) - \mathbf{x}_i - \mathbf{y}_i)^H (\text{PA}(\mathbf{x}_i) - \mathbf{x}_i - \mathbf{y}_i)}{\sum_{i=0}^{C-1} (\text{PA}(\mathbf{x}_i) - \mathbf{x}_i)^H (\text{PA}(\mathbf{x}_i) - \mathbf{x}_i)} \right) \text{ дБ}, \quad (4.1.8)$$

где $\mathbf{x}_i$, $\text{PA}(\mathbf{x}_i)$, $\mathbf{y}_i$ – вход УМ, выход УМ, выход нелинейной модели соответственно для i -ого мощностного режима УМ, $i = \overrightarrow{0, C-1}$, $C = 31$ – число мощностных режимов обучающей выборки (4.1.5).

На основе рис. 33 собрана сравнительная таблица 4 уровня компенсации, полученного в зависимости от числа эпох.

Метод	3 эпох	5 эпох	27 эпох	150 эпох
BGD+Adam, NMSE дБ	-21.55	-22.71	-23.32	-24.17
LS, NMSE дБ	-24.55	-24.55	-24.55	-24.55

Таблица 4. Сравнение уровня компенсации нелинейных искажений методами BGD, LS в зависимости от числа эпох обучения

Как видно из таблицы 4 ускоренный метод градиентного спуска за 3 эпохи достигает уровня компенсации на 3 дБ меньше оптимального значения, за 5 эпох уровня компенсации ≈ 2 дБ меньше оптимального значения, за 27 эпох на 1.2 дБ меньше оптимального значения. По окончании обучения на 150 эпохах уровень компенсации на ≈ 0.4 дБ меньше уровня компенсации, достигаемого при помощи LS метода. Отличие в 0.4 дБ составляет всего 9.6% отличия по энергии ошибки.

Тем не менее, уровень компенсации соответствующий отдельным мощностным режимам может существенно отличаться от полученного при помощи метода LS. Это связано с тем, что значения компенсации, отраженные на рис. 33 вычисляются по составному критерию (4.1.8), в котором аккумулируется энергия ошибки обучения для всех мощностных режимов тренировочной выборки. При это наибольших вклад в энергию ошибки вносят сигналы на выходе УМ соответствующие большим значениям выходной мощности. С точки зрения алгоритма адаптации эти сигналы являются наиболее приоритетными. При этом ошибка адаптации, соответствующая меньшим значениям выходной мощности может быть высокой и корректироваться в последнюю очередь.

Этот процесс представлен на рис. 34. Значения ACLR соответствующие уровню компенсации засчет обучения ускоренным методом градиентного спуска на 5 эпохе для выходной мощности 100 мВт – на ≈ 9.5 дБ меньше значения, полученного LS-методом, на 10 эпохе для выходной мощности 100 мВт – на ≈ 9 дБ, на 27 эпохе для выходной мощности 70 мВт – на ≈ 7 дБ, на 150 эпохе для выходной мощности 100 мВт – на ≈ 6 дБ.

Представленные результаты демонстрируют необходимость поиска компромисс-




Рис. 34. Уровень компенсации внеполосных искажений в передатчике устройства связи за счет адаптации двумерной модели методами LS, а также ускоренным методом блочного градиентного спуска при различном числе эпох обучения

ного метода, который обладает высокой скоростью сходимости, как методы второго порядка и невысокой вычислительной сложностью, как градиентные методы.

Такой метод предложен в разделе 4.1 главы III и представляет собой адаптацию метода сопряженных градиентов на основе смешанного метода Ньютона (раздел 3.3 главы I). Предложенный метод обладает сверхлинейной скоростью сходимости и при этом не требует явного обращения матрицы вторых производных.

Глава III

Практическая реализация нелинейных корректоров в системах связи

1. Исследование компенсации нелинейных искажений методами не требующими явного обращения матрицы Гессе

В данном разделе приводится сравнение ускоренного блочного градиентного спуска (BGD – Block Gradient Descent), смешанного метод Ньютона (Mixed Newton), предложенного метода сопряженных градиентов (CG – Conjugate Gradient). Сравнение проводится с точки зрения результирующего уровня компенсации помехи по истечении фиксированного числа эпох и вычислительной сложности.

В качестве оптимизатора метода градиентного спуска используется алгоритм Adam [kingma2014adam]. Кроме того, величина шага обновления μ изменяется по линейно-убывающему закону, что также позволяет ускорить сходимость BGD:

$$\mu_t = \mu_0 \left(\alpha_{\text{start}} - \frac{t}{T-1} (\alpha_{\text{start}} - \alpha_{\text{end}}) \right), \quad (1.1)$$

где $T = 5000$ – число эпох обучения, $\mu_0 = 10^{-4}$, $\alpha_{\text{start}} = 1$, $\alpha_{\text{end}} = 10^{-4}$ подобраны эмпирически. Параметры оптимизатора Adam и темп обучения градиентного спуска, были выбраны с точки зрения наилучшего результирующего качества модели и высокой скорости сходимости.

Все рассмотренные алгоритмы функционируют в блочном режиме обработки данных с длиной блока $N = 60$. Метод сопряженных градиентов и комбинированный метод Ньютона требуют построения матрицы Гессе для точной оценки локальной кривизны функции потерь. Однако при малой длине блока N непосредственное вычисление матрицы Гессе приводит к накоплению информации, соответствующей устаревшим значениям параметров адаптивной модели. Для решения данной проблемы

в предлагаемом подходе применяется экспоненциальное взвешенное усреднение как для матрицы Гессе, так и для градиента функции потерь:

$$\mathbf{H}_{k+1} = \lambda \mathbf{H}_k + (1 - \lambda) \mathbf{H}_{z^*, z} J \quad (1.2)$$

$$\mathbf{g}_{k+1} = \lambda \mathbf{g}_k + (1 - \lambda) (\mathbf{D}_{z^*} J)^T, \quad (1.3)$$

где $\lambda = 0.9$ – параметр утечки, подобран эмпирически с точки зрения ускорения скорости сходимости. Отметим также, что при реализации смешанного метода Ньютона и метода сопряженных градиентов матрица Гессе дополнительно регуляризуется путём добавления диагональной матрицы $\gamma \mathbf{I}$ для обеспечения устойчивости решения. Параметр $\gamma = 10^{-4}$ – также подобран эмпирически.

В следующих симуляциях нормированная среднеквадратичная ошибка NMSE вычисляется после каждого обновления параметров модели на всем тренировочном сигнале длина 79k отсчетов, что отражено на рис. 35.




Рис. 35. Кривые сходимости. Сравнение смешанного метода Ньютона, BGD с оптимизатором Adam и линейно-убывающим шагов, метода сопряженных градиентов с различным числом итераций на одно обновление параметров модели.

На рис. 23 отражено сравнение скорости сходимости ускоренного метода градиентного спуска, смешанного метода Ньютона, а также метода сопряженных градиентов с различным числом итераций $L \in \{1, 5, 10, 20, 30, 50\}$ на одно обновление параметров модели.

Согласно таблице 5 MNM требуется 0.21 эпохи для достижения результирующего значения уровня компенсации 48.0 dB, в то время как ускоренный BGD требует ~ 1750 эпох для достижения такого же значения NMSE= 48 dB. При этом вычисли-

тельная сложность BGD составляет $\sim 8.47 \cdot 10^{-3}$ относительно сложности смешанного метода Ньютона.

Метод сопряженных градиентов демонстрирует увеличение скорости сходимости по мере увеличения числа итераций L CG-алгоритма на один пересчет параметров модели. Согласно таблице 5 уже при $L = 10$ метод сопряженных градиентов достигает уровень компенсации помехи равный уровню компенсации BGD за число итераций в ~ 90 раз меньше, составляя при этом 59% вычислительной сложности смешанного метода Ньютона. При $L = 20$ метод CG составляет 68% вычислительной сложности смешанного метода Ньютона, но обеспечивает уровень компенсации NMSE=48 dB за 0.28 эпохи.

Таблица 5. Сравнение уровня компенсации помехи и скорости сходимости

Алгоритм	MNM	CG $L = 50$	CG $L = 30$	CG $L = 20$	CG $L = 10$	CG $L = 5$	CG $L = 1$	BGD Adam
Число эпох	0.21	0.21	0.22	0.28	19.41	199.18	5000.00	1746.74
Вычисл. сложность	1	0.93	0.76	0.68	0.59	0.55	0.52	$8.47 \cdot 10^{-3}$
NMSE, dB	-48.0	-48.0	-48.0	-48.0	-48.0	-48.0	-42.7	-48.0

Согласно расчетам, приведенным в теоретической части, вычислительная сложность шага MNM (3.3.5) высока по сравнению с алгоритмами на основе градиентного спуска (2.1.13). В связи с этим, метод сопряженных градиентов выступает в роли компромисса между смешанным методом Ньютона и методами первого порядка с точки зрения вычислительной сложности (4.1.15) и скорости сходимости (рис. 35).

Результаты всех численных экспериментов, представленных в данной работе, могут быть воспроизведены с использованием программного кода, доступного в репозитории [github_repo].

Таким образом, в данной работе предложено использование метода сопряженных градиентов для компенсации собственных помех в приёмнике полнодуплексного устройства связи. Метод построен для модели с комплексными параметрами и основан на аппроксимации шага смешанного метода Ньютона.

Метод является компромиссом между методами второго порядка обеспечивающими высокую скорость сходимости и высокие вычислительные затраты, и градиентными методами с линейной скоростью сходимости и малыми вычислительными затратами. Предложенный метод позволяет сохранить высокую скоростью сходимости, близкую к смешанному методу Ньютона, сокращая более 30% вычислительных затрат при адаптации коэффициентов корректора собственных помех.

2. Сокращение ресурсов при реализации моделей нелинейных искажений засчет канонического тензорного разложения

В разделе 4.1 описана описывается метод компенсации нелинейных искажений в передатчике устройств связи в условиях динамического изменения режима работы УМ. Предложенный метод подразумевает компенсацию искажений путем адаптации параметров классической модели на основе двумерных полиномов Чебышева (4.1.3).

Основной идея данного подхода заключается в выборе признаков на входе адаптивной модели. Модель принимает на вход абсолютные значения задержанных отсчетов передатчика $|x_{n-d}|$, а также отсчеты значений входной мощности УМ p_{n-d} . Такой подход учитывает динамический режим работы УМ, что позволяет удовлетворить условие стационарности входного и опорного сигнала адаптивной модели и, таким образом, обеспечить сходимость алгоритма адаптации нелинейного корректора.

Результаты представленные в разделе 4.1 на рис. 31 демонстрируют эффективность работы предложенной модели. Уровень компенсации нелинейных искажений увеличивается до 14 дБ по сравнению с классическим подходом во всем динамическом диапазоне изменения выходной мощности УМ (4.1.5).

Тем не менее, многомерные модели подвержены проклятию размерности. Данный эффект подразумевает экспоненциальный рост числа параметров модели в зависимости от числа измерений [pa_models]. Действительно, число адаптивных параметров в предложенной двумерной модели (4.1.3) составляет $BP_1P_2 = 864$, где $B = 9$ – число веток, соответствующих различным задержкам сигнала, $P_1 = 8$ – порядок измерения двумерного полинома Чебышева, соответствующего задержанному входному сигналу, $P_2 = 12$ – порядок измерения двумерного полинома Чебышева $|x_{n-d}|$, соответствующего мощностному признаку p_{n-d} .

Таким образом, использование двумерной модели подразумевает хранение в памяти большого числа параметров, а также высокую стоимость аппаратной реализации математической модели.

В связи с этим, в данном разделе предлагается метод сокращения ресурсов аппаратной реализации на основе рангового разложения. В связи с теорией рангового разложения, описанной в разделе 5.9 однослойная двумерная нелинейная модель общего вида (5.9.6) может быть разложена в сумму из R произведений одномерных моделей (5.9.9), где R – ранг матрицы параметров адаптивной модели.

В соответствии с векторным представлением выходных отсчетов модели на основе рангового разложения (5.9.9), модель адаптивной компенсации (4.1.3) может быть

представлена в виде:

$$\begin{aligned}
 y_n &= \sum_{d=-D}^D \sum_{r=0}^{R-1} x_{n-d} \left(\sum_{i=0}^{P_1-1} h_{x,i,d,r} T_i(|x_{n-d}|) \right) \left(\sum_{i=0}^{P_2-1} h_{p,i,d,r} T_i(p_{n-d}) \right), \\
 T_i(|x_n|)T &= \cos(i \arccos(|x_n|)), \\
 T_i(p_n) &= \cos(i \arccos(p_n)).
 \end{aligned} \tag{2.1}$$

В выражении (2.1) выход двумерных функций в каждой ветке $d = \overrightarrow{-D, D}$, $z_{d,n}$ представлен в виде суммы из R произведений выходных отсчетов одномерных функций $z_{x,d,n}$, $z_{p,d,n}$:

$$\begin{aligned}
 z_{d,n} &= \sum_{i=0}^{P_1-1} \sum_{j=0}^{P_2-1} h_{i,j,d} T_{i,j}(|x_{n-d}|, p_{n-d}) = \\
 &= \sum_{r=0}^{R-1} z_{x,d,n,r} z_{p,d,n,r} = \sum_{r=0}^{R-1} \left(\sum_{i=0}^{P_1-1} h_{x,i,d,r} T_i(|x_{n-d}|) \right) \left(\sum_{i=0}^{P_2-1} h_{p,i,d,r} T_i(p_{n-d}) \right).
 \end{aligned} \tag{2.2}$$

Равенство (2.2) отражает следующее утверждение: для любого набора параметров $h_{i,j,d}$ $i = \overrightarrow{0, P_1-1}$, $j = \overrightarrow{0, P_2-1}$, $d = \overrightarrow{-D, D}$ существуют наборы параметров $h_{x,i,d,r}$ и $h_{p,j,d,r}$, $r = \overrightarrow{0, R-1}$ такие, что $z_{d,n} = z_{x,d,n,r} z_{p,d,n,r}$. То есть модель на основе рангового разложения (2.1) гарантированно обеспечивает уровень компенсации не меньше, чем двумерная модель (4.1.3).

Отметим, также, что переход к модели на основе рангового разложения обеспечивает линейный рост числа параметров в зависимости от числа измерений при фиксированном ранге разложения. В текущей задаче число параметров модели:

$$P_1 P_2 \text{ (2D-модель)} \rightarrow R(P_1 + P_2) \text{ (модель на основе рангового разл.)}. \tag{2.3}$$

Данный подход наряду с использованием многослойных структур, является одним из методов борьбы с проклятием размерности.

Отметим, однако, что ввиду структуры (2.1), критерий MSE (1.5.1) не является квадратичной функцией параметров модели на основе рангового разложения и вообще говоря не является выпуклой. По этой причине, глобальный оптимум не может быть найден за один шаг алгоритма LS (3.4).

В то же время, в соответствии с (2.1) выход модели является голоморфной функцией (3.3.1). В последующих численных экспериментах модель (2.1) адаптируется при помощи предложенного ранее смешанного метода Ньютона (3.3.4), рассмотренного в разделе 3.3.

В последующих численных экспериментах сравниваются двумерная модель (4.1.3) и модель на основе рангового разложения (2.1) в задаче компенсации нелинейных искажений в условиях динамического режима работы УМ. Как и в разделе 4.1 главы II, описывающем решение на основе двумерной модели, данные обучающей и тестовой

выборки используемые в данной задаче описаны в разделе 2.4 главы II.

Как и в разделе 4.1 главы II порядок нелинейностей равен $P_1 = 8$, $P_2 = 8$ для измерений модуля входного сигнала $|x_n|$ и мощностных признаков УМ p_n соответственно. Число параметров сравниваемых моделей собраны в таблице 6:

Модель	Ранг $R = 1$	Ранг $R = 2$	Ранг $R = 3$	2D
Число параметров	180	360	540	864

Таблица 6. Число параметров двумерной модели, а также моделей на основе рангового разложения

Результаты сравнения уровня компенсации нелинейных внеполосных искажений во всем динамическом диапазоне выходной мощности представлены на рис. 36.




Рис. 36. Сравнение уровень компенсации внеполосных искажений в передатчике устройства связи засчет адаптации двумерной модели (4.1.3) методом LS, а также модели на основе рангового разложения (2.1) смешанным методом Ньютона для различных R

Как видно из рис. 36 модель на основе рангового разложение матрицы параметров (5.9.8) двумерной модели (5.9.9) прежде всего обеспечивает компенсацию нелинейных искажений, соответствующих высоким значениям выходной мощности УМ. Результаты численных экспериментов собраны в таблице 7.

Из таблицы 7 видно, что максимальное ухудшение компенсации в соседнем канале $\Delta\text{ACLR} \approx 9$ dB по сравнению с двумерной моделью соответствует выходной мощности 70 мВт при использовании рангового разложения с $R = 1$. Максимальное ухудшение компенсации в соседнем канале $\Delta\text{ACLR} \approx 3$ dB соответствует выходной

Модель	Ранг $R = 1$	Ранг $R = 2$	Ранг $R = 3$	2D
$\max_c \Delta \text{ACLR}_c$	9	3	–	0
ΔK_R (%)	79.2	58.3	37.5	0

Таблица 7. Сравнение характеристик моделей

мощности 70 мВт при использовании рангового разложения с $R = 2$. При $R = 3$, $\Delta \text{ACLR} \approx \text{dB}$ для выходной мощности УМ мВт.

Кроме того, в таблице 7 посчитан процент уменьшения числа параметров по сравнению в двумерной моделью (таблица 6) по формуле:

$$\Delta K_R = \frac{K_{2D} - K_{R\text{-rank}}}{K_{2D}} \cdot 100\%. \quad (2.4)$$

Предложенная модель позволяет уменьшить число параметров на 79.2%, 58.3%, 37.5% для $R = 1$, $R = 2$, $R = 3$ соответственно по сравнению с 2D-моделью.

Таким образом, модель на основе рангового разложения позволяет существенно уменьшить ресурсы необходимые для аппаратной реализации до 80% за счет ухудшения предсказательной способности до 9 дБ для малой выходной мощности УМ. При достаточном ранге $R = 3$ разложения уменьшение ресурсов меньше и составляет 37.5%, при этом ухудшение предсказательной способности составляет менее дБ.

3. Методы экономии ресурсов при реализации цифровых фильтров в моделях компенсации нелинейных искажений

В задачах компенсации нелинейных искажений зачастую используются классические адаптивные модели, отражающие физические свойства процессов [dpd_thesis]. К таким моделям относятся модель Вольтерра (раздел 5.4), а также ее упрощения: модель Гаммерштейна (раздел 5.5), модель Винера (раздел 5.6), Винера-Гаммерштейна (раздел 5.7) и другие.

Указанные модели включают адаптивные и предварительно обученные статические цифровые фильтры. При синтезе нелинейных моделей отдельные слои могут калиброваться с учётом параметров конкретной аппаратной реализации и впоследствии использоваться без дополнительной адаптации.

Так например в задаче компенсации нелинейных помех в приемнике (раздел 1.2 главы I) естественным выбором является модель Гаммерштейна (раздел 3.1 главы II), включающая адаптивный фильтр, описывающий импульсный отклик канала распространения помехи из передатчика в приёмник. Характеристика такого канала преимущественно обусловлена выбором дуплексера, свойства которого можно считать неизменными. По этой причине параметры фильтра могут быть предобучены и зафиксированы.

В задаче компенсации нелинейных помех в передатчике (раздел 1.3 главы I) часто используется модель Винера или Винера-Гаммерштейна. При этом входной фильтр модели, описывает инерционные свойства УМ. Ввиду неизменности инерционных свойств нелинейного УМ, входной фильтр модели может быть также предобучен и зафиксирован. Отметим также, что по сути такой подход позволяет адаптивно подобрать дробную задержку на входе нелинейного блока.

Заметим, что порядок фильтров варьируется в зависимости от задачи и физических процессов, описываемых фильтром. Так например в разделе 3.1 главы II импульсный отклик канала TX-RX описывался фильтром 50-го порядка.

Таким образом, после завершения адаптации коэффициенты предобученных адаптивных фильтров могут быть зафиксированы. Структура статических фильтров может быть оптимизирована с точки зрения энергопотребления цифровой схемы и площади, занимаемой фильтром на кристалле RF-чипсета.

Среди методов структурной оптимизации, ориентированных на различные критерии качества, можно выделить метод наименьших квадратов [Selesnick2005] и алгоритм McClellan–Parks–Rabiner [McClellan1973]. Для решения задач аппаратно-ориентированной оптимизации также применяются эволюционные методы, включая генетические алгоритмы с L1-регуляризацией [Aggarwal2018].

Отдельное направление исследований связано с оптимизацией фильтров с целочисленными коэффициентами. В отличие от случая вещественных коэффициентов, эта задача относится к классу NP-сложных. Для её решения предложены оптимальные методы, такие как SIREN [Aksoy2014] и алгоритм KUMM [Kumm2023], основанные на использовании MILP-оптимизаторов (Mixed Linear-Integer Problem). Однако при высоких порядках фильтра (более 100) вычислительная сложность существенно возрастает, что делает поиск глобально оптимального решения практически недостижимым за разумное время.

В подобных условиях применяются эвристические подходы, в частности алгоритмы семейства NAIAD [Aksoy2014ISCAS, Xu2007, Shi2011, Yu2010, YliKaakinen2001, Shahein2012, Aktan2008, Chen1999]. Их условно можно разделить на две группы. К первой относятся методы локального поиска, включая NAIAD и алгоритм MLSA [Shahein2012]. Ко второй — итеративные алгоритмы [Xu2007, Shi2011, Yu2010], последовательно расширяющие пространство поиска и уточняющие решение в соответствии с критериями (3.1), (3.2), либо с точки зрения минимизации числа операций сложения при аппаратной реализации.

$$L_2 = \int_0^{2\pi} W(\omega) |H(\omega) - D(\omega)|^2 d\omega \quad (3.1)$$

$$L_\infty = \max_{\omega \in [0, 2\pi]} |W(\omega)(H(\omega) - D(\omega))| \quad (3.2)$$

где $W(\omega)$ — весовая функция, $H(\omega)$ — частотная характеристика синтезируемого фильтра, $D(\omega)$ — требуемая характеристика.

Альтернативный подход к структурной оптимизации цифровых фильтров основан на выявлении функциональных и численных зависимостей между коэффициентами фильтра, как при реализации в арифметике с плавающей точкой, так и в фиксированной. К алгоритмам реализующим данный подход относятся MCM (Multiple Constant Multiplication) [Aksoy2010] и CQA (Coefficient Quantization Algorithm) [fir_quant].

В последующих разделах рассматривается применение алгоритмов CQA, MCM, а также комбинированный подход CQA+MCM для оптимизации структуры цифровых фильтров. Отдельно рассматривается класс полуполосных фильтров HBF (Half-Band filters) ввиду их простоты аппаратной реализации и, как следствие, широкой применимости при проектировании цифровых передискретизаторов.

Кроме того, отдельно рассматриваются уровни компенсации адаптивных моделей с фиксированными предобученными целочисленными фильтрами до и после аппаратной оптимизации при помощи алгоритмов CQA, MCM и CQA+MCM.

3.1 Метод экономии ресурсов при реализации цифровых фильтров засчет квантования параметров

При изготовлении цифровых фильтров аппаратная реализация умножителей является наиболее трудной с точки зрения используемых ресурсов по сравнению с другими элементами прямой формы реализации КИХ-фильтра, то есть сумматорами и элементами задержки. Это связано с тем, что мощность, потребляемая умножителем, а также площадь, занимаемая на кристалле, растут квадратично в зависимости от разрядности умножителя, в то время как потребление этих же ресурсов сумматорами и элементами задержки растёт линейно в зависимости от разрядности.

В связи с этим предлагается использовать метод квантования коэффициентов КИХ-фильтра CQA, позволяющий сократить количество используемых умножителей за счёт выражения одних коэффициентов фильтра через произведение других коэффициентов и степеней двойки.

С точки зрения аппаратной реализации умножители заменяются на сумматоры и битовые сдвиги. Приведём пример из статьи [fir_quant]. Пусть имеется КИХ-фильтр, реализованный в прямой форме, со следующими коэффициентами:

$$\mathbf{h} = \begin{pmatrix} h_0 & h_1 & h_2 & h_3 & h_4 \end{pmatrix}^T = \begin{pmatrix} 1 & 2 & 4 & 3 & 6 \end{pmatrix}^T. \quad (3.1)$$

В данном примере коэффициенты h_0 , h_1 , h_3 точно выражаются через коэффициенты h_2 , h_4 , однако в общем случае такой возможности нет. Алгоритм, приведённый в статье [fir_quant] формирует импульсную характеристику, соответствующую уменьшенному числу умножителей таким образом, чтобы минимизировать отклонение исходных коэффициентов от тех, что формируется алгоритмом. При этом желаемое количество умножителей задаётся пользователем. Формализуем задачу оптимизации.

Пусть параметры фильтра N -ого порядка представлены векторов $\mathbf{h} \in \mathbb{R}^{N+1}$. Для аппаратной реализации такого фильтра вообще говоря требуется $N + 1$ умножителей. Согласно алгоритму CQA [fir_quant] пользователь выбирает желаемое число умножителей M . Введем вектор базисных коэффициентов $\mathbf{b} \in \mathbb{R}^M$, через которые будут коэффициенты $\mathbf{h}$, где $\mathbf{b} \subset \mathbf{h}$.

В результате, вектор оптимизированных коэффициентов $\mathbf{g} \in \mathbb{R}^{N+1}$ может быть выражен через произведение матрицы трансформации $\mathbf{T} \in \mathbb{R}^{(N+1) \times M}$ и вектора базисных коэффициентов $\mathbf{b} \in \mathbb{R}^M$ следующим образом:

$$\mathbf{g} = \mathbf{T}\mathbf{b}, \quad \mathbf{T} = \{T_{i,j}\}, \quad i \in \overrightarrow{0, N}, \quad j \in \overrightarrow{0, M-1}, \quad (3.2)$$

где матрица трансформации содержит только степени двойки 2^{-p} , $p \in \mathbb{N}_0$:

$$T_{i,j} \in \{0, 2^p\}, \quad p \in \overrightarrow{0, K}, \quad (3.3)$$

где K – константа, определяющая точность квантования.

Таким образом, коэффициенты $\mathbf{g}$ реализуются через M умножителей с базисными коэффициентами $\mathbf{b}$, а оставшиеся $N + 1 - M$ небазисных коэффициентов выражаются через базисные за счет операций сложения и битового сдвига.

Ключевой идеей алгоритма CQA является нахождение вектора $\mathbf{b}$ и матрицы $\mathbf{T}$, обеспечивающих аппроксимацию исходных коэффициентов $\mathbf{h}$ наилучшую следующим критерию J :

$$\forall i \in \overrightarrow{0, N+1}, \quad p, j = \arg \min_{p,j} (|h_i| - |g_{j,p}|), \quad g_{j,p} = \frac{b_j}{2^p}, \quad (3.4)$$

где пара $\{b_j, 2^p\}$ для каждого h_i подбирается в соответствии с алгоритмом CQA [fir_quant].

Приведём примеры работы алгоритма для сокращения числа умножителей линейно-фазового Фильтра Нижних Частот, линейно-фазового Полосового Фильтра, а также минимально фазового Фильтра Нижних Частот.

Рассмотрим линейно-фазовый Фильтр Нижних Частот порядка $N = 138$. Пусть коэффициенты его импульсной характеристики $\mathbf{h} = \{h_n\}, n \in \overrightarrow{0, N-1}$. Пусть при этом желаемое количество умножителей $M = 25$. Импульсную характеристику сформированного алгоритмом фильтра обозначим $\mathbf{g} = \{g_n\}, n \in \overrightarrow{0, N-1}$.

На рис. 37 изображена импульсная характеристика исходного фильтра нижних частот h_n , а также отклонение исходных коэффициентов от коэффициентов фильтра, упрощенного с точки зрения аппаратной реализации $h_n - g_n$. Это отклонение мало и составляет порядка 10^{-3} .

На рис. 38 изображена частотная характеристика исходного фильтра $H(\omega)$, фильтра, построенного на 25 умножителях $G(\omega)$, а также разность частотных характеристик $E(\omega) = H(\omega) - G(\omega)$.

Из рис. 38 видно, что величина отклонения частотной характеристики фильтра,




Рис. 37. Линейно-фазовый Фильтр Нижних Частот. Исходная импульсная характеристика h_n и отклонение $h_n - g_n$

построенного на 25 умножителях от частотной характеристики исходного фильтра порядка $N = 138$, реализованного в прямой форме, составляет -60 dB.




Рис. 38. Линейно-фазовый Фильтр Нижних Частот. Исходная частотная характеристика $H(\omega)$, частотная характеристика $G(\omega)$ и отклонение $E(\omega)$

Рассмотрим линейно-фазовый Полосовой Фильтр порядка $N = 138$. Пусть коэффициенты его импульсной характеристики $\mathbf{h} = \{h_n\}, n \in \overline{0, N-1}$. Пусть при этом желаемое количество умножителей $M = 25$. Импульсную характеристику сформированного алгоритмом фильтра также обозначим $\mathbf{g} = \{g_n\}, n \in \overline{0, N-1}$.

На рис. 39 изображена импульсная характеристика исходного полосового филь-

тра h_n , а также отклонение исходных коэффициентов от коэффициентов фильтра, упрощенного с точки зрения аппаратной реализации $h_n - g_n$. Это отклонение мало и составляет порядка 10^{-5} .




Рис. 39. Линейно-фазовый Полосовой Фильтр. Исходная импульсная характеристика h_n и отклонение $h_n - g_n$

На рис. 40 изображена частотная характеристика исходного фильтра $H(\omega)$, фильтра, построенного на 25 умножителях $G(\omega)$, а также разность частотных характеристик $E(\omega) = H(\omega) - G(\omega)$.

Как видно из рис. 40 величина отклонения частотной характеристики фильтра, построенного на 25 умножителях от частотной характеристики исходного фильтра порядка $N = 138$, реализованного в прямой форме, составляет, так же как и для линейно-фазового ФНЧ, -60 dB.

Рассмотрим минимально фазовый Фильтр Нижних Частот порядка $N = 138$. Пусть коэффициенты его импульсной характеристики $\mathbf{h} = \{h_n\}, n \in \overline{0, N-1}$. $\mathbf{g} = \{g_n\}, n \in \overline{0, N-1}$ – импульсная характеристика сформированного алгоритмом фильтра. Рассмотрим случай уменьшения количества умножителей до $M = 25$ и до $M = 70$.

Данный пример интересен в связи с тем, что в данном случае импульсная характеристика исходного фильтра $\mathbf{h} = \{h_n\}$ не является симметричной.

На рис. 41 изображена импульсная характеристика исходного фильтра нижних частот h_n и отклонение $h_n - g_n$ исходных коэффициентов от коэффициентов фильтра, построенного на 25 умножителях. Это отклонение составляет порядка 10^{-4} .

На рис. 42 изображена частотная характеристика исходного фильтра $H(\omega)$, фильтра, построенного на 25 и 70 умножителях $G(\omega)$, а также разность частотных характеристик $E(\omega) = H(\omega) - G(\omega)$ для обоих случаев.

Из рис. 42 видно, что величина отклонения частотной характеристики фильтра,




Рис. 40. Линейно-фазовый Полосовой Фильтр. Исходная частотная характеристика $H(\omega)$, частотная характеристика $G(\omega)$ и отклонение $E(\omega)$




Рис. 41. Минимально фазовый Фильтр Нижних Частот. Исходная импульсная характеристика h_n и отклонение $h_n - g_n$

построенного на 25 умножителях от частотной характеристики исходного фильтра порядка $N = 138$, реализованного в прямой форме, составляет -50 dB.

При этом отклонения частотной характеристики фильтра, построенного на 70 умножителях от частотной характеристики исходного фильтра порядка $N = 138$ составляет -70 dB.

Таким образом, алгоритм, приведённый в статье `[fir_quant]`, позволяет существенно сократить мощность потребляемую цифровым КИХ-фильтром, а также за-




Рис. 42. Минимально фазовый Фильтр Нижних Частот. Исходная частотная характеристика $H(\omega)$, частотная характеристика $G(\omega)$ и отклонение $E(\omega)$

нимаемую площадь кристалла RF-чипсета, за счёт замены части умножителей более простыми с точки зрения аппаратной реализации и затрачиваемых ресурсов битовыми сдвигами и дополнительными сумматорами.

3.2 Метод экономии ресурсов при реализации цифровых передискретизаторов

Цифровые передискретизаторы представляют собой класс устройств цифровой обработки сигналов, предназначенных для изменения частоты дискретизации. Подобные операции широко применяются при обработке аудиосигналов [`audio_resampler`], а также в телекоммуникационных системах [`resampler_telecom`], где требуется согласование различных частот дискретизации на отдельных этапах обработки.

Типовая структура цифровой обработки сигналов, включающая операцию передискретизации, приведена на рис. 43. Подобные схемы используются, в частности, при решении задач синхронизации [`resample_sync`], а также в системах с нелинейной обработкой, где необходимо уменьшить влияние внеполосных спектральных составляющих.

На рис. 43 обозначены: $H(f)$ и $G(f)$ — частотные характеристики фильтров нижних частот; $X(f)$, $U(f)$, $Q(f)$ и $Y(f)$ — спектральные плотности мощности (СПМ) соответственно входного сигнала, сигнала после интерполяции, сигнала после децимации и выходного сигнала. Рассматриваемая схема включает операции интерполяции и децимации, которые заключаются соответственно во вставке нулевых отсчётов и отбрасывании отсчетов через каждые $L - 1$ из L отсчётов входного сигнала. Кроме

того, структура содержит блок нелинейной обработки (НЛ) и фильтры нижних частот (ФНЧ), предназначенные для подавления спектральных копий, возникающих при изменении частоты дискретизации.




Рис. 43. Структура нелинейной обработки сигнала при передискретизации с коэффициентом L

Фильтры нижних частот с конечной импульсной характеристикой (КИХ) широко применяются в системах цифровой передискретизации [**dsp_oppenheim**]. Однако при достаточно большом коэффициенте изменения частоты дискретизации $L = 2^M$ требуемый порядок КИХ-фильтра существенно возрастает. В альтернативном случае передискретизация реализуется в виде каскадной структуры из M последовательно соединённых фильтров нижних частот малого порядка и интерполяторов (или дециматоров) с целочисленным коэффициентом, равным 2 [**lyons_multi_hbf**].

Увеличение порядка фильтра, равно как и применение каскадной структуры, приводит к росту числа аппаратных умножителей. Последние являются наиболее ресурсоёмкими элементами КИХ-фильтров как с точки зрения занимаемой площади кристалла, так и по энергопотреблению [**mults_complex**]. Более того, аппаратные затраты возрастают квадратично с увеличением разрядности умножителей [**mults_power_are**]. Таким образом, при проектировании передискретизаторов особое значение приобретает снижение числа умножителей без ухудшения частотных характеристик.

С этой целью в данном разделе используются полуполосные фильтры [**ch12_gockler**]. Цифровой фильтр половинной полосы (ППФ или HBF – half-band filter) в базовом варианте с вещественными коэффициентами представляет собой фильтр нижних частот, у которого полосы пропускания и задерживания имеют одинаковую ширину.

Вещественные полуполосные фильтры получили широкое распространение благодаря ряду характерных свойств. Во-первых, их импульсная характеристика является симметричной, что обеспечивает линейную фазовую характеристику. Во-вторых, каждый второй коэффициент импульсной характеристики равен нулю, что существенно упрощает аппаратную реализацию и уменьшает количество требуемых умножителей [**ch12_gockler**].

Импульсная характеристика полуполосного фильтра h_k во временной области может быть представлена следующим образом:

$$h_k = h_{-k} = \begin{cases} \frac{1}{2}, & k = 0, \\ 0, & k \bmod 2 = 0, \\ h_k, & k \bmod 2 = 1. \end{cases}$$

Частота среза полуполосного фильтра определяется как $f_s/4$, где f_s — частота дискретизации.

Благодаря высокой вычислительной эффективности цифровые полуполосные фильтры широко применяются в качестве универсальных блоков цифровой обработки сигналов, во входных трактах цифровых приёмников и выходных трактах цифровых передатчиков (в том числе в системах программно-определяемого радио и модемах [ren_multi_band]).

Несмотря на сравнительно низкую вычислительную сложность вещественных ППФ, ресурсы аппаратной реализации могут быть дополнительно сокращены с использованием методов, рассматриваемых в разделах 3.1, 3.3 данной главы.

Рассмотрим ошибку вносимую схемой передискретизации (рис. 43) при квантовании коэффициентов фильтра половинной полосы. В качестве критерия аппаратной оптимизации фильтра будем рассматривать число аппаратных умножений в единицу времени $\lceil f_d(N+1)/4 \rceil$, где N — порядок фильтра, f_d — частота дискретизации, $\lceil \cdot \rceil$ — оператор округления вверх. В случае, если аппаратная реализация обработки не предполагает использования различных тактовых доменов, в качестве критерия оптимизации можно считать $\lceil (N+1)/4 \rceil$.

Отметим, что в результате квантования параметров фильтра изменяются его характеристики такие как ширина переходной полосы, уровень подавления полосы задерживания, величина пульсаций полосы задерживания и пропускания. В результате схема передискретизации (рис. 43) различным образом влияет на исходный сигнал. Исследуем влияние сокращения ресурсов схемы на качество обработки сигнала.

Коэффициент целочисленной передискретизации выбран равным $L = 2$. Рассматриваются фильтры половинной полосы порядков 30, 62 и 94.

В качестве тестового входного сигнала в схеме передискретизации (рис. 43) выбран белый гауссовский шум, поскольку он занимает всю спектральную полосу, что соответствует наиболее сложному случаю с точки зрения цифровой обработки.

Поскольку целью численного эксперимента является анализ влияния схемы передискретизации на входной сигнал, блок нелинейной обработки НЛ (рис. 43) исключён.

Также будем считать, что частотные характеристики фильтров в данной схеме совпадают $H(f) = G(f)$.

На рис. 44 показаны этапы обработки сигнала в схеме передискретизации. На первом этапе шум со спектральной плотностью мощности $X(f)$ подвергается интерполяции с $L = 2$, в результате чего формируется сигнал со спектральной плотностью $U(f)$. Далее сигнал проходит через два фильтра половинной полосы, формируя спектральную плотность $Q(f)$. Затем выходной сигнал фильтра подвергается децимации с целочисленным коэффициентом $L = 2$. В результате спектральные копии перекрываются с соседними зонами Найквиста, что приводит к формированию выходного сигнала со спектральной плотностью $Y(f)$ (рис. 44). Отметим, что в данной




Рис. 44. Преобразование спектра белого гауссовского шума в схеме передискретизации с $L = 2$

схеме фильтры половинной полосы сформированы на частоте дискретизации f_d , а применяются на удвоенной частоте $2f_d$, вследствие чего частота среза фильтра на первом рисунке 44 составляет $f_d/2$.

Величина искажений вносимых схемой передискретизации может быть численно измерена путем подсчета спектральной плотности разности выходного и входного сигналов схемы $y_k - x_k$. На рис. 44 СПМ ошибка представлена как $E(f)$.




Рис. 45. Подстройка параметров фильтра половинной полосы

Расстояние между лепестками спектра ошибки $E(f)$, возникающих в результате наложений копий спектра (рис. 44), определяет допустимую ширину полосы (рабочую полосу) сигнала, который может быть обработан схемой на рис. 43. При этом уровень искажений, вносимых схемой определяется уровнем лепестков, возникающих в результате наложений лепестков полосы задерживания фильтров половинной полосы.

В данном разделе будем исследовать зависимость уровня искажений вносимых схемой передискретизации, а также рабочей полосы от сложности аппаратной реализации оптимизированных при помощи алгоритма СQA фильтров половинной полосы.

Заметим, что уровень пульсаций в полосе пропускания, а также в полосе подавления меняется в зависимости от ширины переходной полосы для фильтра фиксированного порядка (рис. 45). Как видно из рис. 45, ширина переходной полосы фильтра зависит от параметра α .

При этом, уровень искажений на рис. 44 формируется аддитивно за счет пульсаций в полосе пропускания и заграждения. Таким образом, уровень искажений, возникающих в сигнале, проходящем в схеме передискретизации зависит от параметра α . Кроме того, допустимая рабочая полоса напрямую зависит от параметра α .

Поскольку уровень искажений и рабочая полоса зависят от α , будем варьировать этот параметр, чтобы получать НВФ-фильтры с различными характеристиками.

Рассмотрим фильтр половинной полосы 30-го порядка. Такой фильтр имеет 8




Рис. 46. Параметры искажений вносимых схемой передискретизации с аппаратно оптимизированными фильтрами половинной полосы. M – число умножителей. Чёрный прямоугольник указывает на область, представленную в увеличенном масштабе на основном рисунке.

аппаратных умножителей. Будем варьировать параметра α , сокращая при этом число аппаратных умножителей при помощи алгоритма CQA. Характеристики оптимизированных таким образом фильтров представлены на рис. 46. Число аппаратных умножителей после оптимизации обозначено как M . Как видно из рис. 46 рабочая полоса сигнала растёт почти линейно с ростом уровня искажений. Действительно, для фильтра фиксированного порядка чем меньше переходная полоса 2α и больше рабочая полоса, тем больше пульсации в полосе пропускания и заграждения, а значит и уровень искажений, вносимых схемой передискретизации.

С другой стороны из рис. 46 видно, что после аппаратной оптимизации уровень искажений нелинейной зависит от рабочей полосы. Этот эффект связан с особенностью работы алгоритма квантования параметров фильтра.

Будем считать, что -60 dB – допустимый уровень искажений, вносимый схемой обработки сигнала. Согласно рис. 46 минимальное число умножителей фильтра 30-го порядка, соответствующего выбранному уровню искажений, составляет $M = 5$. При это рабочая полоса составляет $0.743f_d$.

Проведем аналогичные численные эксперименты для фильтров 62 и 94 порядка. Характеристики аппаратно оптимизированных фильтров, соответствующих выбранным критериям качества, а также оценки сложности аппаратной реализации собраны в таблице 8.

Из таблицы 8 видно, что для фильтра 30-го порядка аппаратная оптимизация позволяет сократить $\approx 40\%$ умножителей при той же рабочей полосе и том же уровне вносимых искажений схемой передискретизации.

Таблица 8. Оценка ресурсов аппаратно оптимизированных НВФ-фильтров

Порядок фильтра	Число умножителей	Число сумматоров	Число сдвиговых регистров	Уровень искажений, дБ	Рабочая полоса для -60 дБ, f/f_d
N = 30	5	11 (2 порт) или 2 (6 порт) 1 (4 порт) 3 (2 порт)	7	-60	0.743
	8	1 (9 порт) 8 (2 порт)	1	-61	0.745
N = 62	6	26 (2 порт) или 2 (8 порт) 1 (7 порт) 3 (4 порт) 1 (3 порт) 1 (2 порт)	21	-61	0.817
	16	1 (9 порт) 16 (2 порт)	1	-100	0.812
	16	1 (9 порт) 16 (2 порт)	1	-62	0.868
N = 94	7	41 (2 порт) или 1 (18 порт) 2 (8 порт) 2 (6 порт) 1 (4 порт) 1 (3 порт) 2 (2 порт)	35	-62	0.810
	24	1 (25 порт) 24 (2 порт)	1	-140	0.804
	24	1 (25 порт) 24 (2 порт)	1	-62.2	0.911

Для фильтра 62-го порядка схема передискретизации с оптимизированным фильтром вносит уровень искажений -60 дБ, в то время как уровень искажений исходной схемы составляет -100 дБ. Рабочая полоса сокращается примерно на 5%. Тем не менее, сложность аппаратной реализации сокращается примерно на 63%.

Уровень искажений вносимых схемой с аппаратно оптимизированным фильтром 94 порядка составляет -60 дБ, в то время как уровень искажений исходной схемы -140 дБ. Рабочая полоса сокращается на 12%. Тем не менее, число аппаратных умножителей сокращается на 70%.

Таким образом, аппаратная оптимизация, представленная алгоритмом CQA [**fir_quant**] позволяет существенно сократить стоимость аппаратной реализации фильтров половинной полосы при малых изменениях качества работы схемы передискретизации.

3.3 Метод экономии ресурсов при реализации цифровых фильтров при помощи алгоритма MCM

В данном разделе описывается применение алгоритма множественного умножения на константу (MCM - Multiple Constant Multiplication) для аппаратной оптимизации фильтров половинной полосы. Кроме того, рассматривается объединение алгоритма MCM и ранее рассмотренного CQA.

Умножение на константу может быть реализовано с использованием операций

побитового сдвига и сложения/вычитания. Один из простых способов построения такой структуры основан на применении представления числа в формате Signed Digit (SD) вместо стандартного бинарного представления.

Рассмотрим B -разрядное число:

$$x = \sum_{i=0}^{B-1} b_i 2^i. \quad (3.1)$$

В бинарном представлении коэффициенты принимают значения

$$b_i \in \{0, 1\}, \quad (3.2)$$

тогда как в SD-представлении

$$b_i \in \{-1, 0, 1\}. \quad (3.3)$$

Одно и то же число может иметь несколько SD-представлений. Особый интерес представляют представления с минимальным числом ненулевых разрядов. Такие представления называют Minimal Signed Digit (MSD). Однако MSD-представление также не является единственным.

Если дополнительно потребовать, чтобы два соседних разряда не были одновременно ненулевыми, остаётся единственное представление — Canonical Signed Digit (CSD). В среднем MSD-представление содержит примерно на 33% меньше ненулевых разрядов по сравнению с бинарным представлением, что позволяет сократить число операций сложения и вычитания.

Использование более сложных структур сети сумматоров позволяет дополнительно уменьшить количество операций. Задача поиска оптимальной структуры относится к классу NP-сложных.

Аналогичный подход применяется при реализации структур MCM и CAVM (Constant Array Vector Multiplication). Оптимизация таких структур также является вычислительно сложной задачей, поскольку требует перебора большого числа возможных комбинаций коэффициентов.

Операции сдвига, сложения и вычитания удобно объединить в одну обобщённую операцию как на рис. 47:

$$w = A_{(l_1, l_2, s, r)}(u, v) = |(u \ll l_1) + (-1)^s (v \ll l_2)| \gg r, \quad (3.4)$$

где $a \ll b$, $a \gg b$ представляют собой операции битового сдвига числа a на b бит влево и вправо соответственно.

В алгебраической форме данная операция может быть записана как

$$w = |2^{l_1} u + (-1)^s 2^{l_2} v| 2^{-r}, \quad (3.5)$$

где $l_1, l_2 \geq 0$ — целые числа, задающие сдвиг влево, $r \geq 0$ — целое число, опреде-




Рис. 47. Обобщённая базовая операция $A_{(l_1, l_2, s, r)}(u, v)$

ляющее сдвиг вправо, $s \in \{0, 1\}$ – параметр знака, соответствующий сложению или вычитанию.

Алгоритм МСМ формализует задачу следующим образом. Пусть задано множество $T = \{t_1, \dots, t_n\}$ содержащее повторяющиеся положительные нечётные константы, которые необходимо реализовать. Требуется найти множество $R = \{r_0, \dots, r_m\}$ минимальной мощности такое, что выполняются условия $T \subseteq R$, $r_0 = 1$ и для любого r_k , где $1 \leq k \leq m$, существуют r_i, r_j , $0 \leq i, j < k$, и параметры p_k , такие что $r_k = A_{p_k}(r_i, r_j)$. При этом чётные константы могут быть приведены к нечётным путём сдвига вправо.

Для решения поставленной задачи используется алгоритм поиска, предложенный в [Aksoy2010]. Поскольку задача является NP-сложной, нахождение оптимального решения за приемлемое время не всегда возможно. Длительно время поиска решения при проектировании фильтров высокого порядка является основным недостатком алгоритма. В связи с этим предлагается объединение алгоритмов СQA и МСМ с целью сокращения времени поиска.

В данном разделе предлагается метод последовательного применения алгоритмов СQA и МСМ соответственно. На первом этапе применяется алгоритм СQA, который выделяет M умножителей, соответствующих базисным коэффициентам, из N исходных, $M < N$. Уменьшение числа умножителей сопровождается увеличением числа сумматоров. Снижение числа умножителей позволяет упростить структуру фильтра, в результате чего результирующих граф, необходимый для алгоритма МСМ, становится проще. Такой подход позволяет упростить работу алгоритма МСМ для решения NP-сложной задачи.

В результате работы алгоритма МСМ на втором этапе аппаратные умножители заменяются сумматорами и битовыми сдвигами, в результате чего число аппаратных умножителей рассматриваемого фильтра сводится к нулю.

Рассмотрим 2 фильтра половинной полос 30 и 94 порядков. Как и в разделе 3.2 допустимым уровнем искажений квантования будем считать -60 дБ. Оптимизируем их структуру при помощи алгоритма СQA. АЧХ исходного, оптимизированного фильтров, а также их разность изображена на рис. 48.

Число умножителей аппаратно оптимизированных фильтров (рис. 48) составляет




Рис. 48. АЧХ исходного – кривая 1, аппаратно оптимизированного – кривая 2 и их разность – кривая 3 для фильтров половинной полосы 30 и 94 порядков соответственно

5 (из 8 исходных) и 7 (из 25 исходных) для фильтров 30 и 94 порядка соответственно. Это составляет 30% и 75% уменьшения аппаратных ресурсов соответственно. При этом уровень искажений вносимых в систему за счет квантования составляет < 60 дБ.

Далее, для применения алгоритма МСМ необходимо перевести фильтр из прямой формы в транспонированную. После применения алгоритма получается структура на сумматорах и сдвиговых регистрах. Затем, полученная структура снова переводится в прямую форму.

В таблице 9 собраны ресурсы необходимые для аппаратной реализации рассмотренных фильтров 30 и 94 порядков до и после аппаратной оптимизации. Как видно из результатов симуляции, фильтры могут быть реализованы без проектирования аппаратных умножителей. При этом увеличивается число сумматоров и сдвиговых регистров.

Таблица 9. Сравнение аппаратных ресурсов НВФ фильтров до и после аппаратной оптимизации

Порядок фильтра	Метод	Умножители	Сумматоры (двухвходовые)
$N = 30$	До оптимизации	8	8
	СQA	5	11
	МСМ	0	25
	СQA+МСМ	0	18
$N = 94$	До оптимизации	24	24
	СQA	7	48
	МСМ	0	64
	СQA+МСМ	0	56

Как видно из таблицы 9, объединение алгоритмов СQA+МСМ позволяет сократить число сумматоров на 28% и 13% по сравнению с алгоритмом МСМ для фильтров 30 и 94 порядка соответственно. При этом, число аппаратных умножителей сокращено до нуля по сравнению с алгоритмом СQA.

Сравним рассмотренные алгоритмы с известными и широко применяемыми ме-

тодами оптимизации КИХ-фильтров [Aksoy2014, Kumm2023, Xu2007, Shi2011, Yu2010]. В качестве тестовых примеров использованы фильтры нижних частот, параметры которых приведены в табл. 10. В таблице приняты следующие обозначения: N — число коэффициентов фильтра; w_p и w_s — граничные круговые частоты полос пропускания и подавления; δ_p и δ_s — максимально допустимые отклонения амплитудно-частотной характеристики в соответствующих полосах.

Результаты сравнения работы алгоритмов приведены в табл. 11. Из табл. 11 следует, что алгоритмы NAIAD, SIREN, AKTAN [Aktan2008] и CHEN [Chen1999] позволяют уменьшить ресурсы аппаратной реализации, однако синтез фильтров высокого порядка характерен высокой вычислительной нагрузкой. За счёт полного перебора возможных структур данные методы обеспечивают дополнительное сокращение ресурсов до 10% по сравнению с предложенными алгоритмами.

Для фильтра “С” алгоритмы AKTAN [Aktan2008] и CHEN [Chen1999] требуют до одного дня вычислений, в то время как комбинация CQA + MCM обеспечивает получение результата за 2 с.

Таблица 10. Параметры тестовых фильтров

Фильтр	N	w_p	w_s	δ_p	δ_s
X1	15	0.2π	0.8π	0.0001	0.0001
G1	16	0.2π	0.5π	0.01	0.01
Y1	30	0.3π	0.5π	0.00316	0.00316
Y2	38	0.3π	0.5π	0.001	0.001
B	105	0.2π	0.24π	0.01	0.01
C	325	0.125π	0.14π	0.005	0.005

Таким образом, объединение алгоритмов CQA+MCM позволяет добиться большего сокращения ресурсов по сравнению с отдельными алгоритмами CQA и MCM. Кроме того, предложенный метод демонстрирует сокращение ресурсов аппаратной реализации сравнимое с классическими подходами. При этом существенно сокращается время работы алгоритмов, что является существенным фактором для задач оптимизации фильтров высоких порядков.

Рассмотрены методы аппаратной оптимизации в применении к фильтрам половинной полосы. Тем не менее, методы CQA, MCM и CQA+MCM могут быть применены к произвольным КИХ-фильтрам, включая фильтры нижних частот, полосовые и режекторные. Кроме того, рассмотренные методы могут быть применены к оптимизации как линейно-фазовых, так и нелинейно-фазовых фильтров.

Таблица 11. Сравнение ресурсов аппаратной реализации фильтров и времени расчёта

Фильтр	N	Метод	Стоимость (сумматоры)	Время вычисления
X1	15	KUMM [8]	13	–
		XCJ [9]	15	–
		NAIAD	13	1 мин 3 с
		SIREN	13	2 с
		SHI [10]	13	< 1 с
		MCM	22	2 с
		MCM + CQA	24	2 с
G1	16	KUMM [8]	17	–
		GUSTAFSSON [11]	15	–
		NAIAD	18	50 с
		SHI [10]	17	< 1 с
		SIREN	17	< 1 с
		MCM	19	2 с
		MCM + CQA	19	2 с
Y1	30	KUMM [8]	30	–
		YU [12]	29	21 мин 30 с
		NAIAD	30	6 мин 3 с
		SHI [10]	30	6 с
		SIREN	29	7 мин 56 с
		MCM	40	2 с
		MCM + CQA	37	2 с
	29	MCM	33	2 с
		MCM + CQA	36	2 с
Y2	38	KUMM [8]	38	–
		YLI-KAAKINEN [13]	39	–
		NAIAD	38	19 мин 18 с
		SHI [10]	47	11 с
		SIREN	38	4 мин 29 с
		MCM	48	2 с
		MCM + CQA	47	2 с
B	105	KUMM [8]	–	неосуществимо
		SHAHEIN [14]	109	–
		AKTAN [15]	111	1 мин 7 с
		NAIAD	109	1 день
		MCM	125	2 ч 2 мин
		MCM + CQA	120	2 с
	107	GB	117	2 с
		MCM + CQA	115	2 с
C	325	KUMM [8]	–	неосуществимо
		CHEN [16]	365	1 день
		AKTAN [15]	328	1 день
		NAIAD	311	4 ч
		MCM	374	2 с
		MCM + CQA	355	2 с

3.4 Сокращение ресурсов при реализации классических моделей нелинейных искажений за счет оптимизации структуры цифровых фильтров

В данном разделе рассматривается применение алгоритмов аппаратной оптимизации вещественных КИХ-фильтров в задаче компенсации нелинейных искажений в передатчике двухканальной системы связи (рис. 17).

Системы компенсации двухканальной системы, а также сигнал передатчика на входе и выходе нелинейного УМ описаны в разделе 2.3 главы II. В последующих численных экспериментах будем рассматривать компенсацию искажений в канале B .

В качестве модели нелинейных искажений выбрана структура на основе модели Винера (раздел 5.6 главы I). Структура модели изображена на рис. 49. Выходной




Рис. 49. Модель адаптивной компенсации нелинейных искажений в двухканальной системе связи на основе модели Винера

отсчет модели может быть выражен как:

$$\begin{aligned}
 y_n &= \sum_{r=0}^{R-1} s_{n,r} = \sum_{r=0}^{R-1} \tilde{z}_{n,B,r} f(|z_{n,A,r}|, |z_{n,B,r}|, \mathbf{h}_r), \\
 \tilde{z}_{n,B,r} &= \sum_{k=-D}^D \tilde{w}_{k,B,r} x_{n-k,B}, \\
 z_{n,B,r} &= \sum_{k=-D}^D w_{k,B,r} x_{n-k,B}, \\
 z_{n,A,r} W &= \sum_{k=-D}^D w_{k,A,r} x_{n-k,A},
 \end{aligned} \tag{3.1}$$

где $s_{n,r}$, $r = \overline{0, R-1}$ – отсчет на выходе ветки r , $\tilde{z}_{n,B,r}$, $z_{n,B,r}$ и $z_{n,A,r}$ – отсчеты на выходе фильтров с коэффициентами $\tilde{\mathbf{w}}_{B,r} = \left(\tilde{w}_{-D,B,r} \ \cdots \ \tilde{w}_{D,B,r} \right)^T \in \mathbb{R}^{M \times 1}$, $\mathbf{w}_{B,r} = \left(w_{-D,B,r} \ \cdots \ w_{D,B,r} \right)^T \in \mathbb{R}^{M \times 1}$ и $\mathbf{w}_{A,r} = \left(w_{-D,A,r} \ \cdots \ w_{D,A,r} \right)^T \in \mathbb{R}^{M \times 1}$ соответственно, ветка с индексом r , $M-1 = 2D$ – порядок фильтров, $f(|z_{n,A,r}|, |z_{n,B,r}|)$ – адаптивная двумерная нелинейность с адаптивными параметрами $\mathbf{h}_r \in \mathbb{R}^{L^2 \times 1}$, $L = 6$. Функциональный базис нелинейности построен на сплайновых полиномах (5.3.7) ввиду их простоты аппаратной реализации.

Выбор числа веток $R = 4$ в данной задаче обусловлен достижением уровня компенсации нелинейных искажений до уровня шума. Для текущих данных такой уровень компенсации соответствует значению критерия NMSE = -20 дБ, где ошибка нормируется относительно уровня ошибки до компенсации искажений.

Для простоты в данной модели порядки фильтров выбраны равными, $M = 11$. Выбор величины M обусловлен инерционными свойствами нелинейного УМ и подобран эмпирически с точки зрения минимизации аппаратных ресурсов.

Инерционные свойства УМ можно приближенно считать неизменными. В связи с этим, коэффициенты вещественных предобученных фильтров фиксируются. Параметры нелинейных функций могут быть как статическими так и адаптивным и обучаться по мере изменения температуры и других характеристик, влияющих на нелинейную характеристику УМ.

Отметим, что число аппаратных вещественных умножений для вычисления выходного отсчета одномерной нелинейной модели на основе сплайнового полинома (5.3.7) равно 5 [kamara2024secured]. При этом число вещественных умножений для реализации двумерной модели на основе линейно-сплайнового базиса равно 15.

При этом аппаратная реализация одного комплексного КИХ-фильтра подразумевает аппаратную реализацию как минимум $2M$ вещественных умножителей, где $M-1$ – порядок фильтра. Число аппаратных умножителей необходимых для реализации фильтров с $M = 11$ в одной ветке составляет 66.

Таким образом, аппаратная реализация комплексных предобученных фильтров

является наиболее ресурсоёмкой задачей для данной модели искажений. В данном разделе будем рассматривать аппаратную оптимизацию фильтров при помощи алгоритмов CQA, MSM и их комбинации CQA+MSM, рассмотренных в разделах 3.1, 3.3.

Рассмотрим процесс аппаратной оптимизации фильтров. Сначала обучается модель (3.1) при помощи блочного градиентного спуска с оптимизатором Adam (раздел 2.2 главы I), а также линейно убывающим шагом адаптации (1.1) с $T = 208500$ – число эпох обучения, $\mu_0 = 10$, $\alpha_{\text{start}} = 1$, $\alpha_{\text{end}} = 10^{-3}$, длина блока данных 256. После обучения коэффициенты всей модели фиксируются.

Затем применяется алгоритм аппаратной оптимизации фильтров. В случае применения MSM, алгоритм строит вычислительный граф, состоящих из битовых сдвигов и сумматоров, таким образом, чтобы выходные отсчеты каждого из фильтров до и после оптимизации совпадали. Таким образом, MSM обеспечивает аппаратную оптимизацию без потери качества модели. Отметим, что поскольку MSM строит граф так, чтобы исходное скалярное произведение сигнала с вектором коэффициентов было равно значению в корне графа, алгоритм применяется последовательно к каждому фильтру модели отдельно.

Алгоритм квантования коэффициентов CQA применяется к вектору коэффициентов, представляющему собой объединение векторов коэффициентов всех фильтров. Такой подход обусловлен тем, чтобы позволить алгоритму CQA выражать коэффициенты каждого фильтра через коэффициенты других фильтров. При этом в качестве ошибки квантования набора фильтров будет считать максимальное отклонение АЧХ квантованного фильтра от АЧХ исходного:

$$E = \max_j \Delta H_j = \max_j (H_{\text{квант.},j} - H_{\text{исх.},j}), \quad j = \overrightarrow{0, 6R} \quad (3.2)$$

где $6R = 24$ – общее число фильтров в модели. В данной работе будем рассматривать квантование коэффициентов таким образом, чтобы максимальная ошибка квантования составляла $E \in \{-60, -50, -40, -30, -20, -10, 0\}$ дБ.

Объединение алгоритмов CQA+MSM подразумевает следующую процедуру. Сначала применяется CQA к вектору $\mathbf{w} = \begin{pmatrix} \mathbf{w}_0^T & \mathbf{w}_1^T & \cdots & \mathbf{w}_{6R-1}^T \end{pmatrix}^T \in \mathbb{R}^{6RM \times 1}$, представляющему собой объединение векторов коэффициентов всех фильтров. CQA генерирует матрицу трансформации $\mathbf{T} \in \mathbb{R}^{6RM \times Q}$, а также базисные коэффициенты $\mathbf{b} \in \mathbb{R}^{Q \times 1}$. При этом базисные коэффициенты $\mathbf{b}$ выбраны среди коэффициентов всех фильтров $\mathbf{w}_j \in \mathbb{R}^{M \times 1}$, $j = \overrightarrow{0, 6R}$. Поскольку, как отмечено ранее, MSM применяется к каждому фильтру отдельно, вектор базисных коэффициентов $\mathbf{b}$ должен быть разделен на вектора $\mathbf{b}_j \in \mathbb{R}^{Q_j \times 1}$, $j = \overrightarrow{0, 6R}$ такие, что множество коэффициентов вектора $\mathbf{b}_j$ включается во множество коэффициентов исходного фильтра $\mathbf{w}_j$, то есть $\{b_{j,k}\}_{k=0}^{Q_j-1} \subset \{w_{j,k}\}_{k=0}^{M-1}$, где $\sum_{j=0}^{6R-1} Q_j = Q$. Иначе говоря для каждого фильтра j MSM заменяет аппаратные умножители, которые соответствуют реализации фильтра j , оставшиеся после работы CQA, на аппаратные сумматоры и битовые сдвиги.

Рассмотрим уровень компенсации нелинейных искажений предложенной моде-

лю. На рис. 50 изображена спектральная плотность мощности сигнала передатчика на выходе УМ до и после компенсации нелинейных искажений в случаях применения различных алгоритмов аппаратной оптимизации вещественных преобученных фильтров. Как видно из рис. 50 уже при уровне ошибки квантования $E = -20$ дБ (3.2) модель гарантирует компенсацию искажений почти без потери качества.




Рис. 50. Спектральность мощности сигнала передатчика до и после компенсации DPD при различных уровнях ошибки квантования коэффициентов фильтров $\max_i \Delta H_i$




Рис. 51. Спектральность мощности сигнала разности сигнала передатчика при включенном DPD до и после квантования коэффициентов фильтров при различных уровнях ошибки квантования $\max_i \Delta H_i$

На рис. 51 изображена спектральная плотность мощности отклонения выхода модели до и после квантования коэффициентов для различных E дБ. Отклонение уровня компенсации искажений от уровня компенсации до квантования при ошибке

квантования $E = -20$ дБ составляет -50 дБ. При $E = -30$ дБ, отклонение составляет менее -60 дБ.

В таблице 12 собраны результаты численных экспериментов компенсации искажений, а также ресурсы аппаратной реализации до и после аппаратной оптимизации предобученных фильтров при помощи алгоритмов CQA, MCM и CQA+MCM для различных уровней квантования коэффициентов. Алгоритм MCM, примененный к

Таблица 12. Сравнение уровня компенсации и аппаратных ресурсов для реализации для модели на основе модели Винера с предобученными аппаратно оптимизированными коэффициентами фильтров

Алгоритм	$\max \Delta H_i$, дБ	NMSE, дБ	Число умножителей	Число 2-вход. сумматоров	Число бит. сдвигов
Исходные коэф-ты	—	-20.03	264	240	0
MCM	—	-20.03	0	358	490
CQA	-60	-20.03	201	240	63
CQA	-50	-20.03	160	240	104
CQA	-40	-20.03	128	240	136
CQA	-30	-20.02	70	240	194
CQA	-20	-20.00	25	240	239
CQA	-10	-18.64	10	240	254
CQA	0	-11.98	3	240	261
CQA+MCM	-60	-20.03	0	323	469
CQA+MCM	-50	-20.03	0	315	442
CQA+MCM	-40	-20.03	0	298	426
CQA+MCM	-30	-20.02	0	264	370
CQA+MCM	-20	-20.00	0	247	295
CQA+MCM	-10	-18.64	0	238	273
CQA+MCM	0	-11.98	0	237	261

исходным предобученным коэффициентам позволяет сократить число аппаратных умножителей до нуля без потерь качества, в то время как алгоритм CQA сокращает число умножителей до 25 с малыми потерями компенсации искажений ≈ 0.03 дБ для ошибки квантования $\max \Delta H_i = -20$ дБ. При этом число аппаратных сумматоров сокращается на 32.9%, а битовых сдвигов на 51.2% относительно MCM.

Для $\max \Delta H_i = -10$ дБ CQA сокращает число умножителей до 10 с потерями качества 1.4 дБ, при этом число аппаратных сумматоров сокращается на 32.9%, а битовых сдвигов на 48.2% относительно MCM.

Последовательное применение рассмотренных алгоритмов CQA+MCM позволяет сократить число аппаратных умножителей до нуля с малыми потерями качества ≈ 0.03 дБ для $\max \Delta H_i = -20$ дБ. При этом число сумматоров сокращается на 32.9%, а битовых сдвигов на 48.2% относительно MCM.

Для $\max \Delta H_i = -10$ дБ CQA сокращает число умножителей до нуля с потерями качества ≈ 1.4 дБ, при этом число аппаратных сумматоров сокращается на 32.9%, а битовых сдвигов на 51.2% по сравнению с MCM.

Таким образом, подход на основе последовательного применения аппаратной оптимизации алгоритмов CQA+MCM, предложенный в статье [Bakholdin2025] позволяет существенно сократить ресурсы аппаратной реализации предобученных фильтров модели Винера (3.1) по сравнению с реализацией модели без аппаратной оптимизации, а также модели с аппаратной оптимизацией на основе алгоритма CQA и MCM.

Заключение

В диссертационной работе проведено комплексное исследование методов адаптивной компенсации нелинейных искажений в приёмном и передающем трактах современных систем связи. Рассмотрены теоретические и прикладные аспекты построения нелинейных моделей, алгоритмов их адаптации, а также вопросы аппаратной реализации цифровых корректоров в условиях ограниченных вычислительных ресурсов.

В работе систематизированы подходы к построению адаптивных моделей нелинейных искажений — от классических структур, отражающих физическую природу процессов в радиотракте (модели Винера, Гаммерштейна, обобщённые полиномиальные модели с памятью), до нейросетевых архитектур, рассматриваемых как универсальные аппроксиматоры нелинейных зависимостей.

Показано, что выбор модели определяется компромиссом между интерпретируемостью, вычислительной сложностью и аппроксимационной способностью. Классические модели обеспечивают структурную связь с физическими механизмами формирования искажений и удобны для аппаратной реализации, тогда как нейросетевые модели позволяют адаптивно формировать функциональный базис.

Отдельное внимание уделено методам адаптации нелинейных корректоров. Рассмотрены алгоритмы первого порядка, квазиньютоновские методы и методы второго порядка. Предложенный смешанный метод Ньютона обеспечивает ускоренную сходимость по сравнению с градиентными методами, а также демонстрирует устойчивое поведение в окрестности седловых точек при выполнении условий голоморфности функции ошибки.

Для снижения вычислительной сложности предложена модификация смешанного метода Ньютона на основе метода сопряжённых градиентов, позволяющая отказаться от явного обращения матрицы Гессе при сохранении преимуществ по скорости сходимости. Таким образом, сформирована теоретическая и алгоритмическая база для построения адаптивных нелинейных корректоров различной структуры.

В рамках исследования рассмотрены задачи компенсации нелинейных искажений как в приёмном тракте (Self-Interference Cancellation), так и в передающем тракте (Digital Pre-Distortion).

В задаче компенсации помех в приёмнике проанализированы механизмы формирования собственных помех, включая интермодуляционные компоненты второго порядка.

В рамках рассмотрения задачи компенсации собственных помех в полнодуплексной системе связи проведен сравнительный анализ скорости сходимости смешанного метода Ньютона, а также классических ускоренных градиентных методов. Показано, что хотя смешанный метод Ньютона для вычисления шага требует в ~ 5 раз больше времени, общая длительность обучения составляет 30 эпох, в то время как общая длительность обучения ускоренными методами первого порядка составляет 10000 эпох. При этом в обоих случаях достигается один и тот же уровень компенсации равный 46.9 дБ. Полученные результаты подтверждают эффективность предложенного подхода по сравнению с методами первого порядка.

Предложен метод уменьшения ресурсов при реализации смешанного метода Ньютона на основе метода сопряженных градиентов. Метод позволяет оценивать шаг смешанного метода Ньютона без явного обращения матрицы Гессе при сохранении высокой скорости сходимости. В зависимости от числа итераций L метода сопряженных градиентов на один пересчет параметров модели варьируется точность аппроксимации.

В случае $L = 10$ метод сопряженных градиентов достигает уровня компенсации равный уровню компенсации ускоренным градиентным методом за число итераций в 90 раз меньше числа итераций градиентного метода. В случае $L = 10$ вычислительная сложность метода сопряженных градиентов составляет 68% вычислительной сложности смешанного метода Ньютона, обеспечивает тот же уровень компенсации, но на 33% времени работы требует больше.

Для задачи компенсации комбинационной помехи второго порядка проведено сравнительное исследование классической полиномиальной модели на основе функционального базиса Чебышёва и нейросетевой модели на основе полносвязного перцептрона. Показано, что нейросетевой подход может рассматриваться как адаптивный функциональный базис, позволяющий повысить уровень компенсации при уменьшении аппаратных ресурсов. Согласно численным результатам применение подхода на основе полносвязной модели позволяет сократить число параметров на 45%, при этом уровень компенсации отличается от уровня компенсации полиномиальной модели менее, чем на 0.5 дБ для рассмотренных алгоритмов Adam и L-BFGS.

В то же время, функция потерь является невыпуклой в случае применения полносвязной модели и, как следствие скорость сходимости алгоритмов адаптации меньше по сравнению с полиномиальной моделью. Так уровень компенсации 20 дБ достигается полиномиальной моделью за 50 итераций ускоренного градиентного метода, в то время как полносвязная модель достигает того же уровня компенсации за 320 итераций. При этом уровень компенсации 22.76 дБ достигается полиномиальной моделью за 5000 итераций, а полносвязной моделью за 7000 итераций.

Также предложено использование метода квазиньютоновского метода L-BFGS для ускорения обучения обеих моделей. Так уровень компенсации 23.41 дБ достигается полиномиальной моделью за 100 итераций, в то время как полносвязной модели

требуется 1250 итераций для достижения того же уровня компенсации.

Рассмотрена задача компенсации нелинейных искажений в передатчике в условиях динамического режима работы усилителя мощности. Предложена многомерная модель, учитывающая динамические режимы работы усилителя мощности за счёт введения дополнительных признаков. В отличие от подходов, основанных на переключении параметров, предложенная модель обеспечивает единое представление нелинейной характеристики во всём диапазоне изменения выходной мощности 11.2 дБ.

Проведен сравнительный анализ предложенной модели с классическим подходом на основе одномерной полиномиальной модели. Предложенная двумерная модель обеспечивает до 14 дБ выше уровень компенсации нелинейных искажений во всем динамическом диапазоне мощности УМ поскольку обладает большей обобщающей способностью при таком же числе адаптивных параметров.

Для преодоления проблемы экспоненциального роста числа параметров многомерной модели с числом измерений предложено использование метода рангового разложения, позволяющего существенно сократить число адаптивных параметров при сохранении высокой точности аппроксимации. Адаптация параметров выполняется с использованием смешанного метода Ньютона.

Аппроксимация ранга 1 позволяет сократить число адаптивных параметров модели на 79.2% при уменьшение уровня компенсации искажений до 9 дБ для малых значений выходной мощности до 0.25 Вт, для значений от 0.25 Вт до 0.91 Вт – менее 1 дБ. Аппроксимация ранга 2 позволяет сократить числоа паратров на 58.3% при уменьшение уровня компенсации на 3 дБ для значений выходной мощности до 0.2 Вт, для значений от 0.2 Вт до 0.91 Вт – менее 1 дБ.

Таким образом, малоранговая аппроксимация предложена как компромисс между точностью предсказания нелинейных искажений УМ в динамическом режиме работы и ресурсами аппаратной реализации адаптивного корректора.

Отдельное направление работы посвящено задачам аппаратной оптимизации цифровых фильтров, широко применяемых в системах адаптивной нелинейной обработки сигналов как в составе цифровых передискретизаторов так и в составе адаптивных моделей.

Предложен алгоритм квантования коэффициентов цифровых фильтров СQA, позволяющий заменить часть операций умножения операциями сдвига, что приводит к снижению энергопотребления и площади кристалла необходимой для реализации. Работа данного алгоритма рассмотрена на примере аппаратной оптимизации фильтров половинной полосы в системе передискретизации для нелинейной обработки сигналов. Рассмотрен уровень искажений вносимых в схему передискретизации засчет квантования коэффициентов фильтров, а также изменение рабочей полосы сигнала, который может быть обработан в схеме передискретизации.

Для фильтра 30-го порядка аппаратная оптимизация позволяет сократить $\approx 40\%$

умножителей при той же рабочей полосе и том же уровне вносимых искажений схемой передискретизации.

Для фильтра 62-го порядка схема передискретизации с оптимизированным фильтром вносит уровень искажений -60 дБ, в то время как уровень искажений исходной схемы составляет -100 дБ. Рабочая полоса сокращается примерно на 5%. Тем не менее, сложность аппаратной реализации сокращается примерно на 63%.

Уровень искажений вносимых схемой с аппаратно оптимизированным фильтром 94 порядка составляет -60 дБ, в то время как уровень искажений исходной схемы -140 дБ. Рабочая полоса сокращается на 12%. Тем не менее, число аппаратных умножителей сокращается на 70%.

Разработан комбинированный подход, основанный на совместном применении алгоритма квантования и метода Multiple Constant Multiplication (MCM). На первом этапе сокращается число уникальных коэффициентов, требующих аппаратной реализации, после чего формируется вычислительный граф, исключающий использование аппаратных умножителей. Такой подход позволяет дополнительно уменьшить площадь кристалла и энергопотребление при реализации цифровых фильтров в составе адаптивных корректоров.

Предложенный комбинированный подход CQA+MCM позволяет добиться сокращения ресурсов аппаратной оптимизации сравнимого с классическими подходами такими как NAIAD, SIREN, AKTAN, CHEN. При этом существенно сокращается время работы алгоритма, что является существенным фактором для решения задачи оптимизации фильтров высокого порядка. Так для рассмотренного фильтра 324 порядка алгоритмы AKTAN, CHEN требует около одного дня вычислений, в то время как предложенный метод требует ≈ 2 с времени работы.

Работа предложенных алгоритмов рассмотрена на примере аппаратной оптимизации фильтров модели Винера в задаче компенсации нелинейных искажений в передатчике двухканальной системы связи. При этом число аппаратных сумматоров повышается на 49.2%, а число битовых сдвигов с нуля до 490.

Алгоритм квантования позволяет сократить чисто умножителей до 25, то есть более, чем в 10 раз, относительно исходного, число сумматоров остается неизменным, а число битовых сдвигов повышается с нуля до 239. При этом уровень компенсации нелинейных искажений уменьшается менее, чем на 0.1 дБ.

Комбинированный подход CQA+MCM позволяет сократить число аппаратных умножителей до нуля, число сумматоров лишь на 3% больше исходного и составляет 247, число битовых сдвигов 295. Относительно алгоритма MCM число сумматоров меньше на 32.9%, а число битовых сдвигов на 48.2%. При этом уровень компенсации нелинейных искажений уменьшается менее, чем на 0.1 дБ по сравнению с исходным, а также MCM. Данный результат демонстрирует преимущества комбинированного подхода по сравнению с рассмотренными алгоритмами квантования и MCM, работающими независимо.

Результаты проведённого исследования показывают, что повышение энергетической и спектральной эффективности телекоммуникационных устройств требует комплексного подхода, объединяющего разработку нелинейных моделей, алгоритмов их адаптации с высокой скоростью сходимости и методов аппаратной оптимизации. Согласованное развитие этих компонентов позволяет обеспечить требуемый уровень линейности радиотракта при одновременном повышении коэффициента полезного действия и снижении вычислительных и энергетических затрат.